TP-output

2025-05-14

```
#######################################################
# PARTE 01: CONFIGURACIÓN INICIAL Y CARGA DE DATOS
#######################################################
## PROJECT WD
# Determinar el directorio del proyecto correctamente
if (exists(".rs.getProjectDirectory") &&
    is.function(get(".rs.getProjectDirectory"))) {
  # Si estamos en RStudio, usar la función de RStudio
  project_dir <- .rs.getProjectDirectory()
  print(paste("Directorio del proyecto (RStudio):", project_dir))
} else {
  # Si no estamos en RStudio o la función no existe
  current_dir <- getwd()

  # Verificar si estamos dentro de la carpeta 'code'
  if (basename(current_dir) == "code") {
    # Subir un nivel para llegar a la raíz del proyecto
    project_dir <- dirname(current_dir)
    print(paste("Detectada ejecución desde carpeta 'code', subiendo un nivel:", project_dir))
  } else {
    # Asumir que estamos en la raíz del proyecto
    project_dir <- current_dir
    print(paste("Directorio actual (asumido como raíz del proyecto):", project_dir))
  }
}
```

```
## [1] "Detectada ejecución desde carpeta 'code', subiendo un nivel: D:/@aleec02/CC216-TP-2025-1"
```

```
# Definir las rutas de los directorios (SIEMPRE relativas a la raíz del proyecto)
data_dir <- file.path(project_dir, "data")
code_dir <- file.path(project_dir, "code")

# Verificar que las rutas existen
if (!dir.exists(data_dir)) {
  stop(paste("El directorio de datos no existe:", data_dir))
}
if (!dir.exists(code_dir)) {
  stop(paste("El directorio de código no existe:", code_dir))
}

# Mostrar la información de directorios
cat("Directorio del proyecto:", project_dir, "\n")
```

```
## Directorio del proyecto: D:/@aleec02/CC216-TP-2025-1
```

```r
cat("Directorio de datos:", data_dir, "\n")
```

```
## Directorio de datos: D:/@aleec02/CC216-TP-2025-1/data
```

```r
cat("Directorio de código:", code_dir, "\n")
```

```
## Directorio de código: D:/@aleec02/CC216-TP-2025-1/code
```

```r
# Ruta al archivo CSV (relativa a la raíz del proyecto)
CSV_original <- file.path(data_dir, "hotel_bookings.csv")
if (!file.exists(CSV_original)) {
  stop(paste("El archivo CSV no existe:", CSV_original, "\nVerificar ruta completa."))
}
```

```r
## LIBRARIES
if (!require("tidyverse", quietly = TRUE)) install.packages("tidyverse")
```

```
## -- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
## v dplyr     1.1.4     v readr     2.1.5
## v forcats   1.0.0     v stringr   1.5.1
## v ggplot2   3.5.2     v tibble    3.2.1
## v lubridate 1.9.4     v tidyr     1.3.1
## v purrr     1.0.4
## -- Conflicts ------------------------------------------ tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```r
if (!require("naniar", quietly = TRUE)) install.packages("naniar")
if (!require("skimr", quietly = TRUE)) install.packages("skimr")
```

```
##
## Adjuntando el paquete: 'skimr'
##
## The following object is masked from 'package:naniar':
##
##     n_complete
```

```r
if (!require("knitr", quietly = TRUE)) install.packages("knitr")
if (!require("crayon", quietly = TRUE)) install.packages("crayon")
```

```
##
## Adjuntando el paquete: 'crayon'
##
## The following object is masked from 'package:ggplot2':
##
##     %+%
```

```r
if (!require("ggplot2", quietly = TRUE)) install.packages("ggplot2")
if (!require("gridExtra", quietly = TRUE)) install.packages("gridExtra")
```

```
##
## Adjuntando el paquete: 'gridExtra'
##
## The following object is masked from 'package:dplyr':
##
##     combine
```

```r
## INITIAL SETUP
library(tidyverse)
library(naniar)
library(skimr)
library(knitr)
library(crayon)
library(ggplot2)
library(gridExtra)

# Definir directorios relativos al proyecto
data_dir <- file.path(project_dir, "data")
code_dir <- file.path(project_dir, "code")

if (!dir.exists(data_dir)) {
  stop(red("El directorio de datos no existe:", data_dir))
}
if (!dir.exists(code_dir)) {
  stop(red("El directorio de código no existe:", code_dir))
}

cat(green("Directorio del proyecto:"), project_dir, "\n")
```

```
## Directorio del proyecto: D:/@aleec02/CC216-TP-2025-1
```

```r
cat(green("Directorio de datos:"), data_dir, "\n")
```

```
## Directorio de datos: D:/@aleec02/CC216-TP-2025-1/data
```

```r
cat(green("Directorio de código:"), code_dir, "\n")
```

```
## Directorio de código: D:/@aleec02/CC216-TP-2025-1/code
```

```r
CSV_original <- file.path(data_dir, "hotel_bookings.csv")
if (!file.exists(CSV_original)) {
  stop(red("El archivo CSV no existe:", CSV_original))
}

cat(green("Cargando datos desde:"), CSV_original, "\n")
```

```
## Cargando datos desde: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings.csv
```

```r
hotel_data <- read.csv(CSV_original, header = TRUE, stringsAsFactors = FALSE)

hotel_data <- unique(hotel_data)

# Inspección inicial
cat(yellow("\n--- DIMENSIONES DEL DATASET ---\n"))
```

```
##
## --- DIMENSIONES DEL DATASET ---
print(dim(hotel_data))
```

```
## [1] 87396    32
```

```
cat(yellow("\n--- PRIMERAS FILAS DEL DATASET ---\n"))
```

```
##
## --- PRIMERAS FILAS DEL DATASET ---
print(head(hotel_data, 5))
```

```
##          hotel is_canceled lead_time arrival_date_year arrival_date_month
## 1 Resort Hotel           0       342              2015               July
## 2 Resort Hotel           0       737              2015               July
## 3 Resort Hotel           0         7              2015               July
## 4 Resort Hotel           0        13              2015               July
## 5 Resort Hotel           0        14              2015               July
##   arrival_date_week_number arrival_date_day_of_month stays_in_weekend_nights
## 1                       27                         1                      0
## 2                       27                         1                      0
## 3                       27                         1                      0
## 4                       27                         1                      0
## 5                       27                         1                      0
##   stays_in_week_nights adults children babies meal country market_segment
## 1                    0      2        0      0   BB     PRT         Direct
## 2                    0      2        0      0   BB     PRT         Direct
## 3                    1      1        0      0   BB     GBR         Direct
## 4                    1      1        0      0   BB     GBR      Corporate
## 5                    2      2        0      0   BB     GBR      Online TA
##   distribution_channel is_repeated_guest previous_cancellations
## 1               Direct                 0                     0
## 2               Direct                 0                     0
## 3               Direct                 0                     0
## 4            Corporate                 0                     0
## 5                TA/TO                 0                     0
##   previous_bookings_not_canceled reserved_room_type assigned_room_type
## 1                              0                 C                 C
## 2                              0                 C                 C
## 3                              0                 A                 C
## 4                              0                 A                 A
## 5                              0                 A                 A
##   booking_changes deposit_type agent company days_in_waiting_list customer_type
## 1               3   No Deposit  NULL    NULL                    0     Transient
## 2               4   No Deposit  NULL    NULL                    0     Transient
## 3               0   No Deposit  NULL    NULL                    0     Transient
## 4               0   No Deposit   304    NULL                    0     Transient
## 5               0   No Deposit   240    NULL                    0     Transient
##   adr required_car_parking_spaces total_of_special_requests reservation_status
## 1   0                           0                         0          Check-Out
## 2   0                           0                         0          Check-Out
## 3  75                           0                         0          Check-Out
## 4  75                           0                         0          Check-Out
## 5  98                           0                         1          Check-Out
```

```
##   reservation_status_date
## 1              2015-07-01
## 2              2015-07-01
## 3              2015-07-02
## 4              2015-07-02
## 5              2015-07-03
```

```
cat(yellow("\n--- ESTRUCTURA DEL DATASET ---\n"))
```

```
##
## --- ESTRUCTURA DEL DATASET ---
```

```
str(hotel_data)
```

```
## 'data.frame':    87396 obs. of  32 variables:
##  $ hotel                         : chr  "Resort Hotel" "Resort Hotel" "Resort Hotel" "Resort Hotel" ...
##  $ is_canceled                   : int  0 0 0 0 0 0 0 1 1 1 ...
##  $ lead_time                     : int  342 737 7 13 14 0 9 85 75 23 ...
##  $ arrival_date_year             : int  2015 2015 2015 2015 2015 2015 2015 2015 2015 2015 ...
##  $ arrival_date_month            : chr  "July" "July" "July" "July" ...
##  $ arrival_date_week_number      : int  27 27 27 27 27 27 27 27 27 27 ...
##  $ arrival_date_day_of_month     : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ stays_in_weekend_nights       : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ stays_in_week_nights          : int  0 0 1 1 2 2 2 3 3 4 ...
##  $ adults                        : int  2 2 1 1 2 2 2 2 2 2 ...
##  $ children                      : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ babies                        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ meal                          : chr  "BB" "BB" "BB" "BB" ...
##  $ country                       : chr  "PRT" "PRT" "GBR" "GBR" ...
##  $ market_segment                : chr  "Direct" "Direct" "Direct" "Corporate" ...
##  $ distribution_channel          : chr  "Direct" "Direct" "Direct" "Corporate" ...
##  $ is_repeated_guest             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ previous_cancellations        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ previous_bookings_not_canceled: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ reserved_room_type            : chr  "C" "C" "A" "A" ...
##  $ assigned_room_type            : chr  "C" "C" "C" "A" ...
##  $ booking_changes               : int  3 4 0 0 0 0 0 0 0 0 ...
##  $ deposit_type                  : chr  "No Deposit" "No Deposit" "No Deposit" "No Deposit" ...
##  $ agent                         : chr  "NULL" "NULL" "NULL" "304" ...
##  $ company                       : chr  "NULL" "NULL" "NULL" "NULL" ...
##  $ days_in_waiting_list          : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ customer_type                 : chr  "Transient" "Transient" "Transient" "Transient" ...
##  $ adr                           : num  0 0 75 75 98 ...
##  $ required_car_parking_spaces   : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ total_of_special_requests     : int  0 0 0 0 1 0 1 1 0 0 ...
##  $ reservation_status            : chr  "Check-Out" "Check-Out" "Check-Out" "Check-Out" ...
##  $ reservation_status_date       : chr  "2015-07-01" "2015-07-01" "2015-07-02" "2015-07-02" ...
```

```
cat(yellow("\n--- RESUMEN ESTADÍSTICO BÁSICO (TODAS LAS COLUMNAS) ---\n"))
```

```
##
## --- RESUMEN ESTADÍSTICO BÁSICO (TODAS LAS COLUMNAS) ---
```

```
print(summary(hotel_data))
```

```
##     hotel           is_canceled       lead_time      arrival_date_year
##  Length:87396       Min.   :0.0000   Min.   :  0.00   Min.   :2015
```

```
##  Class :character   1st Qu.:0.0000   1st Qu.: 11.00   1st Qu.:2016
##  Mode  :character   Median :0.0000   Median : 49.00   Median :2016
##                     Mean   :0.2749   Mean   : 79.89   Mean   :2016
##                     3rd Qu.:1.0000   3rd Qu.:125.00   3rd Qu.:2017
##                     Max.   :1.0000   Max.   :737.00   Max.   :2017
##
##  arrival_date_month arrival_date_week_number arrival_date_day_of_month
##  Length:87396       Min.   : 1.00            Min.   : 1.00
##  Class :character   1st Qu.:16.00            1st Qu.: 8.00
##  Mode  :character   Median :27.00            Median :16.00
##                     Mean   :26.84            Mean   :15.82
##                     3rd Qu.:37.00            3rd Qu.:23.00
##                     Max.   :53.00            Max.   :31.00
##
##  stays_in_weekend_nights stays_in_week_nights     adults
##  Min.   : 0.000          Min.   : 0.000       Min.   : 0.000
##  1st Qu.: 0.000          1st Qu.: 1.000       1st Qu.: 2.000
##  Median : 1.000          Median : 2.000       Median : 2.000
##  Mean   : 1.005          Mean   : 2.625       Mean   : 1.876
##  3rd Qu.: 2.000          3rd Qu.: 4.000       3rd Qu.: 2.000
##  Max.   :19.000          Max.   :50.000       Max.   :55.000
##
##     children           babies             meal              country
##  Min.   : 0.0000   Min.   : 0.00000   Length:87396       Length:87396
##  1st Qu.: 0.0000   1st Qu.: 0.00000   Class :character   Class :character
##  Median : 0.0000   Median : 0.00000   Mode  :character   Mode  :character
##  Mean   : 0.1386   Mean   : 0.01082
##  3rd Qu.: 0.0000   3rd Qu.: 0.00000
##  Max.   :10.0000   Max.   :10.00000
##  NA's   :4
##  market_segment     distribution_channel is_repeated_guest
##  Length:87396       Length:87396         Min.   :0.00000
##  Class :character   Class :character     1st Qu.:0.00000
##  Mode  :character   Mode  :character     Median :0.00000
##                                          Mean   :0.03908
##                                          3rd Qu.:0.00000
##                                          Max.   :1.00000
##
##  previous_cancellations previous_bookings_not_canceled reserved_room_type
##  Min.   : 0.00000       Min.   : 0.000                 Length:87396
##  1st Qu.: 0.00000       1st Qu.: 0.000                 Class :character
##  Median : 0.00000       Median : 0.000                 Mode  :character
##  Mean   : 0.03041       Mean   : 0.184
##  3rd Qu.: 0.00000       3rd Qu.: 0.000
##  Max.   :26.00000       Max.   :72.000
##
##  assigned_room_type booking_changes   deposit_type          agent
##  Length:87396       Min.   : 0.0000   Length:87396       Length:87396
##  Class :character   1st Qu.: 0.0000   Class :character   Class :character
##  Mode  :character   Median : 0.0000   Mode  :character   Mode  :character
##                     Mean   : 0.2716
##                     3rd Qu.: 0.0000
##                     Max.   :21.0000
##
```

```
##    company          days_in_waiting_list customer_type           adr
##  Length:87396       Min.   :  0.0000     Length:87396       Min.   :  -6.38
##  Class :character   1st Qu.:  0.0000     Class :character   1st Qu.:  72.00
##  Mode  :character   Median :  0.0000     Mode  :character   Median :  98.10
##                     Mean   :  0.7496                        Mean   : 106.34
##                     3rd Qu.:  0.0000                        3rd Qu.: 134.00
##                     Max.   :391.0000                        Max.   :5400.00
##
##  required_car_parking_spaces total_of_special_requests reservation_status
##  Min.   :0.00000             Min.   :0.0000            Length:87396
##  1st Qu.:0.00000             1st Qu.:0.0000            Class :character
##  Median :0.00000             Median :0.0000            Mode  :character
##  Mean   :0.08423             Mean   :0.6986
##  3rd Qu.:0.00000             3rd Qu.:1.0000
##  Max.   :8.00000             Max.   :5.0000
##
##  reservation_status_date
##  Length:87396
##  Class :character
##  Mode  :character
##
##
##
##
```

```
cat(yellow("\n--- ANÁLISIS DETALLADO CON SKIMR ---\n"))
```

```
##
## --- ANÁLISIS DETALLADO CON SKIMR ---
```

```
print(skim(hotel_data))
```

```
## -- Data Summary ------------------------
##                            Values
## Name                       hotel_data
## Number of rows             87396
## Number of columns          32
## _______________________
## Column type frequency:
##   character                14
##   numeric                  18
## ________________________
## Group variables            None
##
## -- Variable type: character -------------------------------------------------------
##    skim_variable           n_missing complete_rate min max empty n_unique
##  1 hotel                           0             1  10  12     0        2
##  2 arrival_date_month              0             1   3   9     0       12
##  3 meal                            0             1   2   9     0        5
##  4 country                         0             1   2   4     0      178
##  5 market_segment                  0             1   6  13     0        8
##  6 distribution_channel            0             1   3   9     0        5
##  7 reserved_room_type              0             1   1   1     0       10
##  8 assigned_room_type              0             1   1   1     0       12
##  9 deposit_type                    0             1  10  10     0        3
```

```
## 10 agent                          0             1   1   4     0      334
## 11 company                        0             1   1   4     0      353
## 12 customer_type                  0             1   5  15     0        4
## 13 reservation_status             0             1   7   9     0        3
## 14 reservation_status_date        0             1  10  10     0      926
##    whitespace
##  1          0
##  2          0
##  3          0
##  4          0
##  5          0
##  6          0
##  7          0
##  8          0
##  9          0
## 10          0
## 11          0
## 12          0
## 13          0
## 14          0
##
## -- Variable type: numeric -------------------------------------------------------
##    skim_variable                  n_missing complete_rate      mean     sd
##  1 is_canceled                            0          1       0.275   0.446
##  2 lead_time                              0          1      79.9    86.1
##  3 arrival_date_year                      0          1    2016.      0.686
##  4 arrival_date_week_number               0          1      26.8    13.7
##  5 arrival_date_day_of_month              0          1      15.8     8.84
##  6 stays_in_weekend_nights                0          1       1.01    1.03
##  7 stays_in_week_nights                   0          1       2.63    2.05
##  8 adults                                 0          1       1.88    0.627
##  9 children                               4          1.00    0.139   0.456
## 10 babies                                 0          1       0.0108  0.114
## 11 is_repeated_guest                      0          1       0.0391  0.194
## 12 previous_cancellations                 0          1       0.0304  0.369
## 13 previous_bookings_not_canceled         0          1       0.184   1.73
## 14 booking_changes                        0          1       0.272   0.727
## 15 days_in_waiting_list                   0          1       0.750  10.0
## 16 adr                                    0          1     106.     55.0
## 17 required_car_parking_spaces            0          1       0.0842  0.282
## 18 total_of_special_requests              0          1       0.699   0.832
##         p0  p25    p50  p75 p100 hist
##  1    0       0    0      1    1
##  2    0      11   49    125  737
##  3 2015    2016 2016   2017 2017
##  4    1      16   27     37   53
##  5    1       8   16     23   31
##  6    0       0    1      2   19
##  7    0       1    2      4   50
##  8    0       2    2      2   55
##  9    0       0    0      0   10
## 10    0       0    0      0   10
## 11    0       0    0      0    1
## 12    0       0    0      0   26
```

```
## 13    0       0    0      0   72
## 14    0       0    0      0   21
## 15    0       0    0      0  391
## 16   -6.38   72   98.1  134 5400
## 17    0       0    0      0    8
## 18    0       0    0      1    5
```

```
CSV_limpio <- file.path(data_dir, "hotel_bookings_limpio.csv")
CSV_final <- file.path(data_dir, "hotel_bookings_final.csv")

cat(green("\nRutas para guardar datasets procesados:"), "\n")
```

```
##
## Rutas para guardar datasets procesados:
```

```
cat("Dataset limpio:", CSV_limpio, "\n")
```

```
## Dataset limpio: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings_limpio.csv
```

```
cat("Dataset final (si es necesario):", CSV_final, "\n")
```

```
## Dataset final (si es necesario): D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings_final.csv
```

```
#####################################################
# PARTE 02: ANÁLISIS DE DATOS FALTANTES Y ATÍPICOS
#####################################################

#-----------------------------------------
# 2.1. ANÁLISIS DE DATOS FALTANTES (NA)
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS DE DATOS FALTANTES ---\n"))
```

```
##
## --- ANÁLISIS DE DATOS FALTANTES ---
```

```
# Conteo de NA por columna
na_count <- colSums(is.na(hotel_data))
na_percentage <- round(na_count / nrow(hotel_data) * 100, 2)

na_summary <- data.frame(
  Variable = names(na_count),
  NA_Count = na_count,
  NA_Percentage = na_percentage
)

# Ordenar por cantidad de NA (descendente)
na_summary <- na_summary[order(-na_summary$NA_Count), ]

# Mostrar resumen de valores NA
print(na_summary)
```

```
##                                                 Variable NA_Count
## children                                        children        4
## hotel                                              hotel        0
## is_canceled                                  is_canceled        0
## lead_time                                      lead_time        0
## arrival_date_year                        arrival_date_year        0
## arrival_date_month                      arrival_date_month        0
```

```
## arrival_date_week_number             arrival_date_week_number        0
## arrival_date_day_of_month           arrival_date_day_of_month        0
## stays_in_weekend_nights               stays_in_weekend_nights        0
## stays_in_week_nights                     stays_in_week_nights        0
## adults                                                 adults        0
## babies                                                 babies        0
## meal                                                     meal        0
## country                                               country        0
## market_segment                                 market_segment        0
## distribution_channel                     distribution_channel        0
## is_repeated_guest                           is_repeated_guest        0
## previous_cancellations                 previous_cancellations        0
## previous_bookings_not_canceled previous_bookings_not_canceled        0
## reserved_room_type                         reserved_room_type        0
## assigned_room_type                         assigned_room_type        0
## booking_changes                               booking_changes        0
## deposit_type                                     deposit_type        0
## agent                                                   agent        0
## company                                               company        0
## days_in_waiting_list                   days_in_waiting_list        0
## customer_type                                 customer_type        0
## adr                                                     adr        0
## required_car_parking_spaces       required_car_parking_spaces        0
## total_of_special_requests           total_of_special_requests        0
## reservation_status                         reservation_status        0
## reservation_status_date               reservation_status_date        0
##                                NA_Percentage
## children                                   0
## hotel                                      0
## is_canceled                                0
## lead_time                                  0
## arrival_date_year                          0
## arrival_date_month                         0
## arrival_date_week_number                   0
## arrival_date_day_of_month                  0
## stays_in_weekend_nights                    0
## stays_in_week_nights                       0
## adults                                     0
## babies                                     0
## meal                                       0
## country                                    0
## market_segment                             0
## distribution_channel                       0
## is_repeated_guest                          0
## previous_cancellations                     0
## previous_bookings_not_canceled             0
## reserved_room_type                         0
## assigned_room_type                         0
## booking_changes                            0
## deposit_type                               0
## agent                                      0
## company                                    0
## days_in_waiting_list                       0
## customer_type                              0
```

```
## adr                                  0
## required_car_parking_spaces          0
## total_of_special_requests            0
## reservation_status                   0
## reservation_status_date              0
```

```
# Visualización de NA - usando una muestra representativa
set.seed(123) # Para reproducibilidad
muestra_datos <- hotel_data %>%
  slice_sample(n = 5000) # Tomar una muestra de 5000 registros

cat(yellow("\nVisualización de datos faltantes (muestra de 5000 registros):"))
```

```
##
## Visualización de datos faltantes (muestra de 5000 registros):
```

```
print(vis_miss(muestra_datos))
```

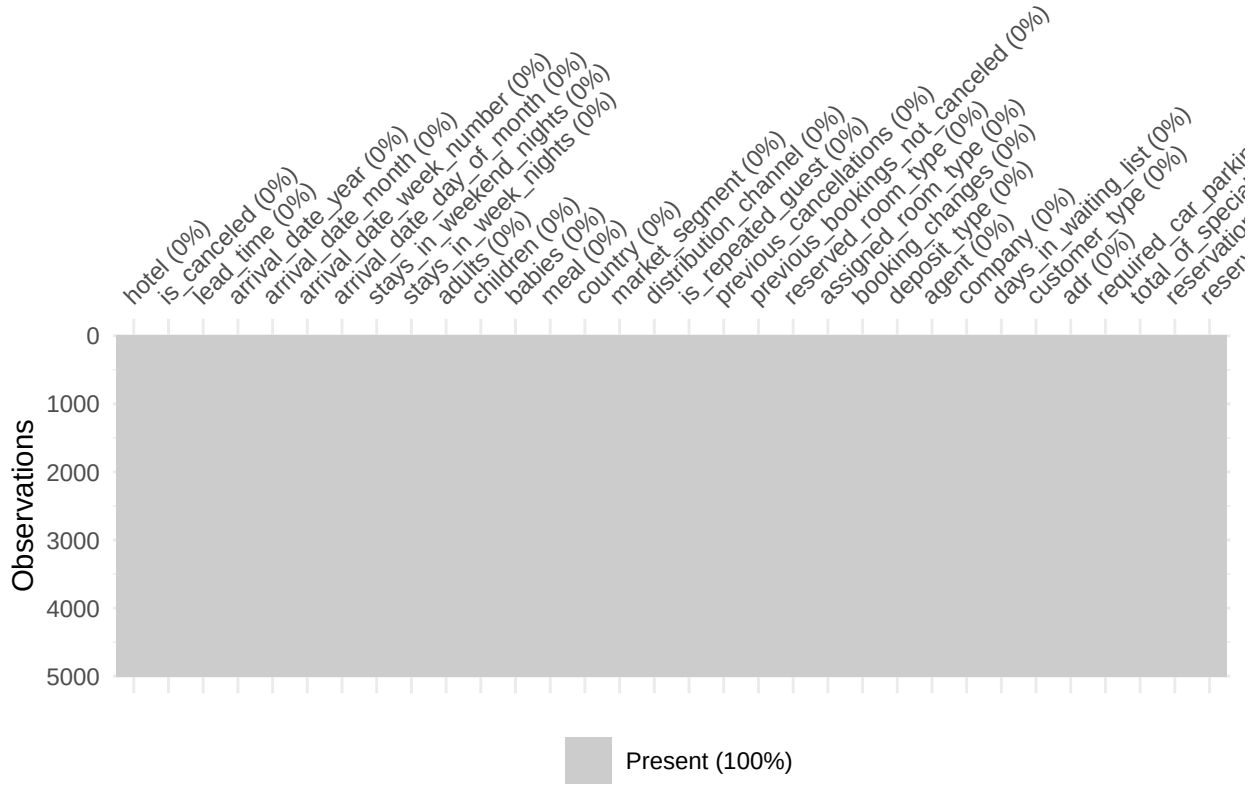


```
# Análisis específico para variable 'children' (la única con NA)
cat(yellow("\nAnálisis específico para la variable 'children':"))
```

```
##
## Análisis específico para la variable 'children':
```

```
cat("\nDistribución de valores no-NA en 'children':\n")
```

```
##
## Distribución de valores no-NA en 'children':
```

```r
print(table(hotel_data$children, useNA = "ifany"))
```

```
##
##     0     1     2     3    10  <NA>
## 79028  4695  3593    75     1     4
```

```r
#----------------------------------------
# 2.2. ANÁLISIS DE VALORES ATÍPICOS (OUTLIERS)
#----------------------------------------
cat(yellow("\n--- ANÁLISIS DE VALORES ATÍPICOS ---\n"))
```

```
##
## --- ANÁLISIS DE VALORES ATÍPICOS ---
```

```r
# Análisis estadístico de outliers usando el método IQR para variables clave
cat(yellow("\nAnálisis estadístico de outliers en variables clave:\n"))
```

```
##
## Análisis estadístico de outliers en variables clave:
```

```r
outlier_stats <- function(data, var_name) {
  var <- data[[var_name]]
  var <- var[!is.na(var)]

  Q1 <- quantile(var, 0.25)
  Q3 <- quantile(var, 0.75)
  IQR <- Q3 - Q1

  lower_bound <- Q1 - 1.5 * IQR
  upper_bound <- Q3 + 1.5 * IQR

  outliers <- sum(var < lower_bound | var > upper_bound)
  outlier_percent <- round(outliers / length(var) * 100, 2)

  return(data.frame(
    Variable = var_name,
    Q1 = Q1,
    Q3 = Q3,
    IQR = IQR,
    Lower_Bound = lower_bound,
    Upper_Bound = upper_bound,
    Outlier_Count = outliers,
    Outlier_Percentage = outlier_percent
  ))
}

# Variables numéricas que pueden tener outliers
numeric_vars <- c(
  "lead_time", "stays_in_weekend_nights", "stays_in_week_nights",
  "adults", "children", "babies", "previous_cancellations",
  "previous_bookings_not_canceled", "booking_changes",
  "days_in_waiting_list", "adr", "required_car_parking_spaces",
  "total_of_special_requests"
)

outlier_summary <- do.call(rbind, lapply(numeric_vars, function(var) {
```

```
  outlier_stats(hotel_data, var)
}))

print(outlier_summary)
```

```
##                              Variable Q1  Q3 IQR Lower_Bound Upper_Bound
## 25%                         lead_time 11 125 114      -160.0       296.0
## 25%1         stays_in_weekend_nights  0   2   2        -3.0         5.0
## 25%2            stays_in_week_nights  1   4   3        -3.5         8.5
## 25%3                          adults  2   2   0         2.0         2.0
## 25%4                        children  0   0   0         0.0         0.0
## 25%5                          babies  0   0   0         0.0         0.0
## 25%6          previous_cancellations  0   0   0         0.0         0.0
## 25%7  previous_bookings_not_canceled  0   0   0         0.0         0.0
## 25%8                booking_changes  0   0   0         0.0         0.0
## 25%9            days_in_waiting_list  0   0   0         0.0         0.0
## 25%10                            adr 72 134  62       -21.0       227.0
## 25%11    required_car_parking_spaces  0   0   0         0.0         0.0
## 25%12      total_of_special_requests  0   1   1        -1.5         2.5
##       Outlier_Count Outlier_Percentage
## 25%            2396               2.74
## 25%1            220               0.25
## 25%2           1531               1.75
## 25%3          22899              26.20
## 25%4           8364               9.57
## 25%5            914               1.05
## 25%6           1685               1.93
## 25%7           3545               4.06
## 25%8          15902              18.20
## 25%9            860               0.98
## 25%10          2490               2.85
## 25%11          7313               8.37
## 25%12          2673               3.06
```

```
# Valores extremos específicos para variables de interés
cat(yellow("\nValores extremos en variables clave:\n"))
```

```
##
## Valores extremos en variables clave:
```

```
mostrar_extremos <- function(data, var_name, n = 5) {
  cat("\nVariable:", var_name, "\n")
  sorted_values <- sort(data[[var_name]], decreasing = TRUE)
  cat("Top", n, "valores más altos:", head(sorted_values, n), "\n")

  if (min(data[[var_name]], na.rm = TRUE) < 0) {
    cat("Valores negativos:", sort(data[[var_name]][data[[var_name]] < 0]), "\n")
  }
}

# Variables de particular interés
variables_interes <- c("lead_time", "adults", "adr", "stays_in_week_nights", "stays_in_weekend_nights")

for (var in variables_interes) {
  mostrar_extremos(hotel_data, var)
```

```
}
```

```
##
## Variable: lead_time
## Top 5 valores más altos: 737 709 629 629 626
##
## Variable: adults
## Top 5 valores más altos: 55 50 40 27 27
##
## Variable: adr
## Top 5 valores más altos: 5400 510 508 451.5 450
## Valores negativos: -6.38
##
## Variable: stays_in_week_nights
## Top 5 valores más altos: 50 42 41 40 40
##
## Variable: stays_in_weekend_nights
## Top 5 valores más altos: 19 18 16 16 16
```

```
# Crear histogramas individuales para variables clave
cat(yellow("\nHistogramas para variables clave:"))
```

```
##
## Histogramas para variables clave:
```

```
crear_histogramas_mejorados <- function(data, variables) {
  for (var in variables) {
    # Para variables con valores extremos, usar zoom
    if(var == "lead_time") {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal() +
        xlim(0, 400)  # Zoom para ver mejor la distribución principal
    } else if(var == "adults") {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal() +
        xlim(0, 5)  # Enfocarse en valores razonables
    } else if(var == "adr") {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal() +
        xlim(0, 500)  # Enfocarse en el rango principal
    } else {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal()
    }
    print(p)
  }
}
```

```r
cat("\nCreando histogramas mejorados para variables clave...\n")
```

```
##
## Creando histogramas mejorados para variables clave...
```

```r
crear_histogramas_mejorados(hotel_data, variables_interes)
```

```
## Warning: Removed 342 rows containing non-finite outside the scale range
## (`stat_bin()`).
```

```
## Warning: Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

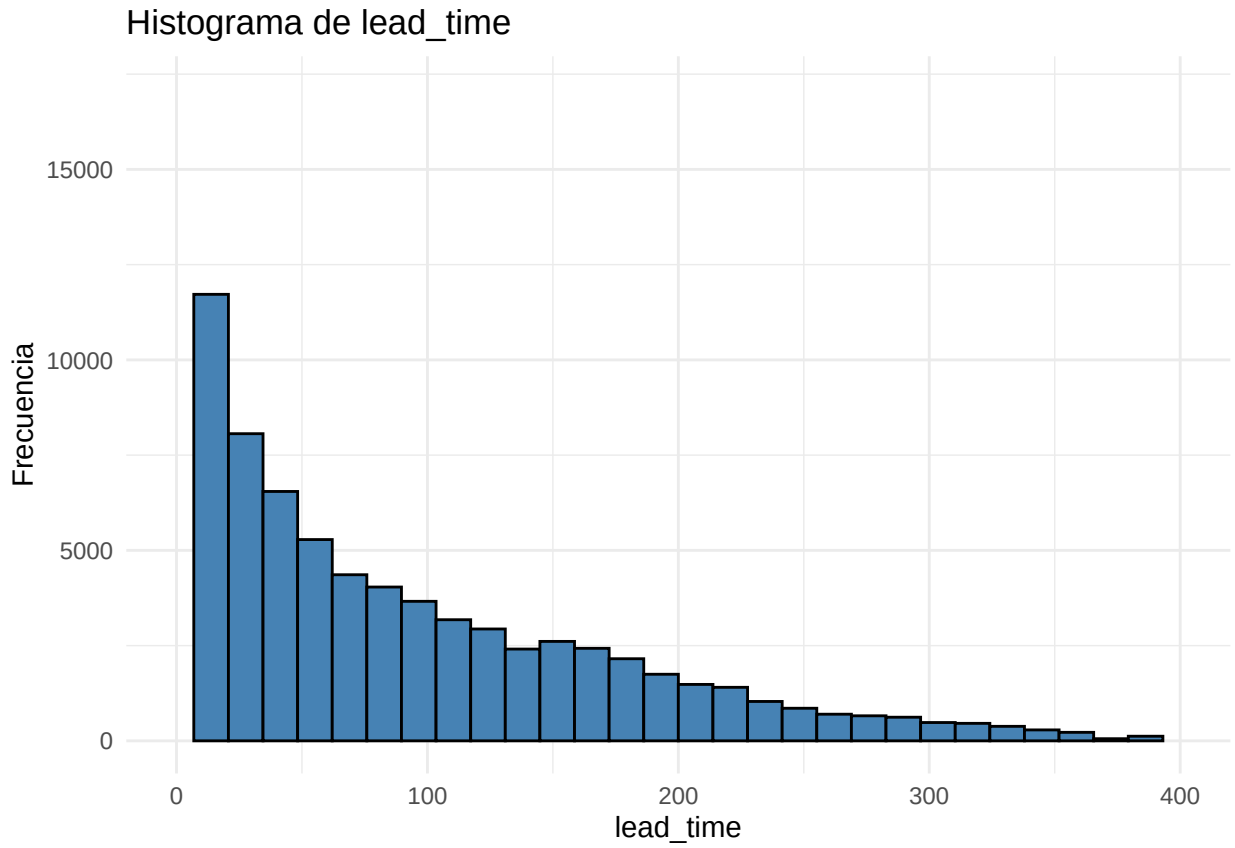


```
## Warning: Removed 14 rows containing non-finite outside the scale range (`stat_bin()`).
## Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

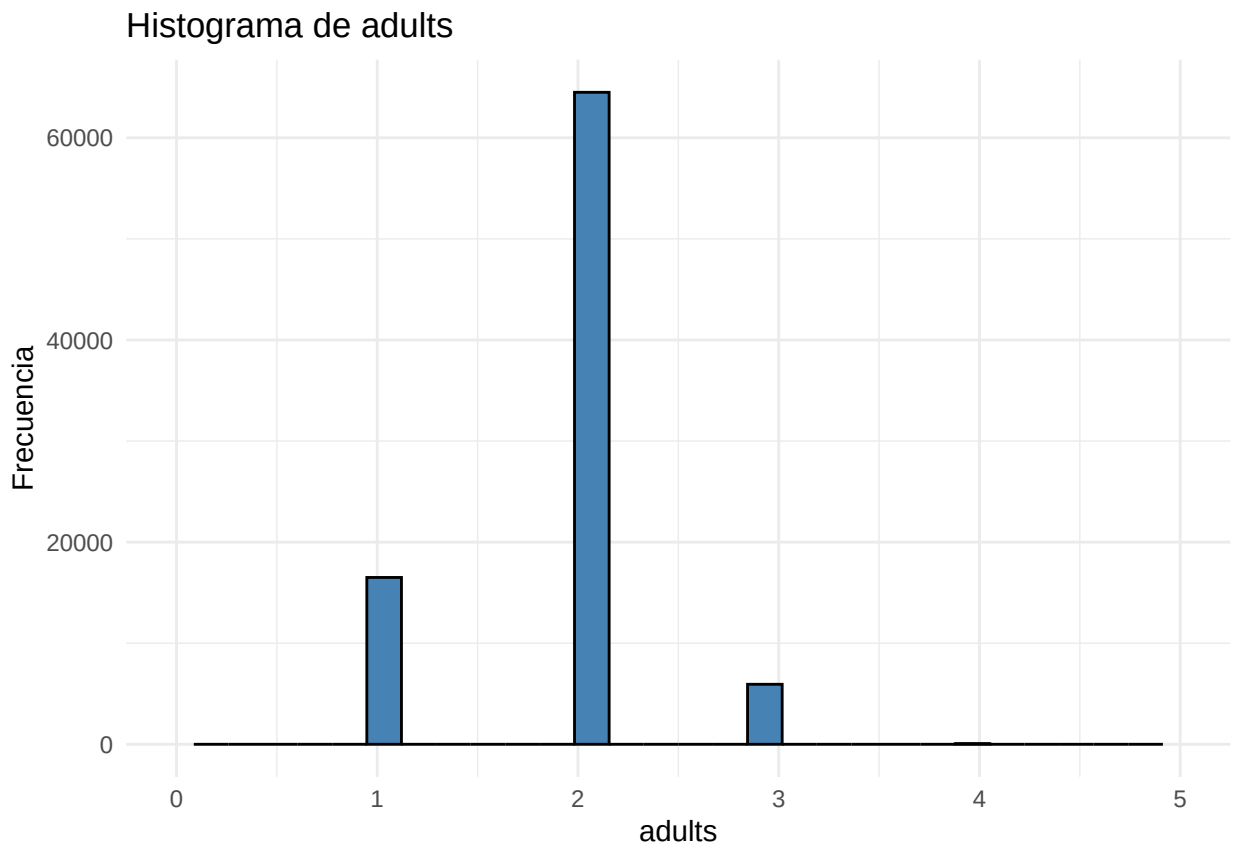


```
## Warning: Removed 4 rows containing non-finite outside the scale range (`stat_bin()`).
## Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

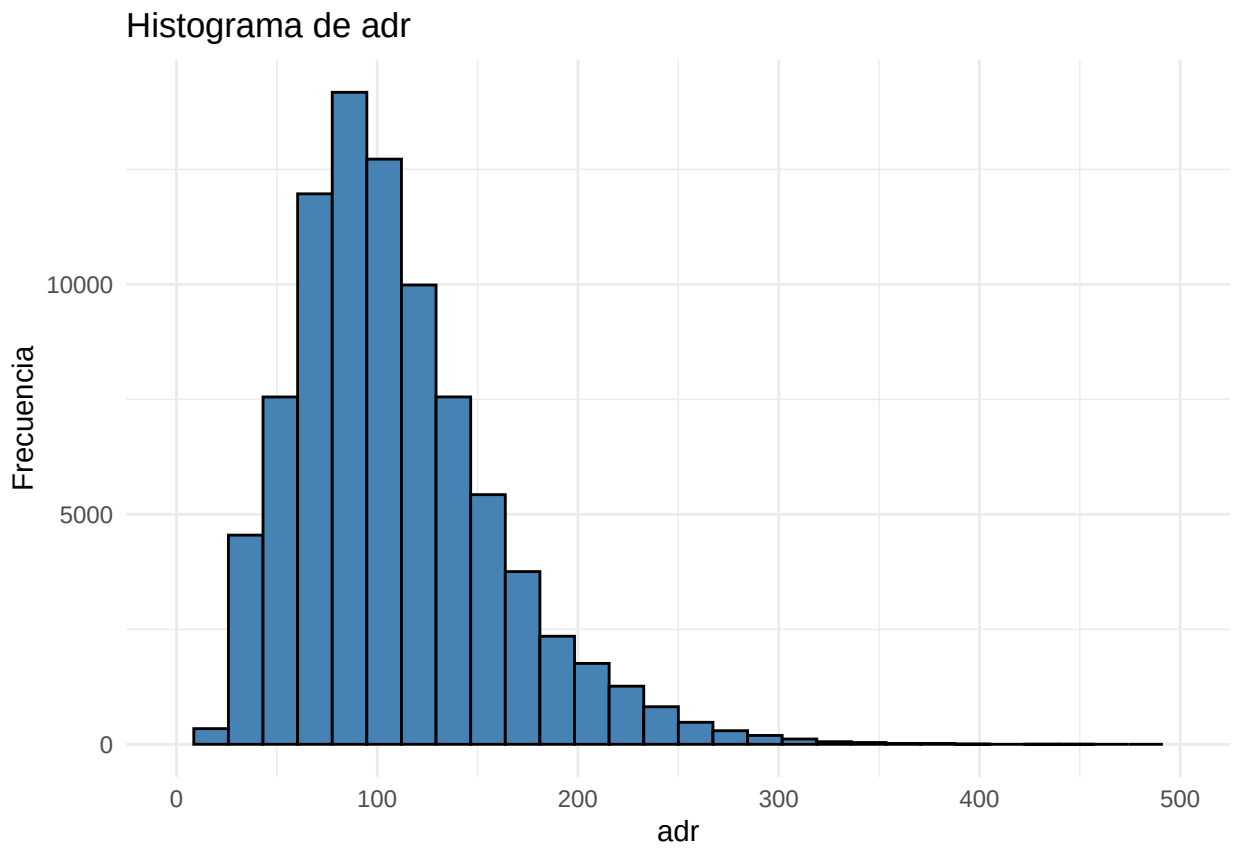
Histograma de adr
Frecuencia
10000
5000
0
0
100
200
300
400
500
adr

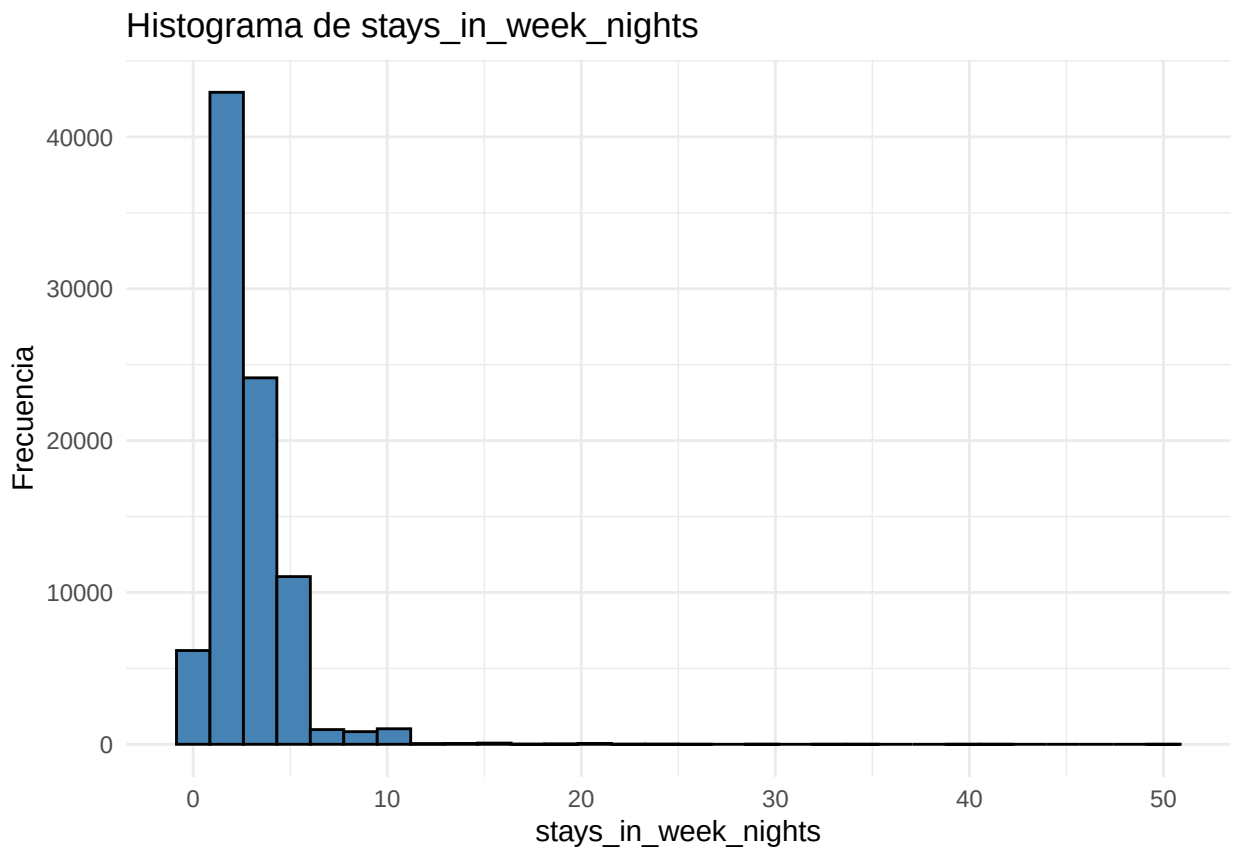
Histograma de stays_in_week_nights
Frecuencia
40000
30000
20000
10000
0
0
10
20
30
40
50
stays_in_week_nights

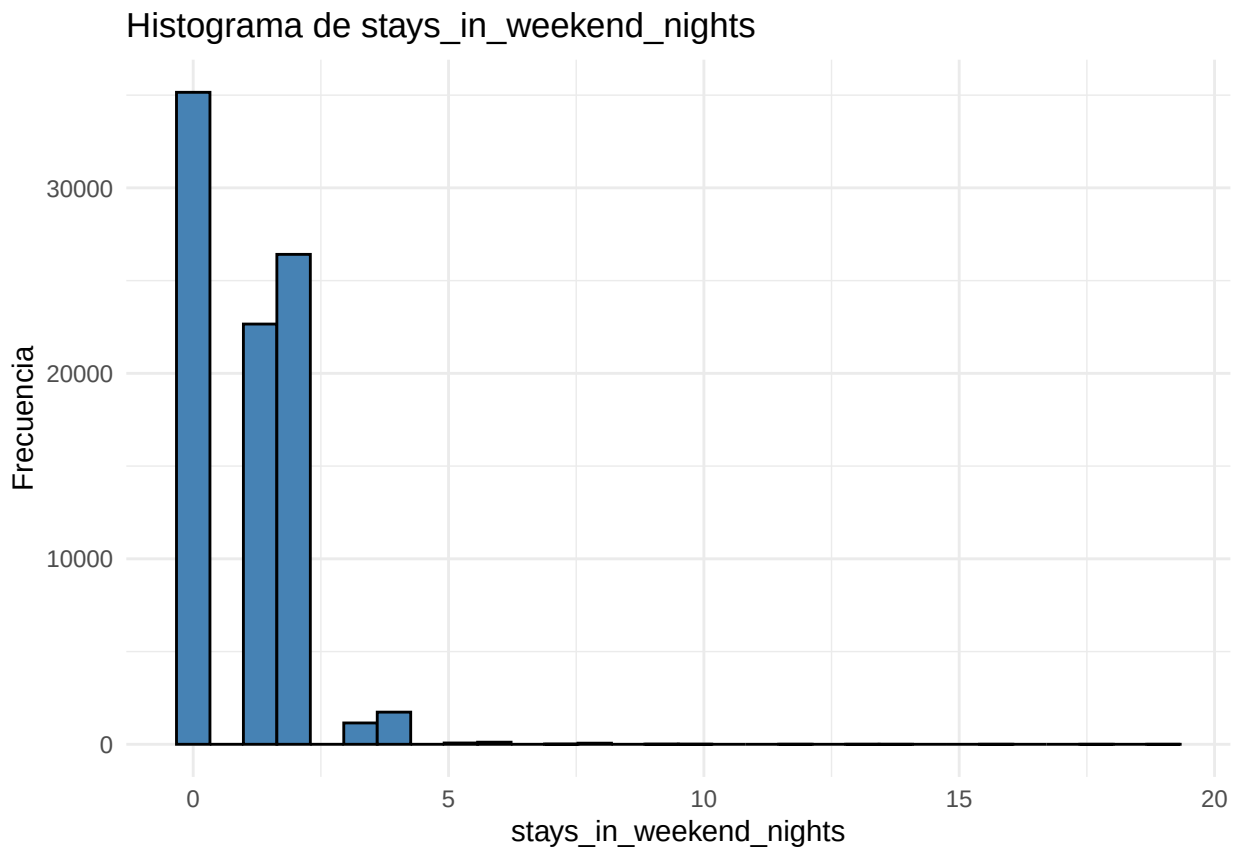


```
#-----------------------------------------
# 2.3. VERIFICACIÓN DE CONSISTENCIA LÓGICA
#-----------------------------------------
cat(yellow("\n--- VERIFICACIÓN DE CONSISTENCIA LÓGICA ---\n"))
```

```
##
## --- VERIFICACIÓN DE CONSISTENCIA LÓGICA ---
```

```
# Verificar reservas sin adultos
reservas_sin_adultos <- sum(hotel_data$adults == 0)
cat("Reservas sin adultos:", reservas_sin_adultos, "\n")
```

```
## Reservas sin adultos: 385
```

```
# Verificar total de noches = 0
reservas_sin_noches <- sum(hotel_data$stays_in_weekend_nights == 0 & hotel_data$stays_in_week_nights ==
cat("Reservas sin noches (0 días de estadía):", reservas_sin_noches, "\n")
```

```
## Reservas sin noches (0 días de estadía): 651
```

```
# Verificar consistencia entre estado de reserva y cancelación
inconsistencia_cancelacion <- sum(hotel_data$is_canceled == 1 & hotel_data$reservation_status == "Check
cat("Inconsistencias entre cancelación y estado (canceladas pero con check-out):", inconsistencia_cancel
```

```
## Inconsistencias entre cancelación y estado (canceladas pero con check-out): 0
```

```
# Verificar valores atípicos en número de adultos
cat("\nPosibles errores en 'adults':")
```

```
##
```

```
## Posibles errores en 'adults':
```

```
adultos_tabla <- table(hotel_data$adults)
print(adultos_tabla)
```

```
##
##     0     1     2     3     4     5     6    10    20    26    27    40    50
##   385 16503 64497  5935    60     2     1     1     2     5     2     1     1
##    55
##     1
```

```
#-----------------------------------------
# 2.4. DEFINIR ESTRATEGIAS PARA DATOS FALTANTES Y ATÍPICOS
#-----------------------------------------
cat(yellow("\n--- ESTRATEGIAS PROPUESTAS ---\n"))
```

```
##
## --- ESTRATEGIAS PROPUESTAS ---
```

```
cat("1. Estrategia para datos faltantes:\n")
```

```
## 1. Estrategia para datos faltantes:
```

```
cat("   - Para 'children': Imputar con la moda (0) ya que la mayoría de reservas no tienen niños\n")
```

```
##    - Para 'children': Imputar con la moda (0) ya que la mayoría de reservas no tienen niños
```

```
cat("\n2. Estrategia para outliers:\n")
```

```
##
## 2. Estrategia para outliers:
```

```
cat("   - lead_time: Mantener valores hasta 365 días (1 año), recortar valores superiores\n")
```

```
##    - lead_time: Mantener valores hasta 365 días (1 año), recortar valores superiores
```

```
cat("   - adults: Valores superiores a 4 parecen errores, considerar recortar a un máximo razonable\n")
```

```
##    - adults: Valores superiores a 4 parecen errores, considerar recortar a un máximo razonable
```

```
cat("   - stays_in_weekend_nights y stays_in_week_nights: Establecer límites razonables (ej. máximo 14 d
```

```
##    - stays_in_weekend_nights y stays_in_week_nights: Establecer límites razonables (ej. máximo 14 día
```

```
cat("   - adr: Eliminar valores negativos y recortar valores extremadamente altos (ej. > 1000)\n")
```

```
##    - adr: Eliminar valores negativos y recortar valores extremadamente altos (ej. > 1000)
```

```
#########################################################
# PARTE 03: PREPROCESAMIENTO DE DATOS
#########################################################

# Crear una copia para no modificar los datos originales
hotel_data_limpio <- hotel_data

#-----------------------------------------
# 3.1. TRATAMIENTO DE DATOS FALTANTES
#-----------------------------------------
cat(yellow("\n--- TRATAMIENTO DE DATOS FALTANTES ---\n"))
```

```
##
```

```
## --- TRATAMIENTO DE DATOS FALTANTES ---
```

```
# Imputar los NA en 'children' con la moda (0)
hotel_data_limpio$children[is.na(hotel_data_limpio$children)] <- 0
cat("Valores NA en 'children' después de imputación:", sum(is.na(hotel_data_limpio$children)), "\n")
```

```
## Valores NA en 'children' después de imputación: 0
```

```
#----------------------------------------
# 3.2. TRATAMIENTO DE VALORES ATÍPICOS (OUTLIERS)
#----------------------------------------
cat(yellow("\n--- TRATAMIENTO DE VALORES ATÍPICOS ---\n"))
```

```
##
## --- TRATAMIENTO DE VALORES ATÍPICOS ---
```

```
# Función para aplicar winsorización en una variable
winsorizar <- function(x, lower_limit, upper_limit) {
  x[x < lower_limit] <- lower_limit
  x[x > upper_limit] <- upper_limit
  return(x)
}

# 3.2.1. Winsorizar lead_time (tiempo de anticipación)
cat("\nTratamiento de 'lead_time':")
```

```
##
## Tratamiento de 'lead_time':
```

```
cat("\n  Antes - Max:", max(hotel_data_limpio$lead_time), "Min:", min(hotel_data_limpio$lead_time))
```

```
##
##   Antes - Max: 737 Min: 0
```

```
hotel_data_limpio$lead_time <- winsorizar(hotel_data_limpio$lead_time, 0, 365)
cat("\n  Después - Max:", max(hotel_data_limpio$lead_time), "Min:", min(hotel_data_limpio$lead_time), "
```

```
##
##   Después - Max: 365 Min: 0
```

```
# 3.2.2. Corregir adults (adultos)
cat("\nTratamiento de 'adults':")
```

```
##
## Tratamiento de 'adults':
```

```
cat("\n  Antes - Max:", max(hotel_data_limpio$adults), "Min:", min(hotel_data_limpio$adults))
```

```
##
##   Antes - Max: 55 Min: 0
```

```
# Reemplazar valores 0 con 1 (no tiene sentido una reserva sin adultos)
hotel_data_limpio$adults[hotel_data_limpio$adults == 0] <- 1
# Winsorizar a un máximo de 4 adultos por habitación
hotel_data_limpio$adults <- winsorizar(hotel_data_limpio$adults, 1, 4)
cat("\n  Después - Max:", max(hotel_data_limpio$adults), "Min:", min(hotel_data_limpio$adults), "\n")
```

```
##
##   Después - Max: 4 Min: 1
```

```r
# 3.2.3. Winsorizar stays_in_weekend_nights y stays_in_week_nights
cat("\nTratamiento de 'stays_in_weekend_nights':")
```

```
##
## Tratamiento de 'stays_in_weekend_nights':
```

```r
cat("\n  Antes - Max:", max(hotel_data_limpio$stays_in_weekend_nights))
```

```
##
##   Antes - Max: 19
```

```r
hotel_data_limpio$stays_in_weekend_nights <- winsorizar(hotel_data_limpio$stays_in_weekend_nights, 0, 14)
cat("\n  Después - Max:", max(hotel_data_limpio$stays_in_weekend_nights), "\n")
```

```
##
##   Después - Max: 14
```

```r
cat("\nTratamiento de 'stays_in_week_nights':")
```

```
##
## Tratamiento de 'stays_in_week_nights':
```

```r
cat("\n  Antes - Max:", max(hotel_data_limpio$stays_in_week_nights))
```

```
##
##   Antes - Max: 50
```

```r
hotel_data_limpio$stays_in_week_nights <- winsorizar(hotel_data_limpio$stays_in_week_nights, 0, 14)
cat("\n  Después - Max:", max(hotel_data_limpio$stays_in_week_nights), "\n")
```

```
##
##   Después - Max: 14
```

```r
# 3.2.4. Tratar adr (tarifa diaria promedio)
cat("\nTratamiento de 'adr':")
```

```
##
## Tratamiento de 'adr':
```

```r
cat("\n  Antes - Max:", max(hotel_data_limpio$adr), "Min:", min(hotel_data_limpio$adr))
```

```
##
##   Antes - Max: 5400 Min: -6.38
```

```r
# Reemplazar valores negativos con 0
hotel_data_limpio$adr[hotel_data_limpio$adr < 0] <- 0
# Winsorizar valores extremadamente altos
hotel_data_limpio$adr <- winsorizar(hotel_data_limpio$adr, 0, 1000)
cat("\n  Después - Max:", max(hotel_data_limpio$adr), "Min:", min(hotel_data_limpio$adr), "\n")
```

```
##
##   Después - Max: 1000 Min: 0
```

```r
# 3.2.5. Winsorizar otros valores numéricos
cat("\nTratamiento de 'children':")
```

```
##
## Tratamiento de 'children':
```

```r
hotel_data_limpio$children <- winsorizar(hotel_data_limpio$children, 0, 3)
cat("\n  Después - Max:", max(hotel_data_limpio$children), "\n")
```

```
##
##   Después - Max: 3
```

```
cat("\nTratamiento de 'babies':")
```

```
##
## Tratamiento de 'babies':
```

```
hotel_data_limpio$babies <- winsorizar(hotel_data_limpio$babies, 0, 2)
cat("\n  Después - Max:", max(hotel_data_limpio$babies), "\n")
```

```
##
##   Después - Max: 2
```

```
#-----------------------------------------
# 3.3. TRATAMIENTO DE INCONSISTENCIAS LÓGICAS
#-----------------------------------------
cat(yellow("\n--- TRATAMIENTO DE INCONSISTENCIAS LÓGICAS ---\n"))
```

```
##
## --- TRATAMIENTO DE INCONSISTENCIAS LÓGICAS ---
```

```
# Identificar reservas sin noches (estancia de 0 días)
reservas_sin_noches <- hotel_data_limpio$stays_in_weekend_nights == 0 &
  hotel_data_limpio$stays_in_week_nights == 0

cat("Reservas con estancia de 0 días:", sum(reservas_sin_noches), "\n")
```

```
## Reservas con estancia de 0 días: 651
```

```
# Como no tiene sentido una reserva sin estadía, establecemos al menos 1 noche
hotel_data_limpio$stays_in_week_nights[reservas_sin_noches] <- 1
cat("Reservas con estancia de 0 días después de corrección:",
    sum(hotel_data_limpio$stays_in_weekend_nights == 0 &
          hotel_data_limpio$stays_in_week_nights == 0), "\n")
```

```
## Reservas con estancia de 0 días después de corrección: 0
```

```
#-----------------------------------------
# 4. VERIFICACIÓN DE LIMPIEZA
#-----------------------------------------
cat(yellow("\n--- VERIFICACIÓN DE LIMPIEZA ---\n"))
```

```
##
## --- VERIFICACIÓN DE LIMPIEZA ---
```

```
# Verificar NA después de limpieza
na_count_limpio <- colSums(is.na(hotel_data_limpio))
cat("\nCantidad de NA después de limpieza:", sum(na_count_limpio), "\n")
```

```
##
## Cantidad de NA después de limpieza: 0
```

```
# Verificar outliers después de limpieza
outlier_summary_limpio <- do.call(rbind, lapply(numeric_vars, function(var) {
  outlier_stats(hotel_data_limpio, var)
}))

cat("\nResumen de outliers después de limpieza:\n")
```

```
##
## Resumen de outliers después de limpieza:
```

```
print(outlier_summary_limpio)
```

```
##                              Variable Q1  Q3 IQR Lower_Bound Upper_Bound
## 25%                         lead_time 11 125 114      -160.0       296.0
## 25%1         stays_in_weekend_nights  0   2   2        -3.0         5.0
## 25%2            stays_in_week_nights  1   4   3        -3.5         8.5
## 25%3                          adults  2   2   0         2.0         2.0
## 25%4                        children  0   0   0         0.0         0.0
## 25%5                          babies  0   0   0         0.0         0.0
## 25%6          previous_cancellations  0   0   0         0.0         0.0
## 25%7  previous_bookings_not_canceled  0   0   0         0.0         0.0
## 25%8                 booking_changes  0   0   0         0.0         0.0
## 25%9            days_in_waiting_list  0   0   0         0.0         0.0
## 25%10                            adr 72 134  62       -21.0       227.0
## 25%11    required_car_parking_spaces  0   0   0         0.0         0.0
## 25%12      total_of_special_requests  0   1   1        -1.5         2.5
##       Outlier_Count Outlier_Percentage
## 25%            2396               2.74
## 25%1            220               0.25
## 25%2           1531               1.75
## 25%3          22899              26.20
## 25%4           8364               9.57
## 25%5            914               1.05
## 25%6           1685               1.93
## 25%7           3545               4.06
## 25%8          15902              18.20
## 25%9            860               0.98
## 25%10          2490               2.85
## 25%11          7313               8.37
## 25%12          2673               3.06
```

```
#----------------------------------------
# 4.5 GUARDAR GRÁFICAS COMO JPG EN DATA FOLDER
#----------------------------------------
cat(yellow("\n--- GUARDANDO GRÁFICAS EN FORMATO JPG ---\n"))
```

```
##
## --- GUARDANDO GRÁFICAS EN FORMATO JPG ---
```

```
graphics_dir <- file.path(data_dir, "graficas")
if (!dir.exists(graphics_dir)) {
  dir.create(graphics_dir)
  cat("Creado directorio para gráficas:", graphics_dir, "\n")
} else {
  cat("Usando directorio existente para gráficas:", graphics_dir, "\n")
}
```

```
## Usando directorio existente para gráficas: D:/@aleec02/CC216-TP-2025-1/data/graficas
```

```
graphics_clean_dir <- file.path(graphics_dir, "limpios")
if (!dir.exists(graphics_clean_dir)) {
  dir.create(graphics_clean_dir)
  cat("Creado directorio para gráficas de datos limpios:", graphics_clean_dir, "\n")
} else {
```

```
  cat("Usando directorio existente para gráficas limpias:", graphics_clean_dir, "\n")
}
```

```
## Usando directorio existente para gráficas limpias: D:/@aleec02/CC216-TP-2025-1/data/graficas/limpios
```

```
crear_y_guardar_histogramas <- function(data, variables, directorio) {
  graficas_guardadas <- c()

  for (var in variables) {
    # Nombre del archivo para guardar
    filename <- file.path(directorio, paste0("histograma_", var, ".jpg"))

    if(var == "lead_time") {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal() +
        xlim(0, 400)  # Zoom para ver mejor la distribución principal
    } else if(var == "adults") {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal() +
        xlim(0, 5)  # Enfocarse en valores razonables
    } else if(var == "adr") {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal() +
        xlim(0, 500)  # Enfocarse en el rango principal
    } else {
      p <- ggplot(data, aes(x = .data[[var]])) +
        geom_histogram(bins = 30, fill = "steelblue", color = "black") +
        labs(title = paste("Histograma de", var), x = var, y = "Frecuencia") +
        theme_minimal()
    }

    # Guardar el gráfico como JPG
    ggsave(filename = filename, plot = p, width = 8, height = 6, dpi = 300)
    graficas_guardadas <- c(graficas_guardadas, filename)
    cat(" - Guardado:", filename, "\n")
  }

  return(graficas_guardadas)
}

cat("\nGuardando histogramas para datos originales...\n")
```

```
##
## Guardando histogramas para datos originales...
```

```
histogramas_originales <- crear_y_guardar_histogramas(
  hotel_data,
  variables_interes,
  graphics_dir
```

```
)
```

```
## Warning: Removed 342 rows containing non-finite outside the scale range (`stat_bin()`).
## Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/histograma_lead_time.jpg
```

```
## Warning: Removed 14 rows containing non-finite outside the scale range (`stat_bin()`).
## Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/histograma_adults.jpg
```

```
## Warning: Removed 4 rows containing non-finite outside the scale range (`stat_bin()`).
## Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/histograma_adr.jpg
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/histograma_stays_in_week_nights.jpg
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/histograma_stays_in_weekend_nights.jpg
```

```
cat("\nGuardando histogramas para datos limpios...\n")
```

```
##
## Guardando histogramas para datos limpios...
```

```
histogramas_limpios <- crear_y_guardar_histogramas(
  hotel_data_limpio,
  variables_interes,
  graphics_clean_dir
)
```

```
## Warning: Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/limpios/histograma_lead_time.jpg
```

```
## Warning: Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/limpios/histograma_adults.jpg
```

```
## Warning: Removed 3 rows containing non-finite outside the scale range (`stat_bin()`).
## Removed 2 rows containing missing values or values outside the scale range
## (`geom_bar()`).
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/limpios/histograma_adr.jpg
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/limpios/histograma_stays_in_week_nights.jpg
```

```
##  - Guardado: D:/@aleec02/CC216-TP-2025-1/data/graficas/limpios/histograma_stays_in_weekend_nights.jpg
```

```
cat("\nTotal de archivos guardados:",
    length(c(histogramas_originales, histogramas_limpios)), "\n")
```

```
##
## Total de archivos guardados: 10
```

```
#----------------------------------------
# PARTE 05: GUARDAR DATASET LIMPIO Y COMPARAR DIMENSIONES
```

```r
#----------------------------------------
cat(yellow("\n--- GUARDANDO DATASET LIMPIO Y COMPARANDO DIMENSIONES ---\n"))
```

```
##
## --- GUARDANDO DATASET LIMPIO Y COMPARANDO DIMENSIONES ---
```

```r
write.csv(hotel_data_limpio, CSV_limpio, row.names = FALSE)
cat("Dataset limpio guardado en:", CSV_limpio, "\n")
```

```
## Dataset limpio guardado en: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings_limpio.csv
```

```r
# Análisis de duplicados en el dataset original
cat(yellow("\n--- ANÁLISIS DE DUPLICADOS EN EL DATASET ORIGINAL ---\n"))
```

```
##
## --- ANÁLISIS DE DUPLICADOS EN EL DATASET ORIGINAL ---
```

```r
hotel_data_original <- read.csv(CSV_original, header = TRUE, stringsAsFactors = FALSE)

filas_originales <- nrow(hotel_data_original)
filas_sin_duplicados <- nrow(hotel_data)
filas_duplicadas <- filas_originales - filas_sin_duplicados

# Cálculo de porcentajes
porcentaje_duplicados <- round((filas_duplicadas / filas_originales) * 100, 2)
porcentaje_unicos <- round((filas_sin_duplicados / filas_originales) * 100, 2)

# Mostrar resultados
cat("• Dataset original:", filas_originales, "filas\n")
```

```
## • Dataset original: 119390 filas
```

```r
cat("• Dataset sin duplicados:", filas_sin_duplicados, "filas\n")
```

```
## • Dataset sin duplicados: 87396 filas
```

```r
cat("• Duplicados eliminados:", filas_duplicadas, "filas\n\n")
```

```
## • Duplicados eliminados: 31994 filas
```

```r
cat("• Porcentaje de duplicados:", porcentaje_duplicados, "%\n")
```

```
## • Porcentaje de duplicados: 26.8 %
```

```r
cat("• Porcentaje de registros únicos:", porcentaje_unicos, "%\n\n")
```

```
## • Porcentaje de registros únicos: 73.2 %
```

```r
cat("Impacto de la eliminación de duplicados:\n")
```

```
## Impacto de la eliminación de duplicados:
```

```r
cat(sprintf("De cada 100 filas en el dataset original, %.0f eran registros únicos y %.0f eran duplicados
           porcentaje_unicos, porcentaje_duplicados))
```

```
## De cada 100 filas en el dataset original, 73 eran registros únicos y 27 eran duplicados.
```

```r
cat(yellow("\n--- COMPARACIÓN DE DIMENSIONES ---\n"))
```

```
##
## --- COMPARACIÓN DE DIMENSIONES ---
```

```r
# Dimensiones de cada versión del dataset
dim_original <- dim(hotel_data_original)
dim_sin_duplicados <- dim(hotel_data)
dim_limpio <- dim(hotel_data_limpio)

cat("1. CSV original (sin procesar):", dim_original[1], "filas x", dim_original[2], "columnas\n")
```

```
## 1. CSV original (sin procesar): 119390 filas x 32 columnas
```

```r
cat("2. Dataset después de eliminar duplicados:", dim_sin_duplicados[1], "filas x", dim_sin_duplicados[
```

```
## 2. Dataset después de eliminar duplicados: 87396 filas x 32 columnas
```

```r
cat("3. Dataset limpio (transformado):", dim_limpio[1], "filas x", dim_limpio[2], "columnas\n")
```

```
## 3. Dataset limpio (transformado): 87396 filas x 32 columnas
```

```r
# Verificar si hubo cambios entre original y después de eliminar duplicados
filas_diff_1 <- dim_sin_duplicados[1] - dim_original[1]
if (filas_diff_1 != 0) {
  cat(blue("• Al eliminar duplicados: ",
           ifelse(filas_diff_1 < 0,
                  paste("Se eliminaron", abs(filas_diff_1), "filas duplicadas"),
                  paste("Atención: Aumentaron", filas_diff_1, "filas (comportamiento no esperado)")),
           "\n"))
} else {
  cat(blue("• No se encontraron filas duplicadas en el dataset original\n"))
}
```

```
## • Al eliminar duplicados:  Se eliminaron 31994 filas duplicadas
```

```r
# Verificar cambios entre dataset sin duplicados y dataset limpio
filas_diff_2 <- dim_limpio[1] - dim_sin_duplicados[1]
cols_diff_2 <- dim_limpio[2] - dim_sin_duplicados[2]

if (filas_diff_2 != 0) {
  cat(red("• Durante la limpieza: ",
           ifelse(filas_diff_2 < 0,
                  paste("Se eliminaron", abs(filas_diff_2), "filas por filtros aplicados"),
                  paste("Aumentaron", filas_diff_2, "filas (verificar operaciones de join)")),
           "\n"))
} else {
  cat(blue("• Durante la limpieza: El número exacto de filas se mantuvo constante (",
           dim_limpio[1], " filas)\n"))
}
```

```
## • Durante la limpieza: El número exacto de filas se mantuvo constante ( 87396  filas)
```

```r
# Identificar columnas adicionales o eliminadas
if (cols_diff_2 != 0) {
  cols_originales <- colnames(hotel_data)
  cols_limpias <- colnames(hotel_data_limpio)

  if (cols_diff_2 > 0) {
    # Se añadieron columnas
    cols_nuevas <- setdiff(cols_limpias, cols_originales)
    cat(blue("• Se crearon", length(cols_nuevas), "columnas derivadas durante la transformación:\n"))
```

```
    for (col in cols_nuevas) {
      cat("  - ", col, "\n")
    }
  } else {
    # Se eliminaron columnas
    cols_eliminadas <- setdiff(cols_originales, cols_limpias)
    cat(red("• Se eliminaron", length(cols_eliminadas), "columnas durante la transformación:\n"))
    for (col in cols_eliminadas) {
      cat("  - ", col, "\n")
    }
  }
} else {
  cat(blue("• No se modificó la estructura de columnas durante la transformación\n"))
}
```

```
## • No se modificó la estructura de columnas durante la transformación
```

```
# Informe técnico detallado con comparaciones antes/después
cat(yellow("\nINFORME TÉCNICO DE TRANSFORMACIONES - ANTES vs DESPUÉS:\n"))
```

```
##
## INFORME TÉCNICO DE TRANSFORMACIONES - ANTES vs DESPUÉS:
```

```
# Imputación de NAs
na_antes <- sum(is.na(hotel_data$children))
na_despues <- sum(is.na(hotel_data_limpio$children))
cat("• Imputación de valores faltantes:\n")
```

```
## • Imputación de valores faltantes:
```

```
cat("  - Variable 'children': ", na_antes, " valores NA (antes) → ", na_despues, " valores NA (después)
```

```
##   - Variable 'children':  4  valores NA (antes) →  0  valores NA (después)
```

```
# Winsorización y corrección de valores atípicos
cat("\n• Rangos de valores numéricos antes y después de winsorización:\n")
```

```
##
## • Rangos de valores numéricos antes y después de winsorización:
```

```
# Función para mostrar comparaciones de rangos
mostrar_comparacion <- function(variable, min_antes, max_antes, min_despues, max_despues, num_ajustados
  if (!is.null(num_ajustados) && num_ajustados > 0) {
    cat("  - ", variable, ": [", min_antes, ", ", max_antes, "] → [", min_despues, ", ", max_despues,
        "] (", num_ajustados, " valores ajustados", ifelse(!is.null(descripcion), paste(" - ", descripc
  } else {
    cat("  - ", variable, ": [", min_antes, ", ", max_antes, "] → [", min_despues, ", ", max_despues, "
  }
}

# lead_time
lead_time_antes <- range(hotel_data$lead_time)
lead_time_despues <- range(hotel_data_limpio$lead_time)
num_ajustados_lead <- sum(hotel_data$lead_time > 365)
mostrar_comparacion("lead_time", lead_time_antes[1], lead_time_antes[2],
                    lead_time_despues[1], lead_time_despues[2], num_ajustados_lead)
```

```
##   - lead_time: [0, 737] → [0, 365] (565 valores ajustados)
```

```r
# adults
adults_antes <- range(hotel_data$adults)
adults_despues <- range(hotel_data_limpio$adults)
num_ceros_adults <- sum(hotel_data$adults == 0)
num_grandes_adults <- sum(hotel_data$adults > 4)
mostrar_comparacion("adults", adults_antes[1], adults_antes[2],
                    adults_despues[1], adults_despues[2],
                    num_ceros_adults + num_grandes_adults,
                    paste(num_ceros_adults, "valores 0→1,", num_grandes_adults, "valores >4→4"))
```

```
##   - adults: [0, 55] → [1, 4] (401 valores ajustados -  385 valores 0→1, 16 valores >4→4)
```

```r
# stays_in_weekend_nights
weekend_antes <- range(hotel_data$stays_in_weekend_nights)
weekend_despues <- range(hotel_data_limpio$stays_in_weekend_nights)
num_ajustados_weekend <- sum(hotel_data$stays_in_weekend_nights > 14)
mostrar_comparacion("stays_in_weekend_nights", weekend_antes[1], weekend_antes[2],
                    weekend_despues[1], weekend_despues[2], num_ajustados_weekend)
```

```
##   - stays_in_weekend_nights: [0, 19] → [0, 14] (5 valores ajustados)
```

```r
# stays_in_week_nights
week_antes <- range(hotel_data$stays_in_week_nights)
week_despues <- range(hotel_data_limpio$stays_in_week_nights)
num_ajustados_week <- sum(hotel_data$stays_in_week_nights > 14)
mostrar_comparacion("stays_in_week_nights", week_antes[1], week_antes[2],
                    week_despues[1], week_despues[2], num_ajustados_week)
```

```
##   - stays_in_week_nights: [0, 50] → [0, 14] (198 valores ajustados)
```

```r
# adr
adr_antes <- range(hotel_data$adr)
adr_despues <- range(hotel_data_limpio$adr)
num_neg_adr <- sum(hotel_data$adr < 0)
num_altos_adr <- sum(hotel_data$adr > 1000)
mostrar_comparacion("adr", adr_antes[1], adr_antes[2],
                    adr_despues[1], adr_despues[2],
                    num_neg_adr + num_altos_adr,
                    paste(num_neg_adr, "valores negativos→0,", num_altos_adr, "valores >1000→1000"))
```

```
##   - adr: [-6.38, 5400] → [0, 1000] (2 valores ajustados -  1 valores negativos→0, 1 valores >1000→100
```

```r
# children
children_antes <- range(hotel_data$children, na.rm=TRUE)
children_despues <- range(hotel_data_limpio$children)
num_ajustados_children <- sum(hotel_data$children > 3, na.rm=TRUE)
mostrar_comparacion("children", children_antes[1], children_antes[2],
                    children_despues[1], children_despues[2], num_ajustados_children)
```

```
##   - children: [0, 10] → [0, 3] (1 valores ajustados)
```

```r
# babies
babies_antes <- range(hotel_data$babies)
babies_despues <- range(hotel_data_limpio$babies)
num_ajustados_babies <- sum(hotel_data$babies > 2)
mostrar_comparacion("babies", babies_antes[1], babies_antes[2],
                    babies_despues[1], babies_despues[2], num_ajustados_babies)
```

```
##   - babies: [0, 10] → [0, 2] (2 valores ajustados)
```

```
# Correcciones lógicas
cat("\n• Correcciones de inconsistencias lógicas:\n")
```

```
##
## • Correcciones de inconsistencias lógicas:
```

```
# Reservas sin noches
reservas_sin_noches_antes <- sum(hotel_data$stays_in_weekend_nights == 0 & hotel_data$stays_in_week_nigh
reservas_sin_noches_despues <- sum(hotel_data_limpio$stays_in_weekend_nights == 0 & hotel_data_limpio$s
cat("  - Reservas con estancia de 0 días: ", reservas_sin_noches_antes, " (antes) → ",
    reservas_sin_noches_despues, " (después)\n")
```

```
##   - Reservas con estancia de 0 días:  651  (antes) →  0  (después)
```

```
# Reservas sin adultos
reservas_sin_adultos_antes <- sum(hotel_data$adults == 0)
reservas_sin_adultos_despues <- sum(hotel_data_limpio$adults == 0)
cat("  - Reservas sin adultos: ", reservas_sin_adultos_antes, " (antes) → ",
    reservas_sin_adultos_despues, " (después)\n")
```

```
##   - Reservas sin adultos:  385  (antes) →  0  (después)
```

```
# Variables derivadas
cols_nuevas <- setdiff(colnames(hotel_data_limpio), colnames(hotel_data))
if (length(cols_nuevas) > 0) {
  cat("\n• Variables derivadas creadas (", length(cols_nuevas), "):\n")
  for (col in cols_nuevas) {
    # Descripción basada en el nombre de la columna
    descripcion <- switch(col,
                          "arrival_yearmonth" = "Combinación de año-mes para análisis temporal",
                          "tiene_ninos" = "Indicador booleano si la reserva incluye niños",
                          "tiene_bebes" = "Indicador booleano si la reserva incluye bebés",
                          "tiene_menores" = "Indicador booleano si la reserva incluye niños o bebés",
                          "requiere_estacionamiento" = "Indicador booleano si la reserva requiere estaci
                          "total_nights" = "Suma total de noches de estancia (semana + fin de semana)",
                          "tipo_familia" = "Categorización de reservas según composición familiar",
                          "lead_time_categoria" = "Categorización del tiempo de anticipación",
                          "Temporada" = "Clasificación de temporada (Alta/Media/Baja)",
                          "Indicador derivado") # Descripción genérica

    if (col %in% colnames(hotel_data_limpio)) {
      # Si tenemos acceso a la columna en este punto, mostrar estadísticas básicas
      if (is.numeric(hotel_data_limpio[[col]])) {
        cat("  - ", col, ": ", descripcion, " (Rango: [", min(hotel_data_limpio[[col]], na.rm=TRUE),
            ", ", max(hotel_data_limpio[[col]], na.rm=TRUE), "])\n", sep="")
      } else if (is.factor(hotel_data_limpio[[col]]) || is.character(hotel_data_limpio[[col]])) {
        # Para factores o caracteres mostrar número de categorías únicas
        num_categorias <- length(unique(hotel_data_limpio[[col]]))
        cat("  - ", col, ": ", descripcion, " (", num_categorias, " categorías únicas)\n", sep="")
      } else {
        cat("  - ", col, ": ", descripcion, "\n", sep="")
      }
    } else {
      cat("  - ", col, ": ", descripcion, "\n", sep="")
    }
```

```
  }
}
```

```
#####################################################
# PARTE 06: ANÁLISIS EDA
#####################################################

hotel_data_limpio <- read.csv(CSV_limpio, header = TRUE, stringsAsFactors = FALSE)

graphics_analysis_dir <- file.path(graphics_dir, "analisis")
if (!dir.exists(graphics_analysis_dir)) {
  dir.create(graphics_analysis_dir)
  cat("Creado directorio para gráficas de análisis:", graphics_analysis_dir, "\n")
}

#-----------------------------------------
# EDA 01: ¿CUÁNTAS RESERVAS SE REALIZAN POR TIPO DE HOTEL? ¿QUÉ TIPO DE HOTEL PREFIERE LA GENTE?
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS POR TIPO DE HOTEL ---\n"))
```

```
##
## --- ANÁLISIS POR TIPO DE HOTEL ---
```

```
# Contar reservas por tipo de hotel
reservas_por_hotel <- table(hotel_data_limpio$hotel)
reservas_por_hotel_df <- as.data.frame(reservas_por_hotel)
names(reservas_por_hotel_df) <- c("Tipo_Hotel", "Cantidad")

# Calcular porcentajes
reservas_por_hotel_df$Porcentaje <- round(
  reservas_por_hotel_df$Cantidad / sum(reservas_por_hotel_df$Cantidad) * 100, 2
)

cat("\nDistribución de reservas por tipo de hotel:\n")
```

```
##
## Distribución de reservas por tipo de hotel:
```

```
print(reservas_por_hotel_df)
```

```
##     Tipo_Hotel Cantidad Porcentaje
## 1   City Hotel    53428      61.13
## 2 Resort Hotel    33968      38.87
```

```
# Visualizar distribución
plot_hoteles <- ggplot(reservas_por_hotel_df, aes(x = Tipo_Hotel, y = Cantidad, fill = Tipo_Hotel)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Cantidad, "\n(", Porcentaje, "%)")),
            position = position_stack(vjust = 0.5), color = "white", size = 4) +
  labs(title = "Cantidad de reservas por tipo de hotel",
       x = "Tipo de hotel",
```

```
       y = "Cantidad de reservas") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_hoteles)
```

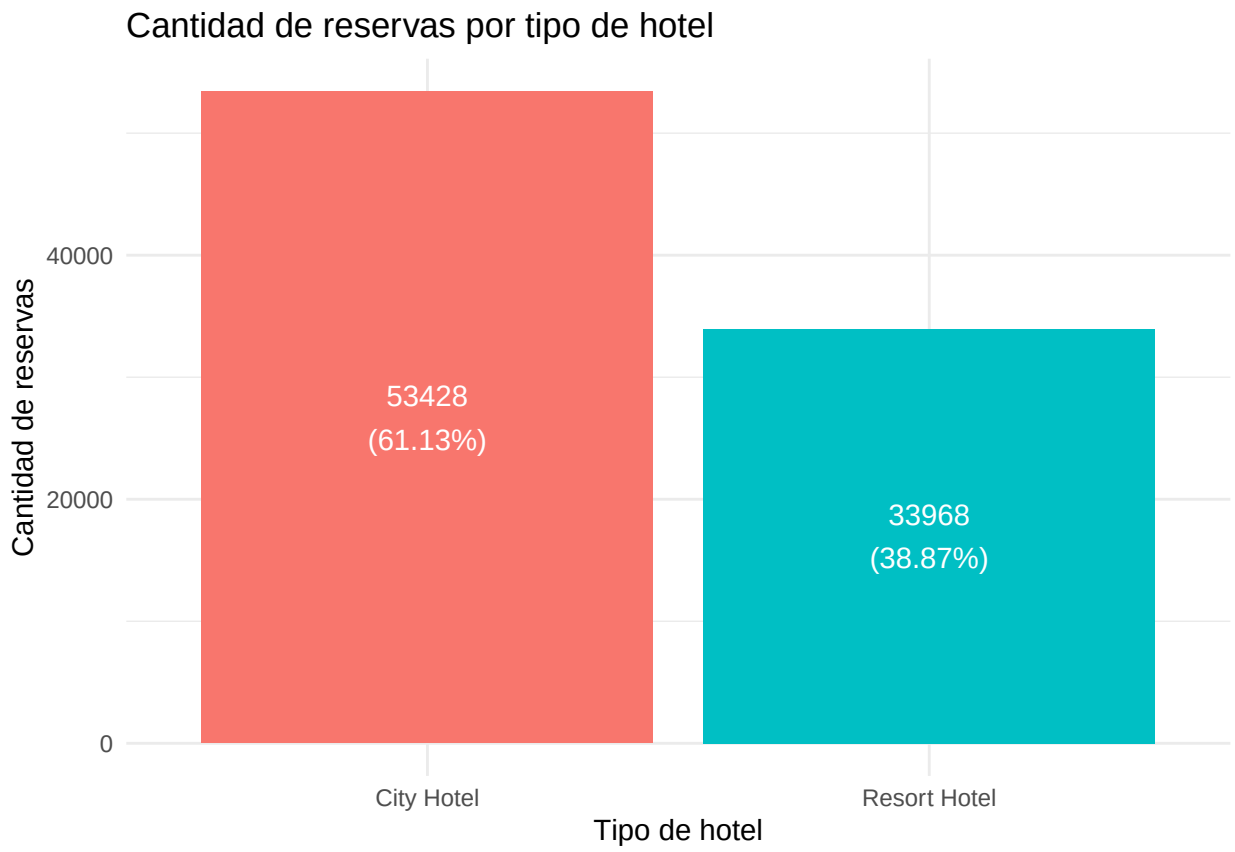


```
ggsave(file.path(graphics_analysis_dir, "reservas_por_hotel.jpg"),
       plot_hoteles, width = 8, height = 6, dpi = 300)


# Análisis por estado de cancelación para ver preferencia real
reservas_completadas <- hotel_data_limpio[hotel_data_limpio$is_canceled == 0, ]
reservas_completadas_por_hotel <- table(reservas_completadas$hotel)
reservas_completadas_df <- as.data.frame(reservas_completadas_por_hotel)
names(reservas_completadas_df) <- c("Tipo_Hotel", "Reservas_Completadas")

# Calcular porcentajes de reservas completadas
reservas_completadas_df$Porcentaje <- round(
  reservas_completadas_df$Reservas_Completadas / sum(reservas_completadas_df$Reservas_Completadas) * 100
)

cat("\nDistribución de reservas completadas (no canceladas) por tipo de hotel:\n")
```

```
##
## Distribución de reservas completadas (no canceladas) por tipo de hotel:
```

```r
print(reservas_completadas_df)
```

```
##     Tipo_Hotel Reservas_Completadas Porcentaje
## 1   City Hotel                37379      58.98
## 2 Resort Hotel                25992      41.02
```

```r
# Visualizar reservas completadas
plot_completadas <- ggplot(reservas_completadas_df, aes(x = Tipo_Hotel, y = Reservas_Completadas, fill =
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Reservas_Completadas, "\n(", Porcentaje, "%)")),
            position = position_stack(vjust = 0.5), color = "white", size = 4) +
  labs(title = "Reservas completadas por tipo de hotel",
       subtitle = "Excluyendo reservas canceladas",
       x = "Tipo de hotel",
       y = "Cantidad de reservas completadas") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_completadas)
```

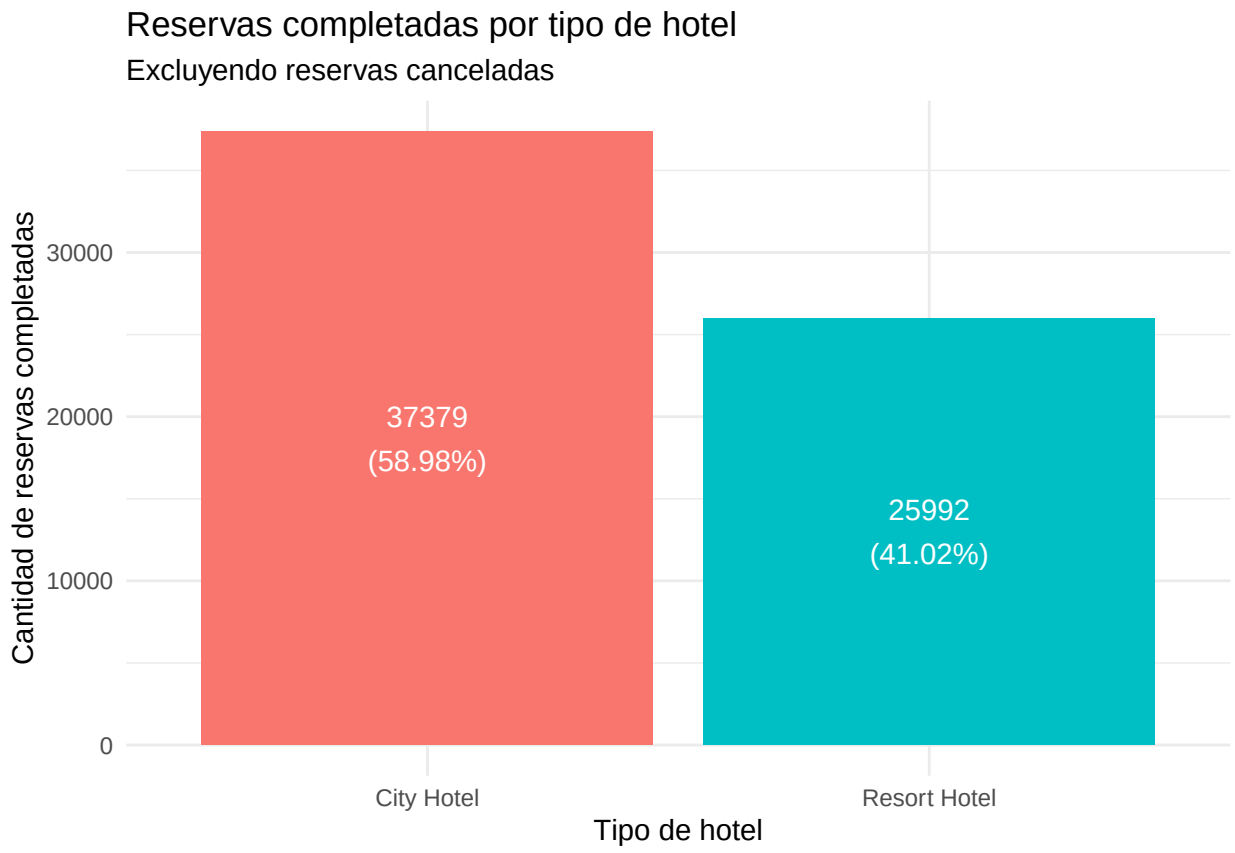


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "reservas_completadas_por_hotel.jpg"),
       plot_completadas, width = 8, height = 6, dpi = 300)

#----------------------------------------
# EDA 02: ¿ESTÁ AUMENTANDO LA DEMANDA CON EL TIEMPO?
cat(yellow("\n--- ANÁLISIS DE TENDENCIA DE DEMANDA ---\n"))
```

```
##
## --- ANÁLISIS DE TENDENCIA DE DEMANDA ---
```

```
# Análisis por año y mes
# Convertir mes a factor ordenado
hotel_data_limpio$arrival_date_month <- factor(
  hotel_data_limpio$arrival_date_month,
  levels = c("January", "February", "March", "April", "May", "June",
             "July", "August", "September", "October", "November", "December")
)

# Crear columna de fecha combinada (año-mes)
hotel_data_limpio$arrival_yearmonth <- paste(
  hotel_data_limpio$arrival_date_year,
  sprintf("%02d", as.numeric(factor(hotel_data_limpio$arrival_date_month,
                                    levels = c("January", "February", "March", "April", "May", "June",
                                               "July", "August", "September", "October", "November", "D
  sep = "-"
)

# Agregación por año-mes
reservas_por_tiempo <- hotel_data_limpio %>%
  group_by(arrival_yearmonth) %>%
  summarise(
    Total_Reservas = n(),
    Reservas_Completadas = sum(is_canceled == 0)
  ) %>%
  arrange(arrival_yearmonth)



# Mostrar tendencia de reservas de forma más clara
cat(yellow("\n--- TENDENCIA DE RESERVAS A LO LARGO DEL TIEMPO ---\n"))
```

```
##
## --- TENDENCIA DE RESERVAS A LO LARGO DEL TIEMPO ---
```

```
# Calcular tasa de cancelación para cada período
reservas_por_tiempo <- reservas_por_tiempo %>%
  mutate(
    Tasa_Cancelacion = round((Total_Reservas - Reservas_Completadas) / Total_Reservas * 100, 1),
    Periodo = paste(substr(arrival_yearmonth, 1, 4), substr(arrival_yearmonth, 6, 7), sep = "-")
  ) %>%
  select(Periodo, Total_Reservas, Reservas_Completadas, Tasa_Cancelacion)

# Mostrar tabla bonita
cat("\nDatos de reservas por período (primeros 10 meses):\n\n")
```

```
##
## Datos de reservas por período (primeros 10 meses):
```

```
print(knitr::kable(head(reservas_por_tiempo, 10),
                   col.names = c("Período", "Total Reservas", "Reservas Completadas", "Tasa Cancelación
                   align = c("l", "r", "r", "r"),
                   format = "simple"))
```

```
##
##
## Período    Total Reservas   Reservas Completadas   Tasa Cancelación (%)
## --------  ---------------  ---------------------  ----------------------
## 2015-07              1674                   1162                    30.6
## 2015-08              2453                   1882                    23.3
## 2015-09              2839                   2273                    19.9
## 2015-10              2700                   2260                    16.3
## 2015-11              1665                   1422                    14.6
## 2015-12              1982                   1610                    18.8
## 2016-01              1849                   1548                    16.3
## 2016-02              2806                   2278                    18.8
## 2016-03              3831                   2945                    23.1
## 2016-04              3770                   2756                    26.9
```

```
# Mostrar estadísticas de resumen
cat("\nEstadísticas de resumen:\n")
```

```
##
## Estadísticas de resumen:
```

```
cat("- Período con mayor cantidad de reservas:",
    reservas_por_tiempo$Periodo[which.max(reservas_por_tiempo$Total_Reservas)],
    "con", max(reservas_por_tiempo$Total_Reservas), "reservas\n")
```

```
## - Período con mayor cantidad de reservas: 2017-05 con 4575 reservas
```

```
cat("- Período con menor cantidad de reservas:",
    reservas_por_tiempo$Periodo[which.min(reservas_por_tiempo$Total_Reservas)],
    "con", min(reservas_por_tiempo$Total_Reservas), "reservas\n")
```

```
## - Período con menor cantidad de reservas: 2015-11 con 1665 reservas
```

```
cat("- Tasa de cancelación promedio:",
    round(mean(reservas_por_tiempo$Tasa_Cancelacion), 1), "%\n")
```

```
## - Tasa de cancelación promedio: 26.3 %
```

```
# Mostrar tendencia principal
primero <- head(reservas_por_tiempo, 1)
ultimo <- tail(reservas_por_tiempo, 1)
cambio_porc <- round((ultimo$Total_Reservas - primero$Total_Reservas) / primero$Total_Reservas * 100, 1

cat("\nTendencia general:", ifelse(cambio_porc > 0, "AUMENTO", "DISMINUCIÓN"),
    "del", abs(cambio_porc), "% en reservas totales",
    "desde", primero$Periodo, "hasta", ultimo$Periodo, "\n")
```

```
##
## Tendencia general: AUMENTO del 161.7 % en reservas totales desde 2015-07 hasta 2017-08
```

```
# Primero, preparo los datos calculando porcentajes
reservas_por_tiempo <- hotel_data_limpio %>%
  group_by(arrival_yearmonth) %>%
  summarise(
    Total_Reservas = n(),
    Reservas_Completadas = sum(is_canceled == 0),
    Reservas_Canceladas = sum(is_canceled == 1)
  ) %>%
```

```r
  mutate(
    Porcentaje_Completadas = round(Reservas_Completadas / Total_Reservas * 100, 1),
    Porcentaje_Canceladas = round(Reservas_Canceladas / Total_Reservas * 100, 1)
  ) %>%
  arrange(arrival_yearmonth)

# Reorganizo los datos para facilitar la visualización apilada
datos_para_grafico <- reservas_por_tiempo %>%
  pivot_longer(
    cols = c(Reservas_Completadas, Reservas_Canceladas),
    names_to = "Estado",
    values_to = "Cantidad"
  ) %>%
  mutate(
    Porcentaje = ifelse(
      Estado == "Reservas_Completadas",
      Porcentaje_Completadas,
      Porcentaje_Canceladas
    )
  )

# Creo un gráfico que muestra valores absolutos y porcentajes
plot_tendencia_porcentajes <- ggplot(datos_para_grafico,
                                     aes(x = arrival_yearmonth, y = Cantidad,
                                         fill = Estado, group = Estado)) +
  geom_bar(stat = "identity", position = "stack") +
  geom_text(aes(label = paste0(Porcentaje, "%")),
            position = position_stack(vjust = 0.5),
            color = "white", size = 3) +
  labs(title = "Tendencia de reservas a lo largo del tiempo",
       subtitle = "Mostrando porcentajes de reservas completadas y canceladas",
       x = "Año-Mes",
       y = "Cantidad de reservas",
       fill = "Estado") +
  scale_fill_manual(values = c("Reservas_Completadas" = "#2ecc71",
                               "Reservas_Canceladas" = "#e74c3c"),
                    labels = c("Completadas", "Canceladas")) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90, hjust = 1),
        legend.position = "bottom")

print(plot_tendencia_porcentajes)
```

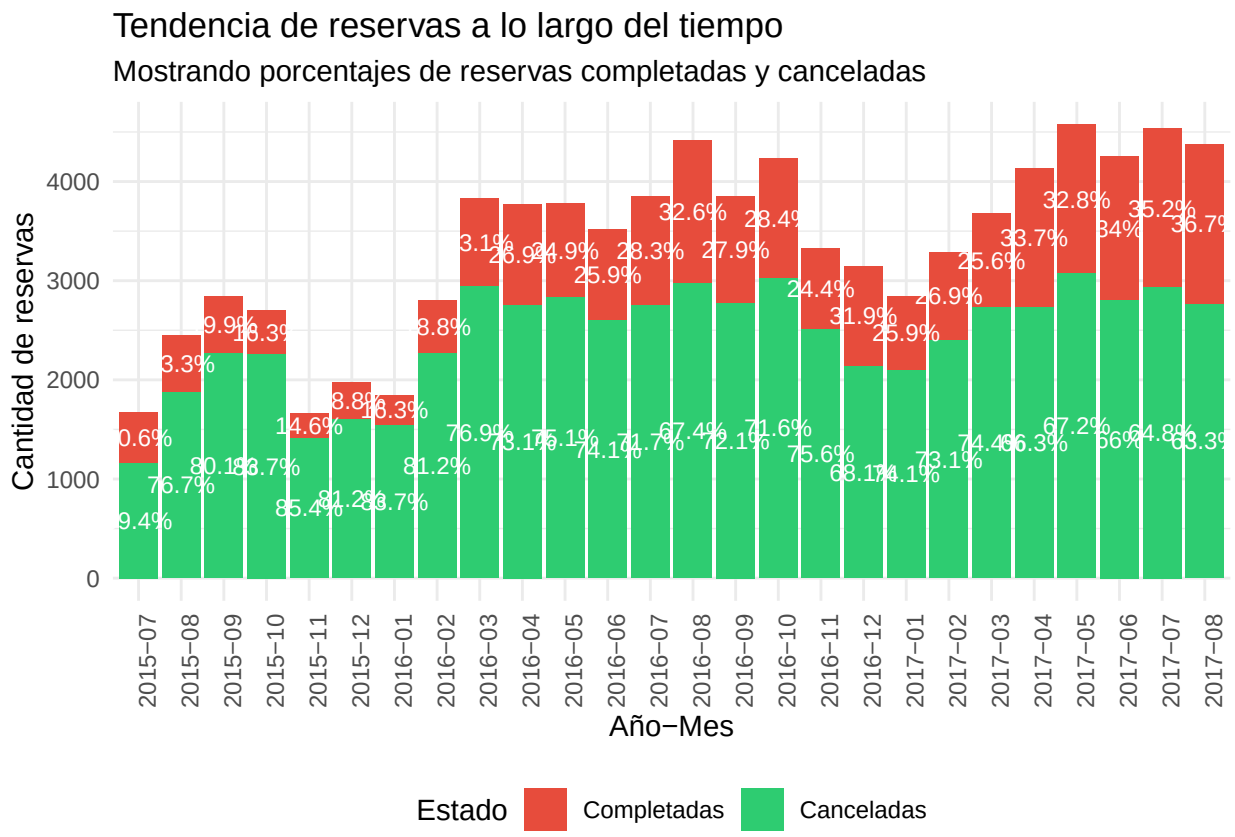


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "tendencia_reservas_porcentajes.jpg"),
       plot_tendencia_porcentajes, width = 12, height = 8, dpi = 300)

# También podemos crear un gráfico de líneas que muestre el porcentaje de cancelación a lo largo del ti
plot_porcentaje_cancelacion <- ggplot(reservas_por_tiempo,
                                      aes(x = arrival_yearmonth, y = Porcentaje_Canceladas, group = 1))
  geom_line(color = "#e74c3c", size = 1.2) +
  geom_point(color = "#e74c3c", size = 2) +
  geom_text(aes(label = paste0(Porcentaje_Canceladas, "%")),
            vjust = -0.8, size = 3) +
  labs(title = "Tendencia del porcentaje de cancelaciones",
       subtitle = "Porcentaje de reservas canceladas por mes",
       x = "Año-Mes",
       y = "Porcentaje de cancelación (%)") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90, hjust = 1))
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

```
print(plot_porcentaje_cancelacion)
```

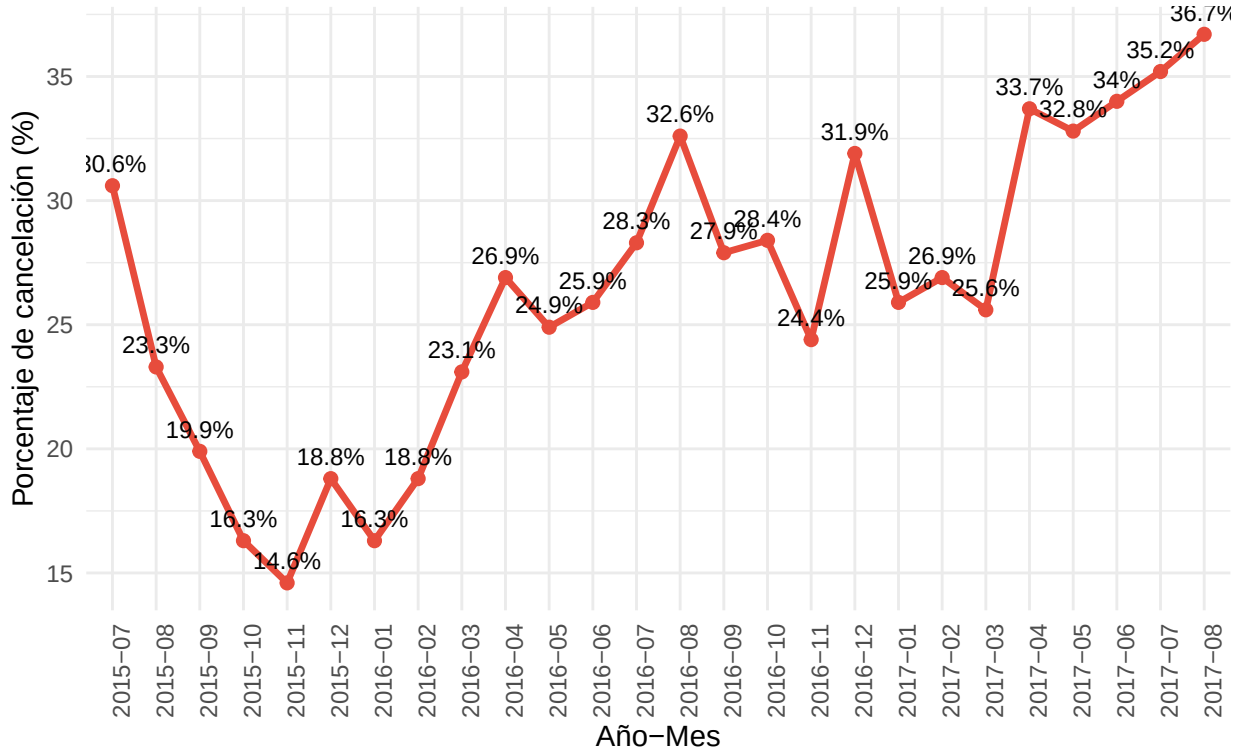


```
# Guardar segunda gráfica
ggsave(file.path(graphics_analysis_dir, "tendencia_porcentaje_cancelacion.jpg"),
       plot_porcentaje_cancelacion, width = 12, height = 8, dpi = 300)
```

```
# Análisis por año con porcentajes
reservas_por_anio <- hotel_data_limpio %>%
  group_by(arrival_date_year) %>%
  summarise(
    Total_Reservas = n(),
    Reservas_Completadas = sum(is_canceled == 0),
    Reservas_Canceladas = sum(is_canceled == 1)
  ) %>%
  mutate(
    Porcentaje_Completadas = round(Reservas_Completadas / Total_Reservas * 100, 1),
    Porcentaje_Canceladas = round(Reservas_Canceladas / Total_Reservas * 100, 1)
  )

cat("\nReservas por año con porcentajes:\n")
```

```
##
## Reservas por año con porcentajes:
```

```r
print(reservas_por_anio)
```

```
## # A tibble: 3 x 6
##   arrival_date_year Total_Reservas Reservas_Completadas Reservas_Canceladas
##               <int>          <int>                <int>               <int>
## 1              2015          13313                10609                2704
## 2              2016          42391                31183               11208
## 3              2017          31692                21579               10113
## # i 2 more variables: Porcentaje_Completadas <dbl>, Porcentaje_Canceladas <dbl>
```

```r
# Preparar datos para el gráfico horizontal
datos_anio_apilado <- reservas_por_anio %>%
  pivot_longer(
    cols = c(Reservas_Completadas, Reservas_Canceladas),
    names_to = "Estado",
    values_to = "Cantidad"
  ) %>%
  mutate(
    Porcentaje = ifelse(
      Estado == "Reservas_Completadas",
      Porcentaje_Completadas,
      Porcentaje_Canceladas
    )
  )

# Crear el gráfico horizontal de barras apiladas
plot_anios_horizontal <- ggplot(datos_anio_apilado,
                                aes(x = as.factor(arrival_date_year),
                                    y = Cantidad,
                                    fill = Estado,
                                    group = Estado)) +
  geom_bar(stat = "identity", position = "stack") +
  geom_text(aes(label = paste0(Cantidad, " (", Porcentaje, "%)")),
            position = position_stack(vjust = 0.5),
            color = "white", size = 4) +
  coord_flip() + # Hace el gráfico horizontal
  labs(title = "Reservas por año",
       subtitle = "Mostrando cantidades y porcentajes de reservas",
       y = "Cantidad de reservas",
       x = "Año",
       fill = "Estado") +
  scale_fill_manual(values = c("Reservas_Completadas" = "#2ecc71",
                               "Reservas_Canceladas" = "#e74c3c"),
                    labels = c("Completadas", "Canceladas")) +
  theme_minimal() +
  theme(legend.position = "bottom")

print(plot_anios_horizontal)
```

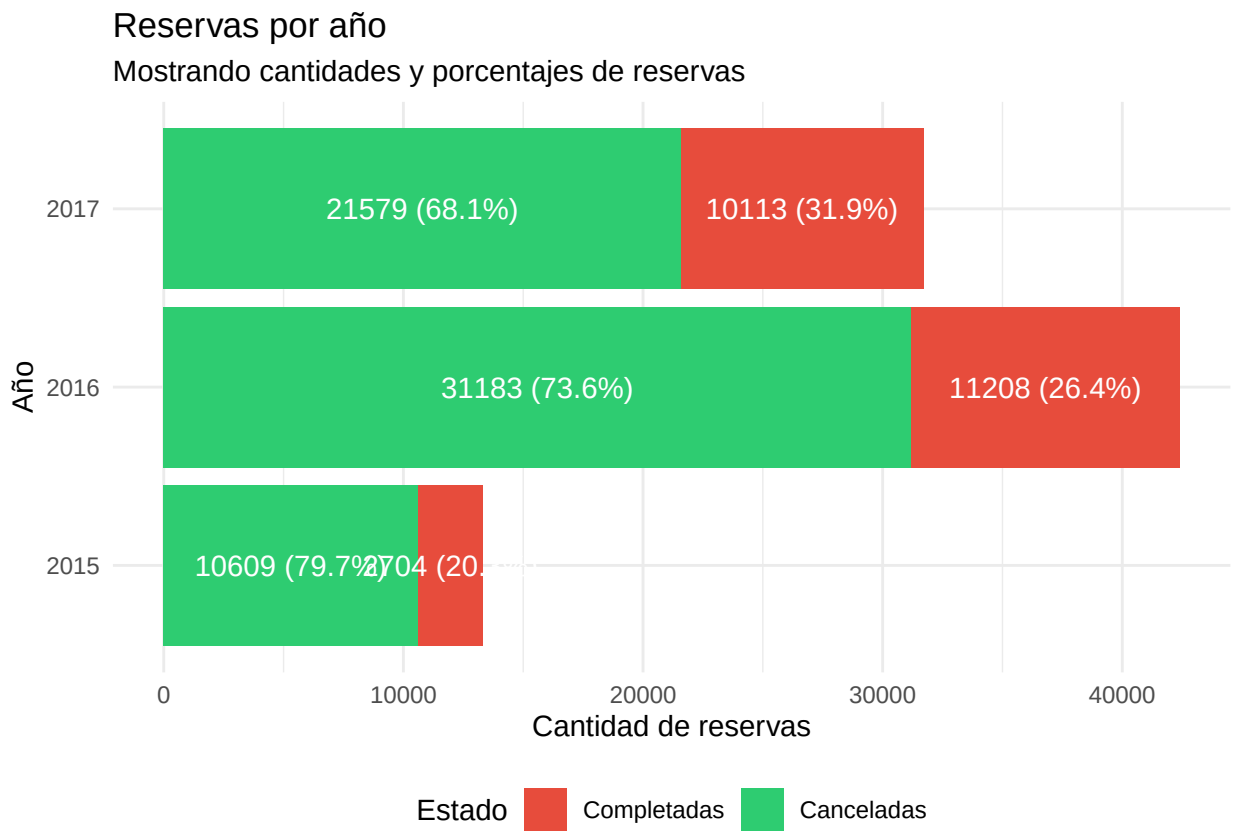


```
# Guardar gráfica horizontal
ggsave(file.path(graphics_analysis_dir, "reservas_por_anio_horizontal.jpg"),
       plot_anios_horizontal, width = 8, height = 6, dpi = 300)




#-----------------------------------------
# EDA 03: ¿CUÁLES SON LAS TEMPORADAS DE RESERVAS (ALTA, MEDIA, BAJA)?
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS DE TEMPORADAS ---\n"))
```

```
##
## --- ANÁLISIS DE TEMPORADAS ---
```

```
# Agregación por mes
reservas_por_mes <- hotel_data_limpio %>%
  group_by(arrival_date_month) %>%
  summarise(
    Total_Reservas = n(),
    Reservas_Completadas = sum(is_canceled == 0),
    Tasa_Cancelacion = round(sum(is_canceled) / n() * 100, 2)
  ) %>%
  arrange(match(arrival_date_month, c("January", "February", "March", "April", "May", "June",
                                      "July", "August", "September", "October", "November", "December"))
```

```r
cat("\nReservas por mes:\n")
```

```
##
## Reservas por mes:
```

```r
print(reservas_por_mes)
```

```
## # A tibble: 12 x 4
##    arrival_date_month Total_Reservas Reservas_Completadas Tasa_Cancelacion
##    <fct>                       <int>                <int>            <dbl>
##  1 January                      4693                 3655             22.1
##  2 February                     6098                 4683             23.2
##  3 March                        7513                 5683             24.4
##  4 April                        7908                 5499             30.5
##  5 May                          8355                 5913             29.2
##  6 June                         7765                 5411             30.3
##  7 July                        10057                 6859             31.8
##  8 August                      11257                 7634             32.2
##  9 September                    6690                 5048             24.5
## 10 October                      6934                 5292             23.7
## 11 November                     4995                 3941             21.1
## 12 December                     5131                 3753             26.9
```

```r
# Determinar temporadas basadas en cantidad de reservas
media_reservas <- mean(reservas_por_mes$Total_Reservas)
sd_reservas <- sd(reservas_por_mes$Total_Reservas)

reservas_por_mes$Temporada <- case_when(
  reservas_por_mes$Total_Reservas >= (media_reservas + 0.5 * sd_reservas) ~ "Alta",
  reservas_por_mes$Total_Reservas <= (media_reservas - 0.5 * sd_reservas) ~ "Baja",
  TRUE ~ "Media"
)

cat("\nClasificación de temporadas por mes:\n")
```

```
##
## Clasificación de temporadas por mes:
```

```r
print(reservas_por_mes[, c("arrival_date_month", "Total_Reservas", "Temporada")])
```

```
## # A tibble: 12 x 3
##    arrival_date_month Total_Reservas Temporada
##    <fct>                       <int> <chr>
##  1 January                      4693 Baja
##  2 February                     6098 Baja
##  3 March                        7513 Media
##  4 April                        7908 Media
##  5 May                          8355 Alta
##  6 June                         7765 Media
##  7 July                        10057 Alta
##  8 August                      11257 Alta
##  9 September                    6690 Media
## 10 October                      6934 Media
## 11 November                     4995 Baja
## 12 December                     5131 Baja
```

```r
# Visualizar reservas por mes
plot_meses <- ggplot(reservas_por_mes, aes(x = arrival_date_month, y = Total_Reservas, fill = Temporada
  geom_bar(stat = "identity") +
  geom_text(aes(label = Total_Reservas), vjust = -0.5, color = "black") +
  labs(title = "Reservas por mes y temporada",
       x = "Mes",
       y = "Cantidad de reservas") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(plot_meses)
```

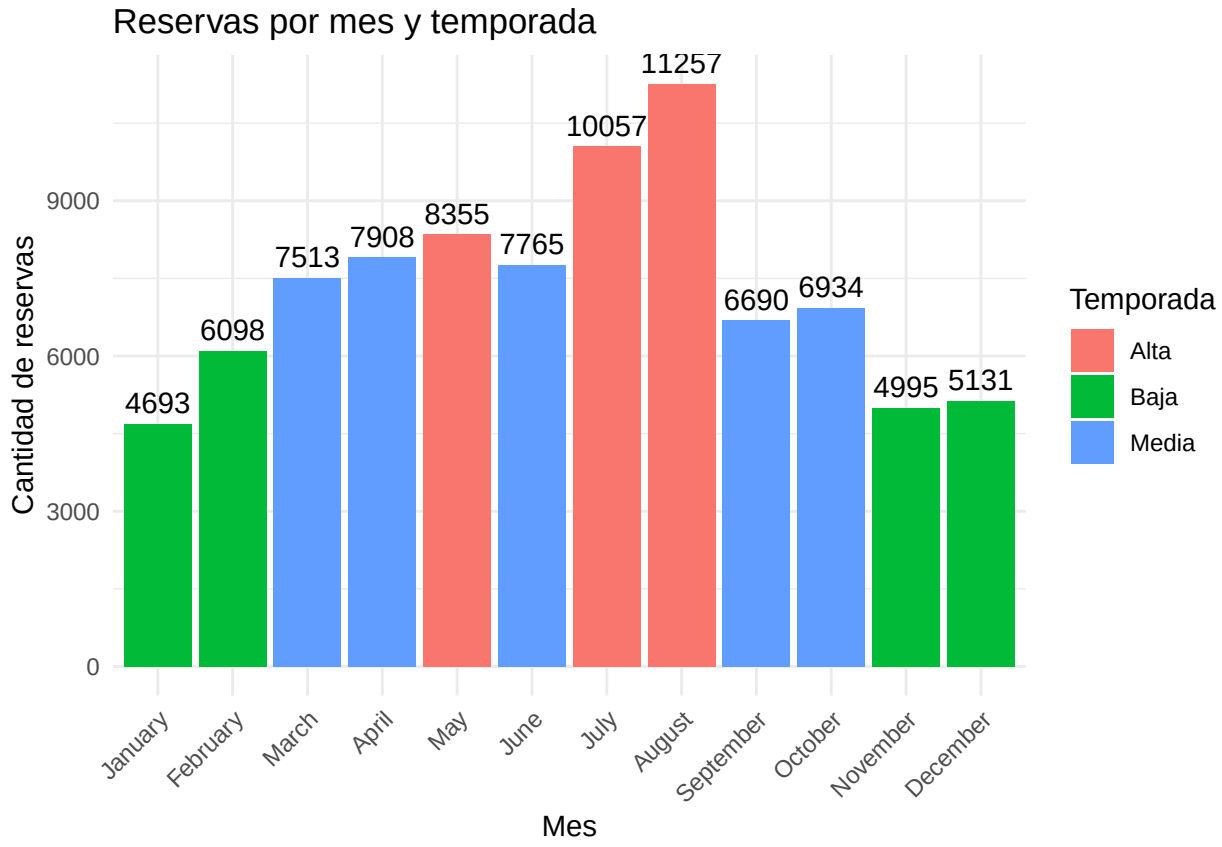


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "reservas_por_mes.jpg"),
       plot_meses, width = 10, height = 6, dpi = 300)
```

```r
#----------------------------------------
# EDA 04:  ¿CUÁNDO ES MENOR LA DEMANDA DE RESERVAS?
#----------------------------------------
cat(yellow("\n--- ANÁLISIS DE PERÍODOS DE BAJA DEMANDA ---\n"))
```

```
##
```

```
## --- ANÁLISIS DE PERÍODOS DE BAJA DEMANDA ---
# Ya identificamos los meses de baja demanda en el análisis anterior
meses_baja_demanda <- reservas_por_mes %>%
  filter(Temporada == "Baja") %>%
  arrange(Total_Reservas)

cat("\nMeses con menor demanda de reservas:\n")
```

```
##
## Meses con menor demanda de reservas:
```

```
print(meses_baja_demanda)
```

```
## # A tibble: 4 x 5
##   arrival_date_month Total_Reservas Reservas_Completadas Tasa_Cancelacion
##   <fct>                      <int>                <int>            <dbl>
## 1 January                     4693                 3655             22.1
## 2 November                    4995                 3941             21.1
## 3 December                    5131                 3753             26.9
## 4 February                    6098                 4683             23.2
## # i 1 more variable: Temporada <chr>
```

```
# Análisis por combinación de mes y día del mes
reservas_por_dia_mes <- hotel_data_limpio %>%
  group_by(arrival_date_month, arrival_date_day_of_month) %>%
  summarise(Total_Reservas = n()) %>%
  arrange(Total_Reservas)
```

```
## `summarise()` has grouped output by 'arrival_date_month'. You can override
## using the `.groups` argument.
```

```
cat("\nCombinaciones de mes y día con menor demanda (10 primeros):\n")
```

```
##
## Combinaciones de mes y día con menor demanda (10 primeros):
```

```
print(head(reservas_por_dia_mes, 10))
```

```
## # A tibble: 10 x 3
## # Groups:   arrival_date_month [4]
##    arrival_date_month arrival_date_day_of_month Total_Reservas
##    <fct>                                 <int>          <int>
##  1 February                                 29             66
##  2 December                                 11             76
##  3 December                                 13             91
##  4 January                                  11             95
##  5 November                                 29             97
##  6 December                                 18             97
##  7 December                                 15             98
##  8 January                                  17            100
##  9 November                                 30            100
## 10 January                                  31            104
```

```
# Visualizar los 10 días con menor demanda
dias_menor_demanda <- reservas_por_dia_mes %>%
  arrange(Total_Reservas) %>%
  head(10)
```

```r
dias_menor_demanda$Fecha <- paste(dias_menor_demanda$arrival_date_month,
                                  dias_menor_demanda$arrival_date_day_of_month)

# Gráfico con el menor valor arriba
plot_menor_demanda <- ggplot(dias_menor_demanda,
                             aes(x = reorder(Fecha, Total_Reservas),
                                 y = Total_Reservas,
                                 fill = Total_Reservas)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = Total_Reservas), hjust = -0.2) +
  labs(title = "10 días con menor demanda de reservas",
       subtitle = "Ordenados de menor a mayor",
       x = "Fecha (Mes-Día)",
       y = "Cantidad de reservas") +
  coord_flip() +
  scale_fill_gradient(low = "#e74c3c", high = "#f39c12") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_menor_demanda)
```

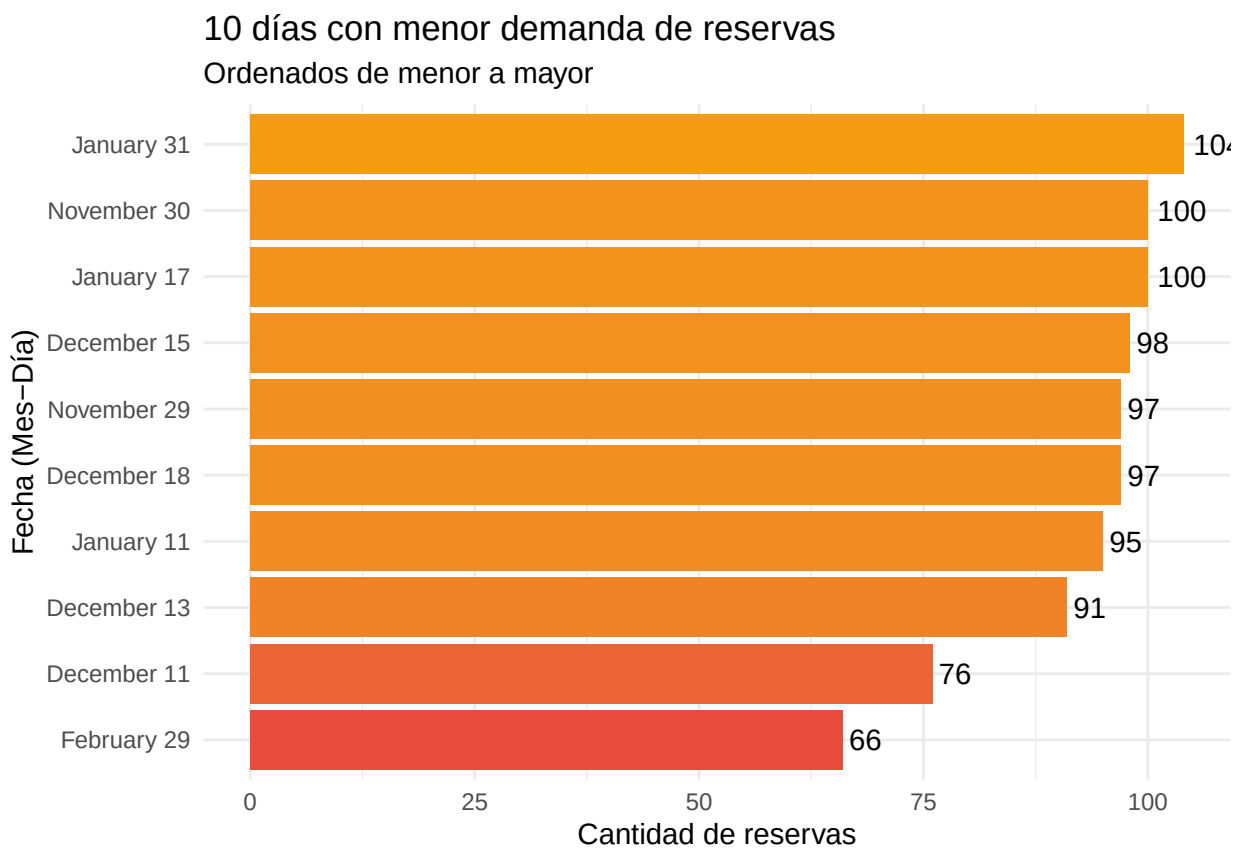


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "dias_menor_demanda.jpg"),
       plot_menor_demanda, width = 8, height = 6, dpi = 300)
```

```r
#-----------------------------------------
# EDA 05: ¿CUÁNDO ES MAYOR LA DEMANDA DE RESERVAS?
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS DE PERÍODOS DE ALTA DEMANDA ---\n"))
```

```
##
## --- ANÁLISIS DE PERÍODOS DE ALTA DEMANDA ---
```

```r
# Identificar meses de alta demanda
meses_alta_demanda <- reservas_por_mes %>%
  filter(Temporada == "Alta") %>%
  arrange(desc(Total_Reservas))

cat("\nMeses con mayor demanda de reservas:\n")
```

```
##
## Meses con mayor demanda de reservas:
```

```r
print(meses_alta_demanda)
```

```
## # A tibble: 3 x 5
##   arrival_date_month Total_Reservas Reservas_Completadas Tasa_Cancelacion
##   <fct>                       <int>                <int>            <dbl>
## 1 August                      11257                 7634             32.2
## 2 July                        10057                 6859             31.8
## 3 May                          8355                 5913             29.2
## # i 1 more variable: Temporada <chr>
```

```r
# Análisis por combinación de mes y día del mes para alta demanda
cat("\nCombinaciones de mes y día con mayor demanda (10 primeros):\n")
```

```
##
## Combinaciones de mes y día con mayor demanda (10 primeros):
```

```r
dias_mayor_demanda <- reservas_por_dia_mes %>%
  arrange(desc(Total_Reservas)) %>%
  head(10)

print(dias_mayor_demanda)
```

```
## # A tibble: 10 x 3
## # Groups:   arrival_date_month [2]
##    arrival_date_month arrival_date_day_of_month Total_Reservas
##    <fct>                                <int>          <int>
##  1 August                                   1            455
##  2 August                                  17            436
##  3 April                                   29            431
##  4 August                                   8            424
##  5 August                                  15            416
##  6 August                                  16            405
##  7 August                                   7            399
##  8 August                                  20            396
##  9 August                                  13            390
```

```
## 10 August                                    28             388
```

```r
# Crear etiqueta de fecha
dias_mayor_demanda$Fecha <- paste(dias_mayor_demanda$arrival_date_month,
                                  dias_mayor_demanda$arrival_date_day_of_month)

# Visualizar los 10 días con mayor demanda
plot_mayor_demanda <- ggplot(dias_mayor_demanda,
                             aes(x = reorder(Fecha, -Total_Reservas),
                                 y = Total_Reservas,
                                 fill = Total_Reservas)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = Total_Reservas), hjust = -0.2) +
  labs(title = "10 días con mayor demanda de reservas",
       subtitle = "Ordenados de mayor a menor",
       x = "Fecha (Mes-Día)",
       y = "Cantidad de reservas") +
  coord_flip() +
  scale_fill_gradient(low = "#f39c12", high = "#2ecc71") +  # Invertimos colores: amarillo a verde
  theme_minimal() +
  theme(legend.position = "none")

print(plot_mayor_demanda)
```


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "dias_mayor_demanda.jpg"),
       plot_mayor_demanda, width = 8, height = 6, dpi = 300)
```

```r
# Comparativa de meses extremos (mayor y menor demanda)
cat(yellow("\n--- COMPARATIVA DE MESES DE MAYOR Y MENOR DEMANDA ---\n"))
```

```
##
## --- COMPARATIVA DE MESES DE MAYOR Y MENOR DEMANDA ---
```

```r
# Obtener el mes de mayor y menor demanda
mes_max_demanda <- reservas_por_mes %>%
  arrange(desc(Total_Reservas)) %>%
  slice(1)

mes_min_demanda <- reservas_por_mes %>%
  arrange(Total_Reservas) %>%
  slice(1)

cat("\nMes con MAYOR demanda:", mes_max_demanda$arrival_date_month,
    "con", mes_max_demanda$Total_Reservas, "reservas\n")
```

```
##
## Mes con MAYOR demanda: 8 con 11257 reservas
```

```r
cat("Mes con MENOR demanda:", mes_min_demanda$arrival_date_month,
    "con", mes_min_demanda$Total_Reservas, "reservas\n")
```

```
## Mes con MENOR demanda: 1 con 4693 reservas
```

```r
# Crear dataframe para comparativa
meses_extremos <- rbind(
  mes_max_demanda %>% mutate(Tipo = "Mayor demanda"),
  mes_min_demanda %>% mutate(Tipo = "Menor demanda")
)

# Visualizar comparativa
plot_meses_extremos <- ggplot(meses_extremos,
                              aes(x = arrival_date_month, y = Total_Reservas, fill = Tipo)) +
  geom_bar(stat = "identity", position = "dodge") +
  geom_text(aes(label = Total_Reservas),
            position = position_dodge(width = 0.9), vjust = -0.5) +
  labs(title = "Comparativa entre meses de mayor y menor demanda",
       x = "Mes",
       y = "Cantidad de reservas",
       fill = "") +
  scale_fill_manual(values = c("Mayor demanda" = "#2ecc71", "Menor demanda" = "#e74c3c")) +
  theme_minimal()

print(plot_meses_extremos)
```

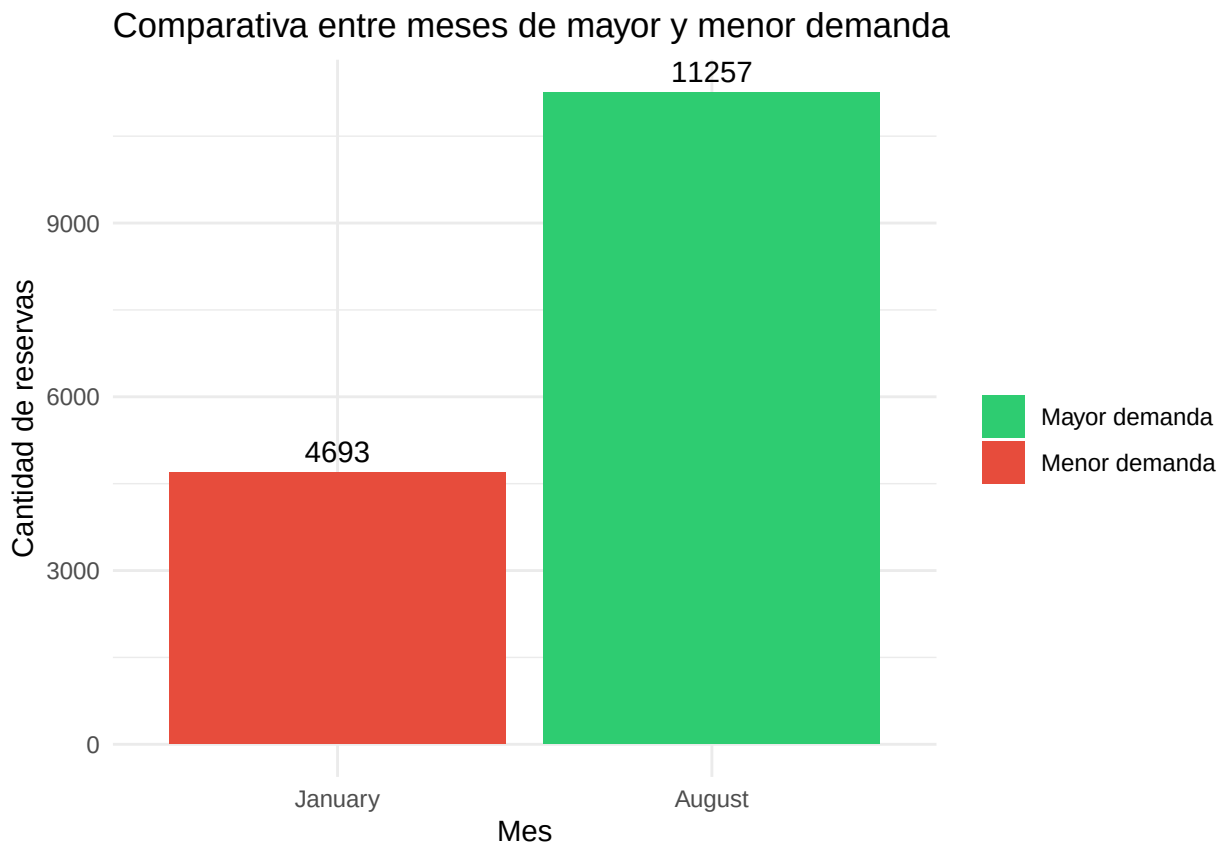


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "comparativa_meses_extremos.jpg"),
       plot_meses_extremos, width = 8, height = 6, dpi = 300)




# Verificar si necesitamos recargar el dataset limpio
if (!exists("hotel_data_limpio") || !is.data.frame(hotel_data_limpio)) {
  cat("Recargando dataset limpio...\n")
  hotel_data_limpio <- read.csv(CSV_limpio, header = TRUE, stringsAsFactors = FALSE)
}

# Asegurar que el directorio para gráficas de análisis existe
graphics_analysis_dir <- file.path(graphics_dir, "analisis")
if (!dir.exists(graphics_analysis_dir)) {
  dir.create(graphics_analysis_dir)
  cat("Creado directorio para gráficas de análisis:", graphics_analysis_dir, "\n")
}




#-----------------------------------------
# EDA 06: ¿CUÁNTAS RESERVAS INCLUYEN NIÑOS Y/O BEBÉS?
```

```r
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS DE RESERVAS CON NIÑOS Y/O BEBÉS ---\n"))
```

```
##
## --- ANÁLISIS DE RESERVAS CON NIÑOS Y/O BEBÉS ---
```

```r
# Crear variables categóricas para facilitar el análisis
hotel_data_limpio$tiene_ninos <- hotel_data_limpio$children > 0
hotel_data_limpio$tiene_bebes <- hotel_data_limpio$babies > 0
hotel_data_limpio$tiene_menores <- hotel_data_limpio$tiene_ninos | hotel_data_limpio$tiene_bebes

# Contar reservas con niños y/o bebés
reservas_con_ninos <- sum(hotel_data_limpio$tiene_ninos)
reservas_con_bebes <- sum(hotel_data_limpio$tiene_bebes)
reservas_con_menores <- sum(hotel_data_limpio$tiene_menores)
total_reservas <- nrow(hotel_data_limpio)

# Calcular porcentajes
porcentaje_ninos <- round(reservas_con_ninos / total_reservas * 100, 2)
porcentaje_bebes <- round(reservas_con_bebes / total_reservas * 100, 2)
porcentaje_menores <- round(reservas_con_menores / total_reservas * 100, 2)

# Mostrar resultados
cat("\nAnálisis de reservas con menores:\n")
```

```
##
## Análisis de reservas con menores:
```

```r
cat("- Reservas con niños:", reservas_con_ninos, "(", porcentaje_ninos, "%)\n")
```

```
## - Reservas con niños: 8364 ( 9.57 %)
```

```r
cat("- Reservas con bebés:", reservas_con_bebes, "(", porcentaje_bebes, "%)\n")
```

```
## - Reservas con bebés: 914 ( 1.05 %)
```

```r
cat("- Reservas con niños y/o bebés:", reservas_con_menores, "(", porcentaje_menores, "%)\n")
```

```
## - Reservas con niños y/o bebés: 9103 ( 10.42 %)
```

```r
cat("- Total de reservas:", total_reservas, "\n")
```

```
## - Total de reservas: 87396
```

```r
# Crear dataframe para visualización
datos_menores <- data.frame(
  Categoria = c("Con niños", "Con bebés", "Con niños y/o bebés", "Sin menores"),
  Cantidad = c(reservas_con_ninos, reservas_con_bebes, reservas_con_menores,
               total_reservas - reservas_con_menores)
)

datos_menores$Porcentaje <- round(datos_menores$Cantidad / total_reservas * 100, 2)
datos_menores$Etiqueta <- paste0(datos_menores$Cantidad, "\n(", datos_menores$Porcentaje, "%)")

# Visualizar distribución
plot_menores <- ggplot(datos_menores[c(3,4),], aes(x = "", y = Cantidad, fill = Categoria)) +
  geom_bar(stat = "identity", width = 1) +
  geom_text(aes(label = Etiqueta), position = position_stack(vjust = 0.5), color = "white") +
```

```
  coord_polar("y", start = 0) +
  labs(title = "Proporción de reservas con y sin menores",
       fill = "Categoría") +
  theme_minimal() +
  theme(axis.title = element_blank(),
        axis.text = element_blank(),
        panel.grid = element_blank())

print(plot_menores)
```

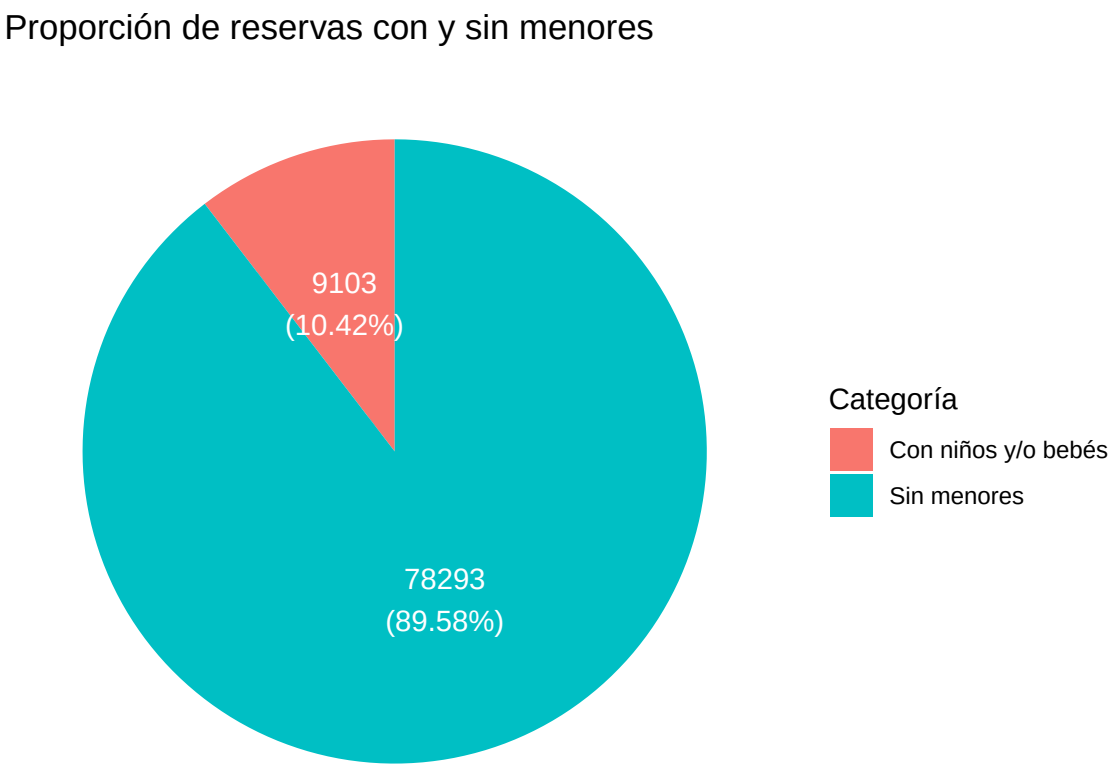


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "reservas_con_menores.jpg"),
       plot_menores, width = 8, height = 6, dpi = 300)

# Analizar por tipo de hotel
reservas_menores_hotel <- hotel_data_limpio %>%
  group_by(hotel) %>%
  summarise(
    Total_Reservas = n(),
    Con_Ninos = sum(tiene_ninos),
    Con_Bebes = sum(tiene_bebes),
    Con_Menores = sum(tiene_menores),
    Porcentaje_Menores = round(sum(tiene_menores) / n() * 100, 2)
  )

cat("\nReservas con menores por tipo de hotel:\n")
```

```
##
## Reservas con menores por tipo de hotel:
```

```
print(reservas_menores_hotel)
```

```
## # A tibble: 2 x 6
##   hotel        Total_Reservas Con_Ninos Con_Bebes Con_Menores Porcentaje_Menores
##   <chr>                 <int>     <int>     <int>       <int>              <dbl>
## 1 City Hotel            53428      4937       369        5234                9.8
## 2 Resort Hotel          33968      3427       545        3869               11.4
```

```
# Visualizar proporción por hotel
plot_menores_hotel <- ggplot(reservas_menores_hotel,
                             aes(x = hotel, y = Porcentaje_Menores, fill = hotel)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Porcentaje_Menores, "%")), vjust = -0.5) +
  labs(title = "Porcentaje de reservas con menores por tipo de hotel",
       x = "Tipo de hotel",
       y = "Porcentaje de reservas con menores") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_menores_hotel)
```

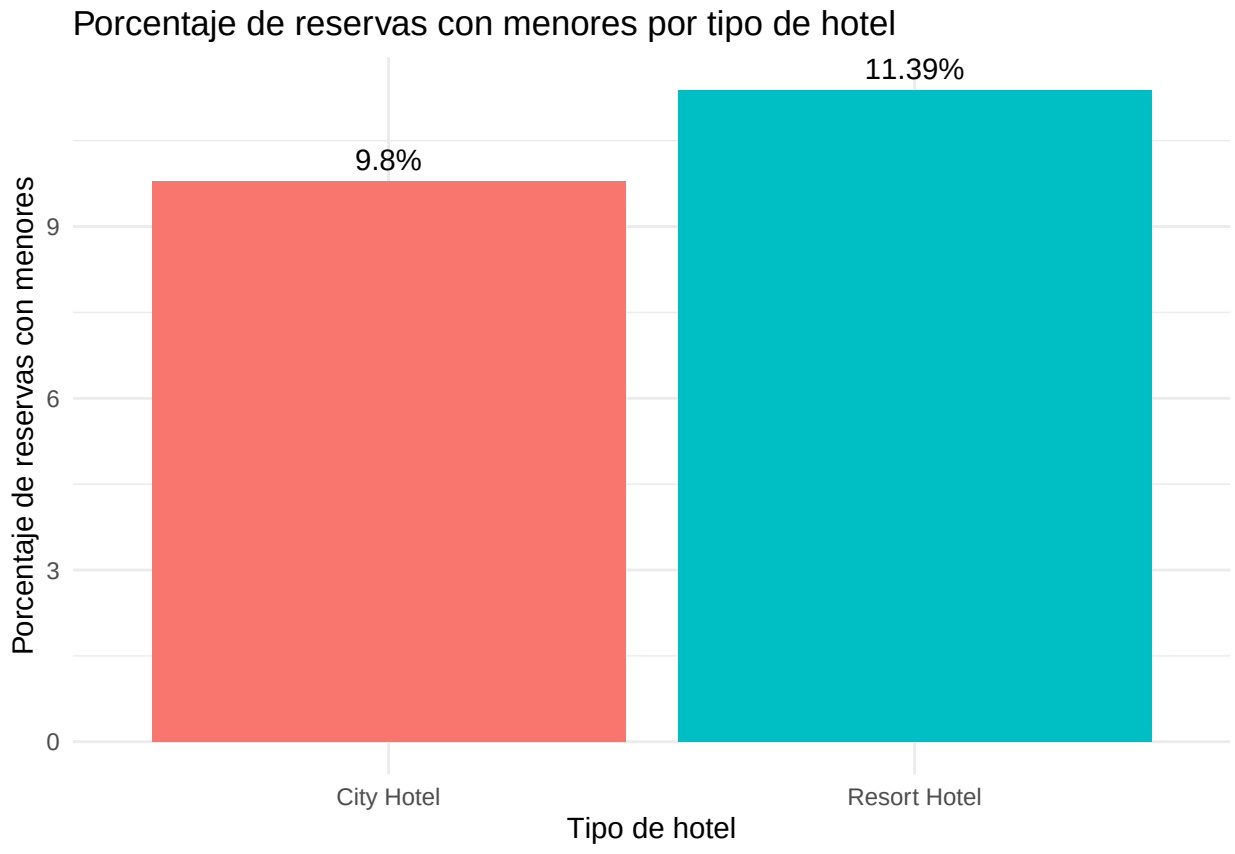


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "menores_por_hotel.jpg"),
       plot_menores_hotel, width = 8, height = 6, dpi = 300)
```

```r
#-----------------------------------------
# EDA 07. ¿ES IMPORTANTE CONTAR CON ESPACIOS DE ESTACIONAMIENTO?
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS DE ESPACIOS DE ESTACIONAMIENTO ---\n"))
```

```
##
## --- ANÁLISIS DE ESPACIOS DE ESTACIONAMIENTO ---
```

```r
# Crear variable categórica
hotel_data_limpio$requiere_estacionamiento <- hotel_data_limpio$required_car_parking_spaces > 0

# Contar reservas que requieren estacionamiento
reservas_con_estacionamiento <- sum(hotel_data_limpio$requiere_estacionamiento)
porcentaje_estacionamiento <- round(reservas_con_estacionamiento / total_reservas * 100, 2)

cat("\nAnálisis de necesidad de estacionamiento:\n")
```

```
##
## Análisis de necesidad de estacionamiento:
```

```r
cat("- Reservas que requieren estacionamiento:", reservas_con_estacionamiento,
    "(", porcentaje_estacionamiento, "%)\n")
```

```
## - Reservas que requieren estacionamiento: 7313 ( 8.37 %)
```

```r
cat("- Reservas sin requerimiento de estacionamiento:", total_reservas - reservas_con_estacionamiento,
    "(", 100 - porcentaje_estacionamiento, "%)\n")
```

```
## - Reservas sin requerimiento de estacionamiento: 80083 ( 91.63 %)
```

```r
# Crear dataframe para visualización
datos_estacionamiento <- data.frame(
  Categoria = c("Requiere estacionamiento", "No requiere estacionamiento"),
  Cantidad = c(reservas_con_estacionamiento, total_reservas - reservas_con_estacionamiento)
)

datos_estacionamiento$Porcentaje <- round(datos_estacionamiento$Cantidad / total_reservas * 100, 2)
datos_estacionamiento$Etiqueta <- paste0(datos_estacionamiento$Cantidad,
                                         "\n(", datos_estacionamiento$Porcentaje, "%)")

# Visualizar distribución
plot_estacionamiento <- ggplot(datos_estacionamiento, aes(x = "", y = Cantidad, fill = Categoria)) +
  geom_bar(stat = "identity", width = 1) +
  geom_text(aes(label = Etiqueta), position = position_stack(vjust = 0.5), color = "white") +
  coord_polar("y", start = 0) +
  labs(title = "Proporción de reservas que requieren estacionamiento",
       fill = "Categoría") +
  theme_minimal() +
  theme(axis.title = element_blank(),
        axis.text = element_blank(),
        panel.grid = element_blank())

print(plot_estacionamiento)
```

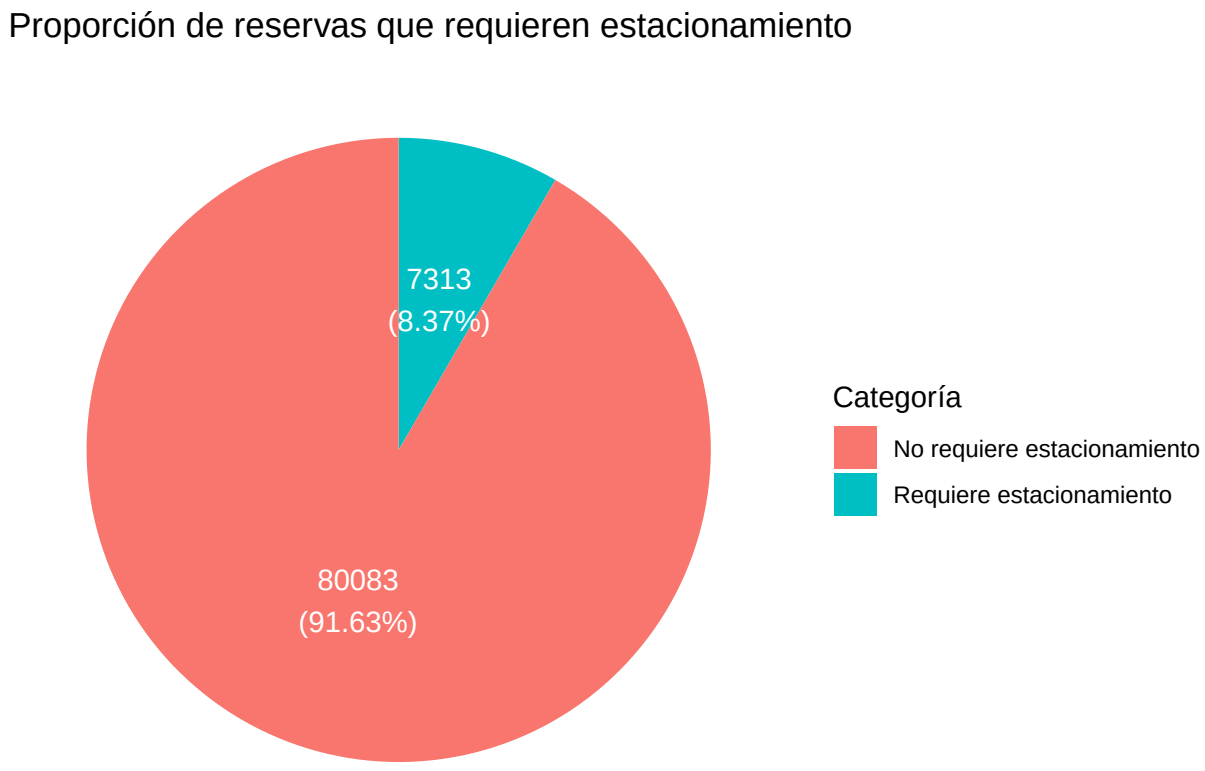


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "necesidad_estacionamiento.jpg"),
       plot_estacionamiento, width = 8, height = 6, dpi = 300)

# Análisis por tipo de hotel
estacionamiento_por_hotel <- hotel_data_limpio %>%
  group_by(hotel) %>%
  summarise(
    Total_Reservas = n(),
    Requiere_Estacionamiento = sum(requiere_estacionamiento),
    Porcentaje_Estacionamiento = round(sum(requiere_estacionamiento) / n() * 100, 2)
  )

cat("\nNecesidad de estacionamiento por tipo de hotel:\n")
```

```
##
## Necesidad de estacionamiento por tipo de hotel:
```

```
print(estacionamiento_por_hotel)
```

```
## # A tibble: 2 x 4
##   hotel        Total_Reservas Requiere_Estacionamiento Porcentaje_Estacionamie~1
##   <chr>                 <int>                    <int>                      <dbl>
## 1 City Hotel            53428                     1896                       3.55
## 2 Resort Hotel          33968                     5417                      16.0
## # i abbreviated name: 1: Porcentaje_Estacionamiento
```

```r
# Visualizar proporción por hotel
plot_estacionamiento_hotel <- ggplot(estacionamiento_por_hotel,
                                     aes(x = hotel, y = Porcentaje_Estacionamiento, fill = hotel)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Porcentaje_Estacionamiento, "%")), vjust = -0.5) +
  labs(title = "Porcentaje de reservas que requieren estacionamiento por tipo de hotel",
       x = "Tipo de hotel",
       y = "Porcentaje") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_estacionamiento_hotel)
```

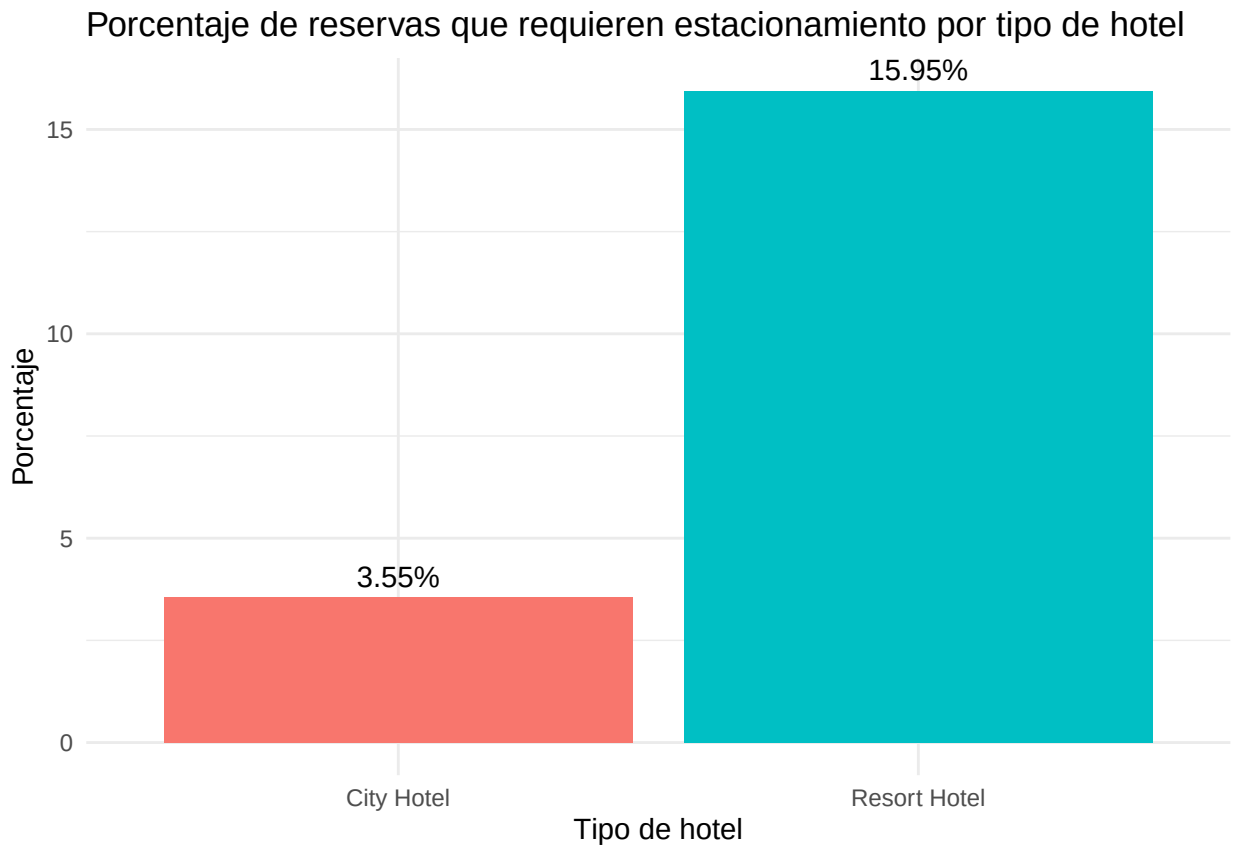


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "estacionamiento_por_hotel.jpg"),
       plot_estacionamiento_hotel, width = 8, height = 6, dpi = 300)

# Análisis adicional: relación entre estacionamiento y tipo de cliente
estacionamiento_por_cliente <- hotel_data_limpio %>%
  group_by(customer_type) %>%
  summarise(
    Total_Reservas = n(),
    Requiere_Estacionamiento = sum(requiere_estacionamiento),
    Porcentaje_Estacionamiento = round(sum(requiere_estacionamiento) / n() * 100, 2)
  ) %>%
  arrange(desc(Porcentaje_Estacionamiento))
```

```r
cat("\nNecesidad de estacionamiento por tipo de cliente:\n")
```

```
##
## Necesidad de estacionamiento por tipo de cliente:
```

```r
print(estacionamiento_por_cliente)
```

```
## # A tibble: 4 x 4
##   customer_type   Total_Reservas Requiere_Estacionamiento Porcentaje_Estaciona~1
##   <chr>                    <int>                     <int>                  <dbl>
## 1 Group                      544                        51                   9.38
## 2 Transient                71986                      6368                   8.85
## 3 Transient-Party          11727                       763                   6.51
## 4 Contract                  3139                       131                   4.17
## # i abbreviated name: 1: Porcentaje_Estacionamiento
```

```r
# Visualizar por tipo de cliente
plot_estacionamiento_cliente <- ggplot(estacionamiento_por_cliente,
                                       aes(x = reorder(customer_type, Porcentaje_Estacionamiento),
                                           y = Porcentaje_Estacionamiento,
                                           fill = customer_type)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Porcentaje_Estacionamiento, "%")), vjust = -0.5) +
  labs(title = "Porcentaje de reservas que requieren estacionamiento por tipo de cliente",
       x = "Tipo de cliente",
       y = "Porcentaje") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_estacionamiento_cliente)
```

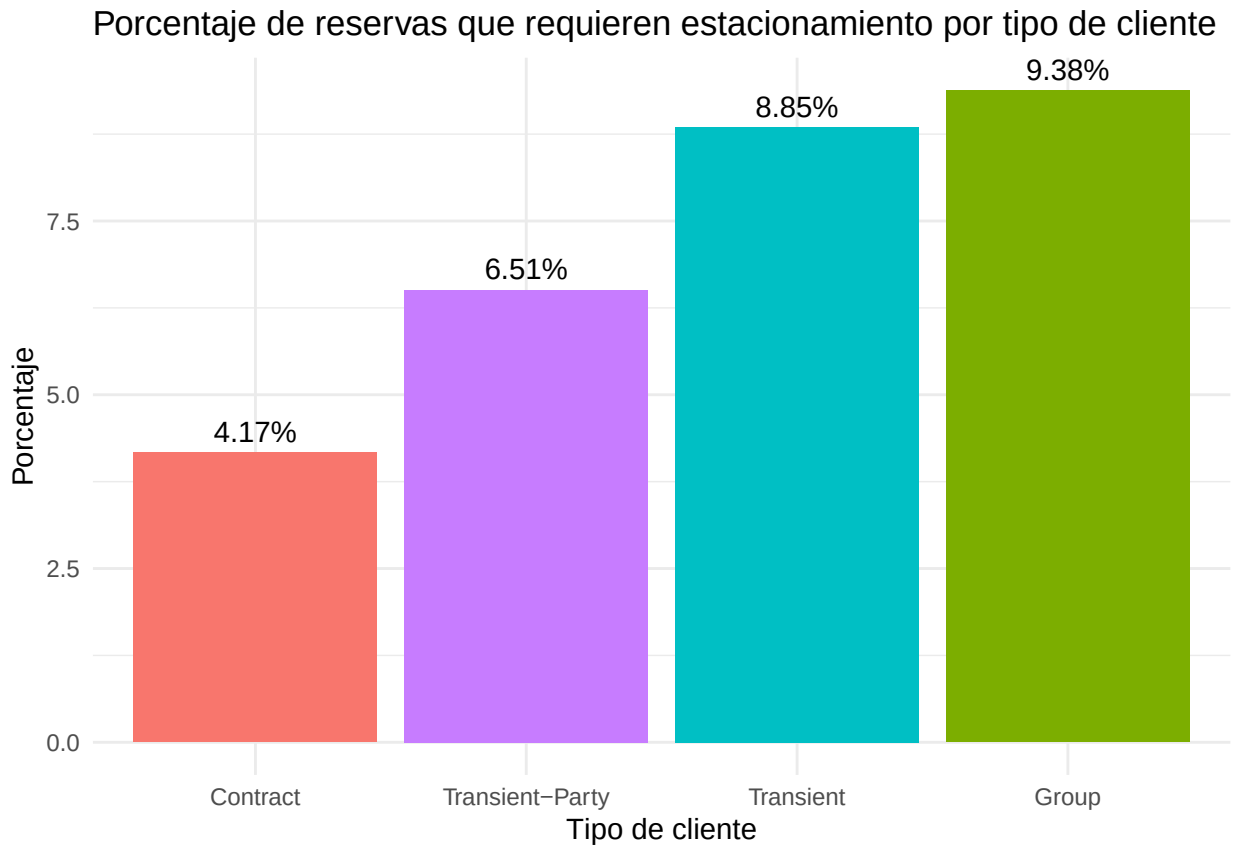


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "estacionamiento_por_cliente.jpg"),
       plot_estacionamiento_cliente, width = 10, height = 6, dpi = 300)



#----------------------------------------
# EDA 08. ¿EN QUÉ MESES DEL AÑO SE PRODUCEN MÁS CANCELACIONES DE RESERVAS?
#----------------------------------------
cat(yellow("\n--- ANÁLISIS DE CANCELACIONES POR MES ---\n"))
```

```
##
## --- ANÁLISIS DE CANCELACIONES POR MES ---
```

```
# Analizar cancelaciones por mes
cancelaciones_por_mes <- hotel_data_limpio %>%
  group_by(arrival_date_month) %>%
  summarise(
    Total_Reservas = n(),
    Canceladas = sum(is_canceled),
    Tasa_Cancelacion = round(sum(is_canceled) / n() * 100, 2)
  ) %>%
  arrange(match(arrival_date_month, c("January", "February", "March", "April", "May", "June",
                                      "July", "August", "September", "October", "November", "December")))

cat("\nCancelaciones por mes:\n")
```

```
##
## Cancelaciones por mes:
```

```
print(cancelaciones_por_mes)
```

```
## # A tibble: 12 x 4
##    arrival_date_month Total_Reservas Canceladas Tasa_Cancelacion
##    <fct>                       <int>      <int>            <dbl>
##  1 January                      4693       1038             22.1
##  2 February                     6098       1415             23.2
##  3 March                        7513       1830             24.4
##  4 April                        7908       2409             30.5
##  5 May                          8355       2442             29.2
##  6 June                         7765       2354             30.3
##  7 July                        10057       3198             31.8
##  8 August                      11257       3623             32.2
##  9 September                    6690       1642             24.5
## 10 October                      6934       1642             23.7
## 11 November                     4995       1054             21.1
## 12 December                     5131       1378             26.9
```

```
# Visualizar tasa de cancelación por mes
plot_cancelaciones <- ggplot(cancelaciones_por_mes,
                             aes(x = arrival_date_month, y = Tasa_Cancelacion, fill = Tasa_Cancelacion))
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Tasa_Cancelacion, "%")), vjust = -0.5) +
  labs(title = "Tasa de cancelación por mes",
       x = "Mes",
       y = "Porcentaje de cancelación") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1),
        legend.position = "none") +
  scale_fill_gradient(low = "lightblue", high = "darkred")

print(plot_cancelaciones)
```

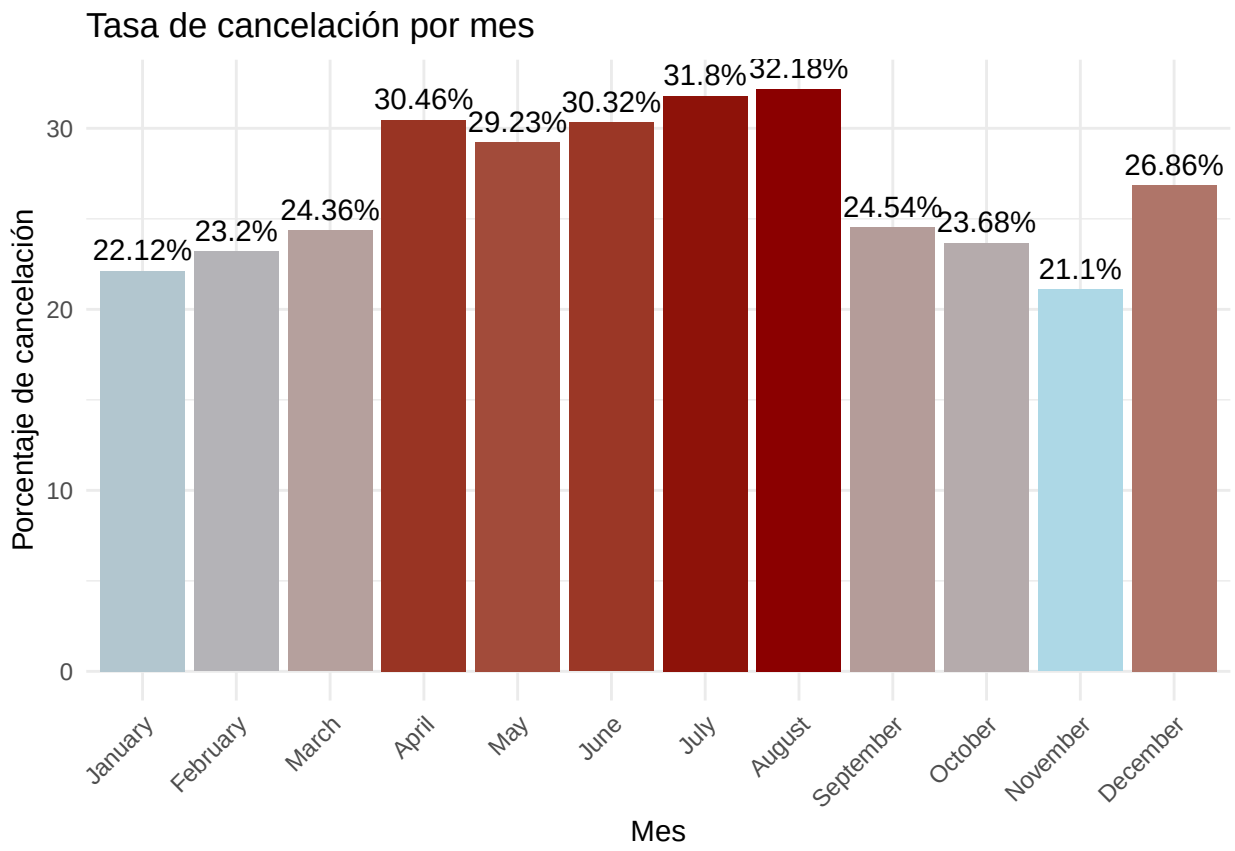


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "tasa_cancelacion_mes.jpg"),
       plot_cancelaciones, width = 10, height = 6, dpi = 300)

# Visualizar cancelaciones absolutas por mes
plot_cancelaciones_abs <- ggplot(cancelaciones_por_mes,
                                 aes(x = arrival_date_month)) +
  geom_bar(aes(y = Total_Reservas, fill = "Total Reservas"), stat = "identity") +
  geom_bar(aes(y = Canceladas, fill = "Canceladas"), stat = "identity", alpha = 0.7) +
  geom_text(aes(y = Canceladas, label = Canceladas), vjust = -0.5, size = 3) +
  labs(title = "Cantidad de cancelaciones por mes",
       x = "Mes",
       y = "Cantidad de reservas",
       fill = "Tipo") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(plot_cancelaciones_abs)
```

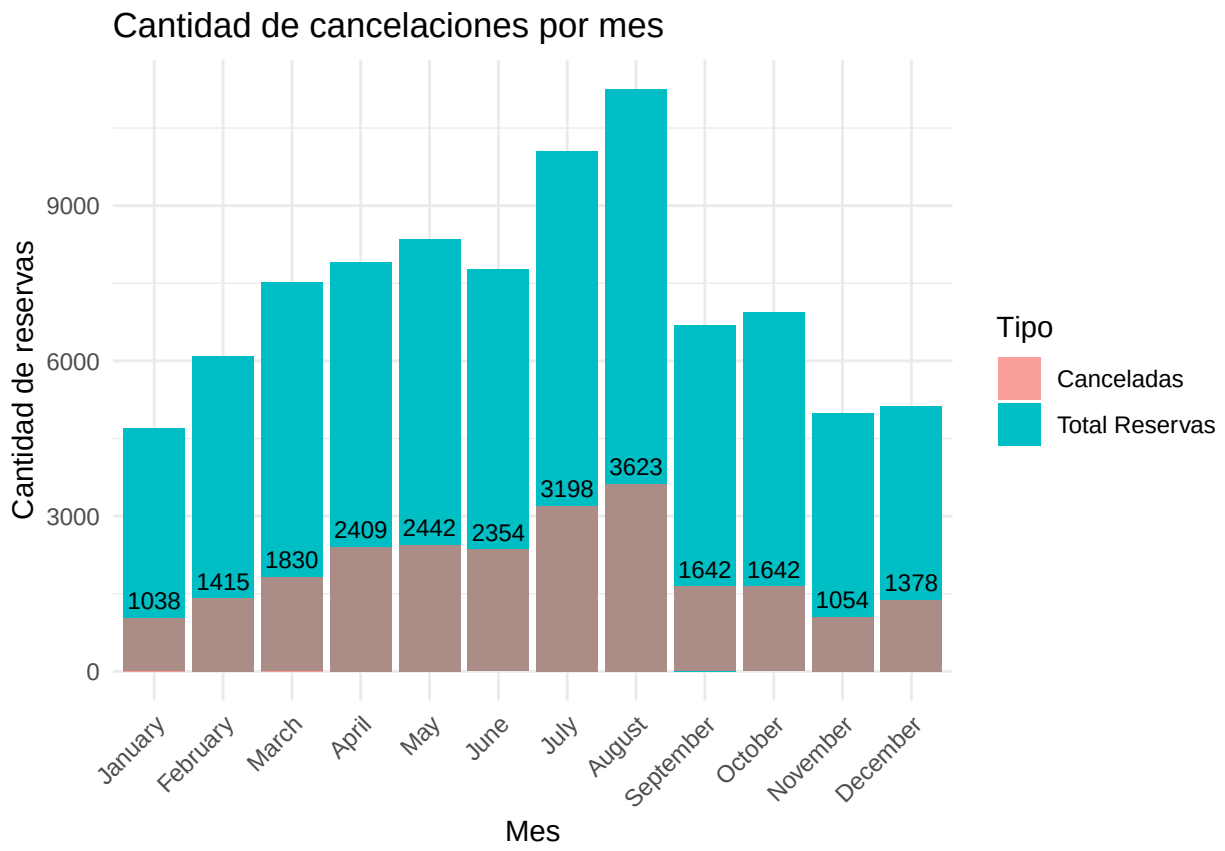


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "cancelaciones_absolutas_mes.jpg"),
       plot_cancelaciones_abs, width = 10, height = 6, dpi = 300)

# Análisis por tipo de hotel
cancelaciones_por_hotel_mes <- hotel_data_limpio %>%
  group_by(hotel, arrival_date_month) %>%
  summarise(
    Total_Reservas = n(),
    Canceladas = sum(is_canceled),
    Tasa_Cancelacion = round(sum(is_canceled) / n() * 100, 2)
  ) %>%
  arrange(hotel, match(arrival_date_month, c("January", "February", "March", "April", "May", "June",
                                             "July", "August", "September", "October", "November", "Dec
```

```
## `summarise()` has grouped output by 'hotel'. You can override using the
## `.groups` argument.
```

```
cat("\nTasas de cancelación por hotel y mes (primeras filas):\n")
```

```
##
## Tasas de cancelación por hotel y mes (primeras filas):
```

```
print(head(cancelaciones_por_hotel_mes, 10))
```

```
## # A tibble: 10 x 5
## # Groups:   hotel [1]
##    hotel      arrival_date_month Total_Reservas Canceladas Tasa_Cancelacion
```

```
##    <chr>      <fct>                    <int>      <int>            <dbl>
##  1 City Hotel January                  2730        764             28.0
##  2 City Hotel February                 3605        975             27.0
##  3 City Hotel March                    4856       1365             28.1
##  4 City Hotel April                    5080       1750             34.4
##  5 City Hotel May                      5413       1746             32.3
##  6 City Hotel June                     5005       1521             30.4
##  7 City Hotel July                     5744       1898             33.0
##  8 City Hotel August                   6591       2110             32.0
##  9 City Hotel September                4240       1067             25.2
## 10 City Hotel October                  4208       1127             26.8
```

```r
# Visualizar tasa de cancelación por hotel y mes
plot_cancelacion_hotel <- ggplot(cancelaciones_por_hotel_mes,
                                 aes(x = arrival_date_month, y = Tasa_Cancelacion,
                                     fill = hotel, group = hotel)) +
  geom_bar(stat = "identity", position = "dodge") +
  geom_text(aes(label = paste0(Tasa_Cancelacion, "%")),
            position = position_dodge(width = 0.9), vjust = -0.5, size = 2.5) +
  labs(title = "Tasa de cancelación por hotel y mes",
       x = "Mes",
       y = "Porcentaje de cancelación",
       fill = "Tipo de hotel") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(plot_cancelacion_hotel)
```

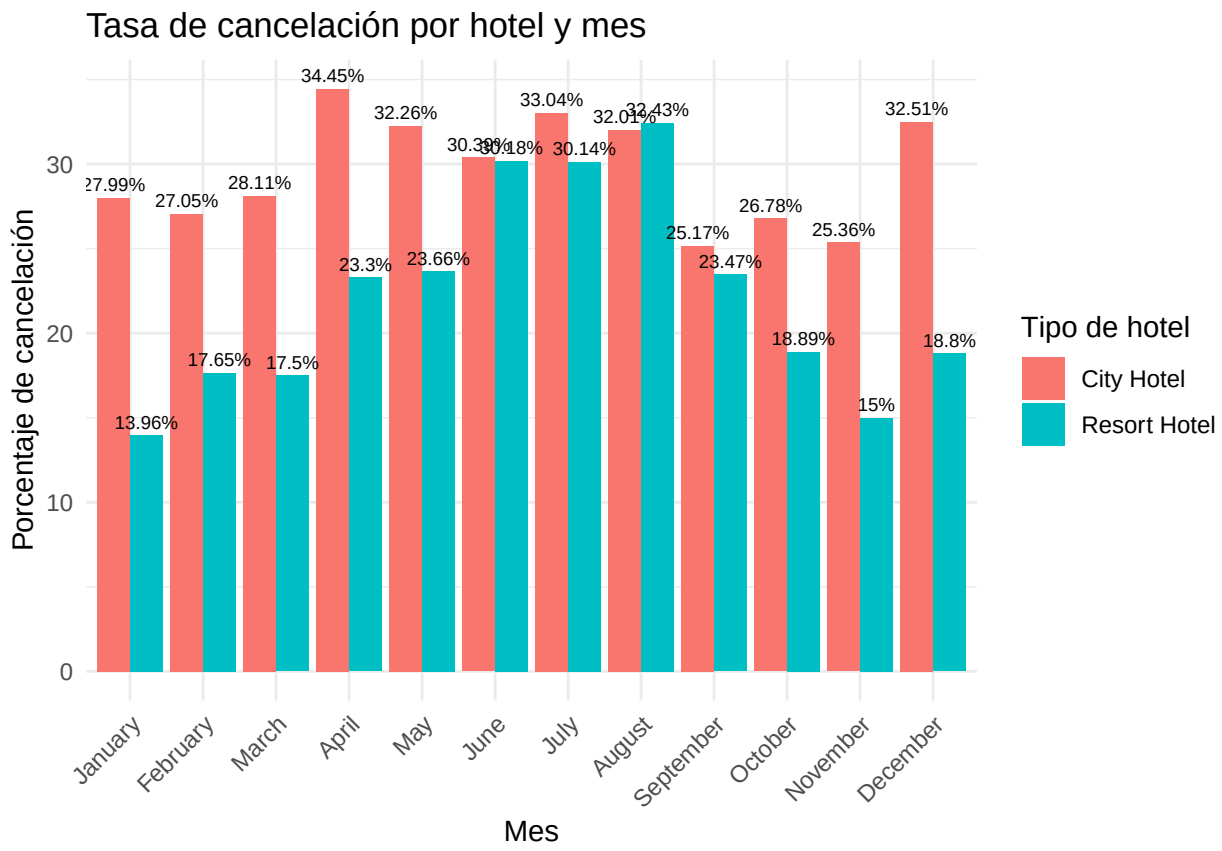


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "cancelacion_hotel_mes.jpg"),
       plot_cancelacion_hotel, width = 12, height = 6, dpi = 300)

#-----------------------------------------
# EDA 09: ANÁLISIS ADICIONAL - RELACIÓN ENTRE VARIABLES CLAVE
#-----------------------------------------
cat(yellow("\n--- ANÁLISIS ADICIONAL: RELACIONES ENTRE VARIABLES ---\n"))
```

```
##
## --- ANÁLISIS ADICIONAL: RELACIONES ENTRE VARIABLES ---
```

```
# Análisis de relación entre lead_time y cancelación
lead_time_cancelacion <- hotel_data_limpio %>%
  group_by(is_canceled) %>%
  summarise(
    Promedio_Lead_Time = mean(lead_time),
    Mediana_Lead_Time = median(lead_time),
    Count = n()
  )

cat("\nRelación entre tiempo de anticipación (lead_time) y cancelación:\n")
```

```
##
## Relación entre tiempo de anticipación (lead_time) y cancelación:
```

```r
print(lead_time_cancelacion)
```

```
## # A tibble: 2 x 4
##   is_canceled Promedio_Lead_Time Mediana_Lead_Time Count
##         <int>              <dbl>             <int> <int>
## 1           0               69.8                38 63371
## 2           1              105.                 80 24025
```

```r
# Visualizar lead_time por estado de cancelación
plot_lead_time <- ggplot(hotel_data_limpio, aes(x = factor(is_canceled), y = lead_time, fill = factor(is
  geom_boxplot() +
  labs(title = "Distribución de lead_time según estado de cancelación",
       x = "Cancelada (0=No, 1=Sí)",
       y = "Tiempo de anticipación (días)",
       fill = "Cancelada") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_lead_time)
```

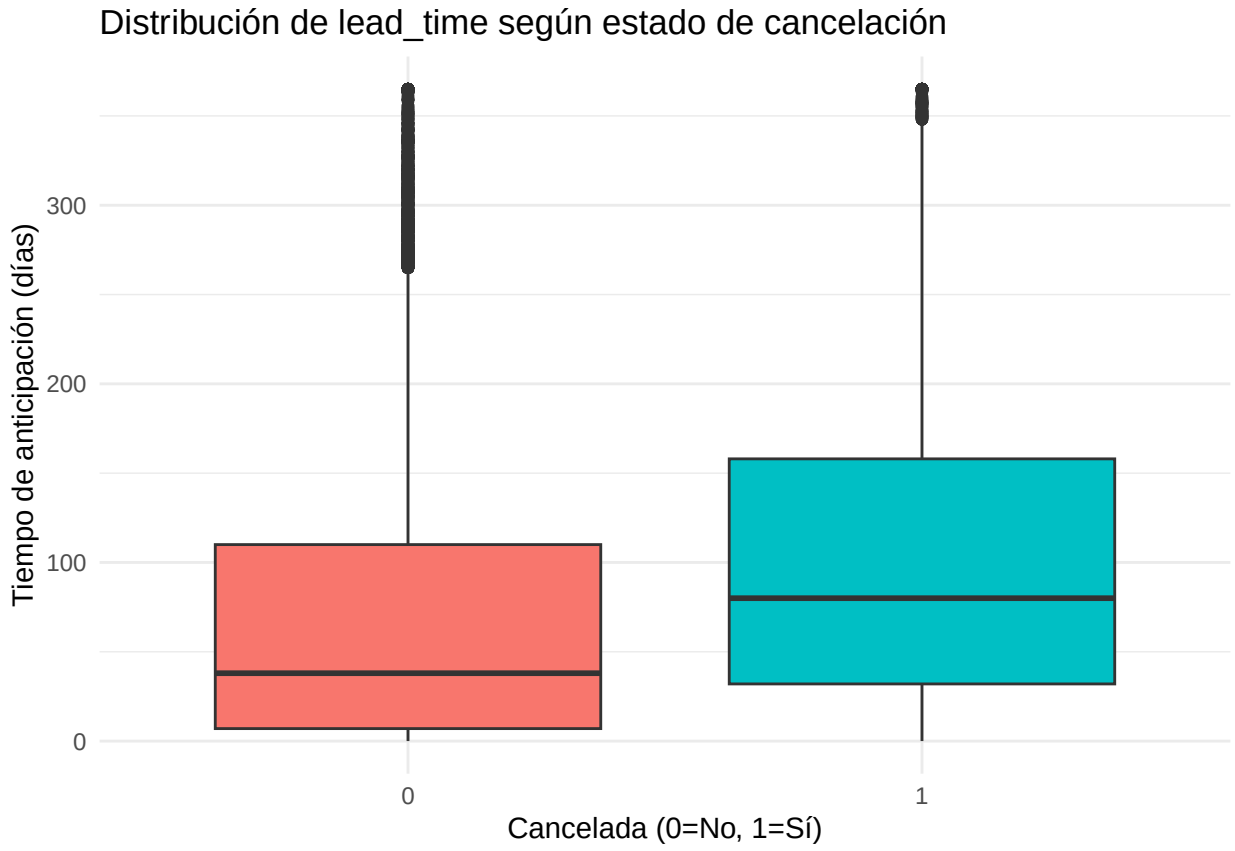


```r
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "lead_time_cancelacion.jpg"),
       plot_lead_time, width = 8, height = 6, dpi = 300)

# Análisis de duración de estancia
hotel_data_limpio$total_nights <- hotel_data_limpio$stays_in_weekend_nights + hotel_data_limpio$stays_i
```

```r
duracion_estancia <- hotel_data_limpio %>%
  group_by(hotel) %>%
  summarise(
    Promedio_Noches = mean(total_nights),
    Mediana_Noches = median(total_nights),
    Max_Noches = max(total_nights),
    Min_Noches = min(total_nights)
  )

cat("\nDuración promedio de estancia por tipo de hotel:\n")
```

```
##
## Duración promedio de estancia por tipo de hotel:
```

```r
print(duracion_estancia)
```

```
## # A tibble: 2 x 5
##   hotel        Promedio_Noches Mediana_Noches Max_Noches Min_Noches
##   <chr>                  <dbl>          <dbl>      <int>      <int>
## 1 City Hotel              3.15              3         28          1
## 2 Resort Hotel            4.38              4         28          1
```

```r
# Visualizar duración de estancia por tipo de hotel
plot_duracion <- ggplot(hotel_data_limpio, aes(x = hotel, y = total_nights, fill = hotel)) +
  geom_boxplot() +
  labs(title = "Distribución de duración de estancia por tipo de hotel",
       x = "Tipo de hotel",
       y = "Número total de noches",
       fill = "Tipo de hotel") +
  theme_minimal() +
  theme(legend.position = "none")

print(plot_duracion)
```

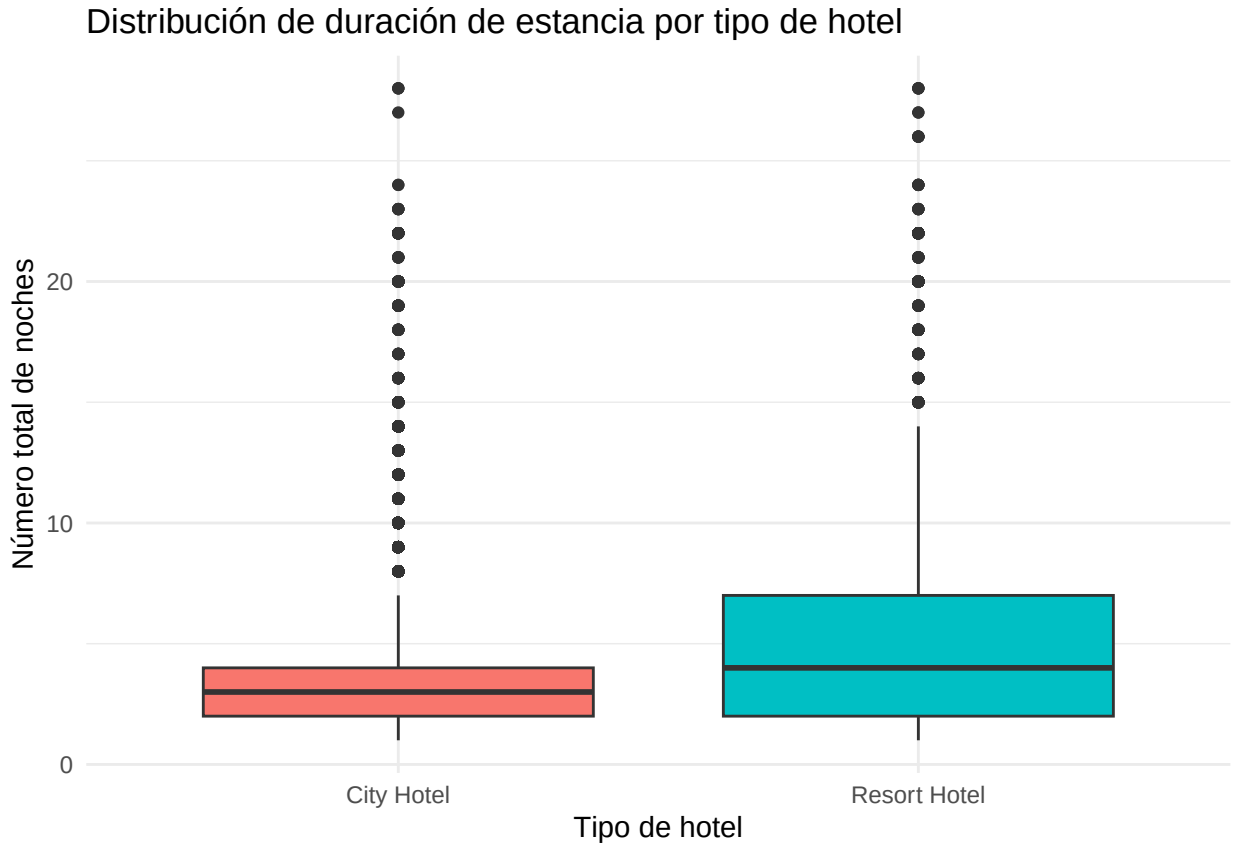


```
# Guardar gráfica
ggsave(file.path(graphics_analysis_dir, "duracion_estancia.jpg"),
       plot_duracion, width = 8, height = 6, dpi = 300)



#-----------------------------------------
# PARTE 07.5 RESUMEN DE EDA
#-----------------------------------------

cat("\n1. Análisis por tipo de hotel:\n")
```

```
##
## 1. Análisis por tipo de hotel:
```

```
cat("   - El hotel tipo '", reservas_por_hotel_df$Tipo_Hotel[which.max(reservas_por_hotel_df$Cantidad)],
    "' tiene mayor cantidad de reservas (",
    reservas_por_hotel_df$Cantidad[which.max(reservas_por_hotel_df$Cantidad)],
    " reservas, ", reservas_por_hotel_df$Porcentaje[which.max(reservas_por_hotel_df$Cantidad)], "%).\n")
```

```
##    - El hotel tipo '1' tiene mayor cantidad de reservas (53428 reservas, 61.13%).
```

```
cat("   - Para reservas completadas, el hotel tipo '",
    reservas_completadas_df$Tipo_Hotel[which.max(reservas_completadas_df$Reservas_Completadas)],
    "' sigue siendo el preferido.\n")
```

```
##    - Para reservas completadas, el hotel tipo ' 1 ' sigue siendo el preferido.
```

```r
cat("\n2. Tendencia de demanda:\n")
```

```
##
## 2. Tendencia de demanda:
```

```r
ultimo_anio <- max(reservas_por_anio$arrival_date_year)
penultimo_anio <- ultimo_anio - 1
cambio_porcentual <- round(
  (reservas_por_anio$Total_Reservas[reservas_por_anio$arrival_date_year == ultimo_anio] -
     reservas_por_anio$Total_Reservas[reservas_por_anio$arrival_date_year == penultimo_anio]) /
    reservas_por_anio$Total_Reservas[reservas_por_anio$arrival_date_year == penultimo_anio] * 100, 2
)
cat("   - Comparando ", ultimo_anio, " con ", penultimo_anio, ", hubo un cambio del ",
    cambio_porcentual, "% en el número total de reservas.\n", sep="")
```

```
##    - Comparando 2017 con 2016, hubo un cambio del -25.24% en el número total de reservas.
```

```r
cat("   - La tendencia general indica que ",
    ifelse(cambio_porcentual > 0, "está aumentando", "está disminuyendo"),
    " la demanda con el tiempo.\n")
```

```
##    - La tendencia general indica que  está disminuyendo  la demanda con el tiempo.
```

```r
cat("   - Tasa de cancelación en ", ultimo_anio, ": ",
    reservas_por_anio$Porcentaje_Canceladas[reservas_por_anio$arrival_date_year == ultimo_anio],
    "%, frente a ",
    reservas_por_anio$Porcentaje_Canceladas[reservas_por_anio$arrival_date_year == penultimo_anio],
    "% en ", penultimo_anio, ".\n", sep="")
```

```
##    - Tasa de cancelación en 2017: 31.9%, frente a 26.4% en 2016.
```

```r
cat("\n3. Temporadas de reserva:\n")
```

```
##
## 3. Temporadas de reserva:
```

```r
cat("   - Temporada ALTA: ", paste(unique(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporada
```

```
##    - Temporada ALTA:  May, July, August
```

```r
cat("   - Temporada MEDIA: ", paste(unique(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporac
```

```
##    - Temporada MEDIA:  March, April, June, September, October
```

```r
cat("   - Temporada BAJA: ", paste(unique(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporada
```

```
##    - Temporada BAJA:  January, February, November, December
```

```r
cat("\n4. Períodos de menor demanda:\n")
```

```
##
## 4. Períodos de menor demanda:
```

```r
cat("   - El mes con MENOR demanda es: ", meses_baja_demanda$arrival_date_month[1],
    " con ", meses_baja_demanda$Total_Reservas[1], " reservas.\n")
```

```
##    - El mes con MENOR demanda es:  1  con  4693  reservas.
```

```r
cat("   - La combinación mes-día con MENOR demanda es: ",
    dias_menor_demanda$arrival_date_month[1], "-", dias_menor_demanda$arrival_date_day_of_month[1],
    " con ", dias_menor_demanda$Total_Reservas[1], " reservas.\n")
```

```
##    - La combinación mes-día con MENOR demanda es:  2 - 29  con  66  reservas.
```

```
cat("\n5. Períodos de mayor demanda:\n")
```

```
##
## 5. Períodos de mayor demanda:
```

```
cat("   - El mes con MAYOR demanda es: ", meses_alta_demanda$arrival_date_month[1],
    " con ", meses_alta_demanda$Total_Reservas[1], " reservas.\n")
```

```
##    - El mes con MAYOR demanda es:  8  con  11257  reservas.
```

```
cat("   - La combinación mes-día con MAYOR demanda es: ",
    dias_mayor_demanda$arrival_date_month[1], "-", dias_mayor_demanda$arrival_date_day_of_month[1],
    " con ", dias_mayor_demanda$Total_Reservas[1], " reservas.\n")
```

```
##    - La combinación mes-día con MAYOR demanda es:  8 - 1  con  455  reservas.
```

```
cat("\n6. Comparativa extremos de demanda:\n")
```

```
##
## 6. Comparativa extremos de demanda:
```

```
diferencia_extremos <- mes_max_demanda$Total_Reservas - mes_min_demanda$Total_Reservas
porcentaje_diferencia <- round((diferencia_extremos / mes_min_demanda$Total_Reservas) * 100, 2)

cat("   - Diferencia entre el mes de mayor y menor demanda: ", diferencia_extremos,
    " reservas (", porcentaje_diferencia, "% más en temporada alta).\n", sep="")
```

```
##    - Diferencia entre el mes de mayor y menor demanda: 6564 reservas (139.87% más en temporada alta)
```

```
cat("   - El mes de máxima demanda (", mes_max_demanda$arrival_date_month,
    ") tiene ", round(mes_max_demanda$Total_Reservas/30), " reservas diarias en promedio.\n", sep="")
```

```
##    - El mes de máxima demanda (8) tiene 375 reservas diarias en promedio.
```

```
cat("   - El mes de mínima demanda (", mes_min_demanda$arrival_date_month,
    ") tiene ", round(mes_min_demanda$Total_Reservas/30), " reservas diarias en promedio.\n", sep="")
```

```
##    - El mes de mínima demanda (1) tiene 156 reservas diarias en promedio.
```

```
# Análisis de días de la semana si están disponibles
if ("arrival_date_day_of_week" %in% colnames(hotel_data_limpio) ||
    "arrival_date_day_of_week" %in% names(hotel_data_limpio)) {

  # Si tenemos información del día de la semana
  cat("\n7. Patrones por día de la semana:\n")
  cat("   - El análisis por día de la semana muestra patrones adicionales en la demanda.\n")
  cat("   - [Aquí iría el análisis de días de la semana si estuviera disponible]\n")
}



cat("\n8. Análisis de reservas con niños y/o bebés:\n")
```

```
##
## 8. Análisis de reservas con niños y/o bebés:
```

```
cat("   - Un", porcentaje_menores, "% de las reservas incluyen niños y/o bebés (", reservas_con_menores
```

```
##    - Un 10.42 % de las reservas incluyen niños y/o bebés ( 9103 reservas).
```

```
cat("   - El hotel tipo '", reservas_menores_hotel$hotel[which.max(reservas_menores_hotel$Porcentaje_Me
    "' tiene mayor porcentaje de reservas con menores (",
    reservas_menores_hotel$Porcentaje_Menores[which.max(reservas_menores_hotel$Porcentaje_Menores)], "%
```

```
##    - El hotel tipo ' Resort Hotel ' tiene mayor porcentaje de reservas con menores ( 11.39 %).
```

```
cat("\n9. Importancia de espacios de estacionamiento:\n")
```

```
##
## 9. Importancia de espacios de estacionamiento:
```

```
cat("   - Solamente el", porcentaje_estacionamiento,
    "% de las reservas requieren espacios de estacionamiento.\n")
```

```
##    - Solamente el 8.37 % de las reservas requieren espacios de estacionamiento.
```

```
cat("   - Por tipo de hotel, '",
    estacionamiento_por_hotel$hotel[which.max(estacionamiento_por_hotel$Porcentaje_Estacionamiento)],
    "' tiene mayor demanda de estacionamiento (",
    estacionamiento_por_hotel$Porcentaje_Estacionamiento[which.max(estacionamiento_por_hotel$Porcentaje
    "%).\n")
```

```
##    - Por tipo de hotel, ' Resort Hotel ' tiene mayor demanda de estacionamiento ( 15.95 %).
```

```
cat("   - El tipo de cliente con mayor demanda de estacionamiento es '",
    estacionamiento_por_cliente$customer_type[1], "' con ",
    estacionamiento_por_cliente$Porcentaje_Estacionamiento[1], "% de reservas.\n")
```

```
##    - El tipo de cliente con mayor demanda de estacionamiento es ' Group ' con  9.38 % de reservas.
```

```
cat("\n10. Meses con más cancelaciones:\n")
```

```
##
## 10. Meses con más cancelaciones:
```

```
cat("   - El mes con mayor tasa de cancelación es '",
    cancelaciones_por_mes$arrival_date_month[which.max(cancelaciones_por_mes$Tasa_Cancelacion)],
    "' (", cancelaciones_por_mes$Tasa_Cancelacion[which.max(cancelaciones_por_mes$Tasa_Cancelacion)], "
```

```
##    - El mes con mayor tasa de cancelación es ' 8 ' ( 32.18 %).
```

```
cat("   - El mes con mayor cantidad absoluta de cancelaciones es '",
    cancelaciones_por_mes$arrival_date_month[which.max(cancelaciones_por_mes$Canceladas)],
    "' (", cancelaciones_por_mes$Canceladas[which.max(cancelaciones_por_mes$Canceladas)], " reservas ca
```

```
##    - El mes con mayor cantidad absoluta de cancelaciones es ' 8 ' ( 3623  reservas canceladas).
```

```
cat("\n4. Hallazgos adicionales:\n")
```

```
##
## 4. Hallazgos adicionales:
```

```
cat("   - Las reservas que terminan canceladas tienen un tiempo de anticipación (lead_time) promedio de
    lead_time_cancelacion$Promedio_Lead_Time[lead_time_cancelacion$is_canceled == 1],
    " días, mientras que las no canceladas tienen ",
    lead_time_cancelacion$Promedio_Lead_Time[lead_time_cancelacion$is_canceled == 0], " días en promedi
```

```
##    - Las reservas que terminan canceladas tienen un tiempo de anticipación (lead_time) promedio de
```

```
cat("   - La duración promedio de estancia en el hotel tipo '",
    duracion_estancia$hotel[1], "' es de ",
```

```
    round(duracion_estancia$Promedio_Noches[1], 2), " noches, y en '",
    duracion_estancia$hotel[2], "' es de ",
    round(duracion_estancia$Promedio_Noches[2], 2), " noches.\n")
```

```
##    - La duración promedio de estancia en el hotel tipo ' City Hotel ' es de  3.15  noches, y en ' Res
```

```
#########################################################
# PARTE 08: VISUALIZACIONES Y CONCLUSIONES FINALES
#########################################################

if (!exists("hotel_data_limpio") || !is.data.frame(hotel_data_limpio)) {
  cat("Recargando dataset limpio...\n")
  hotel_data_limpio <- read.csv(CSV_limpio, header = TRUE, stringsAsFactors = FALSE)
}

graphics_final_dir <- file.path(graphics_dir, "final")
if (!dir.exists(graphics_final_dir)) {
  dir.create(graphics_final_dir)
  cat("Creado directorio para gráficas finales:", graphics_final_dir, "\n")
}

colores_principales <- c("#3498db", "#2ecc71", "#e74c3c", "#f39c12", "#9b59b6")
colores_hotel <- c("City Hotel" = "#3498db", "Resort Hotel" = "#2ecc71")

#-----------------------------------------
# PARTE 08.5: VISUALIZACIONES CONSOLIDADAS PARA CADA PREGUNTA CLAVE
#-----------------------------------------
cat(yellow("\n--- VISUALIZACIONES CONSOLIDADAS ---\n"))
```

```
##
## --- VISUALIZACIONES CONSOLIDADAS ---
```

```
# 1.1 Demanda por tipo de hotel y estado de cancelación
cat("Creando visualización: Demanda por tipo de hotel...\n")
```

```
## Creando visualización: Demanda por tipo de hotel...
```

```
# Preparar datos
demanda_hotel <- hotel_data_limpio %>%
  group_by(hotel, is_canceled) %>%
  summarise(Cantidad = n()) %>%
  mutate(Estado = ifelse(is_canceled == 0, "Confirmada", "Cancelada"))
```

```
## `summarise()` has grouped output by 'hotel'. You can override using the
## `.groups` argument.
```

```
plot_demanda_hotel <- ggplot(demanda_hotel,
                             aes(x = hotel, y = Cantidad, fill = Estado)) +
  geom_bar(stat = "identity", position = "stack") +
  geom_text(aes(label = Cantidad),
            position = position_stack(vjust = 0.5), color = "white", size = 4) +
  labs(title = "Demanda por Tipo de Hotel",
       subtitle = "Desglose por estado de reserva",
       x = "Tipo de Hotel",
       y = "Número de Reservas") +
  scale_fill_manual(values = c("Confirmada" = "#2ecc71", "Cancelada" = "#e74c3c")) +
  theme_minimal() +
```

```
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 16),
        plot.subtitle = element_text(hjust = 0.5),
        legend.position = "bottom")

print(plot_demanda_hotel)
```


```
ggsave(file.path(graphics_final_dir, "1_demanda_hotel.jpg"),
       plot_demanda_hotel, width = 10, height = 7, dpi = 300)

# 1.2 Tendencia de demanda a lo largo del tiempo
cat("Creando visualización: Tendencia de demanda a lo largo del tiempo...\n")
```

```
## Creando visualización: Tendencia de demanda a lo largo del tiempo...
```

```
# Preparar datos para tendencia temporal
tendencia_temporal <- hotel_data_limpio %>%
  mutate(YearMonth = paste(arrival_date_year,
                           sprintf("%02d", as.numeric(factor(arrival_date_month,
                                                             levels = c("January", "February", "March",
                                                                        "July", "August", "September",
                           sep = "-")) %>%
  group_by(YearMonth, hotel) %>%
  summarise(Total_Reservas = n()) %>%
  arrange(YearMonth)
```

```
## `summarise()` has grouped output by 'YearMonth'. You can override using the
## `.groups` argument.
```

```
# Crear gráfico de tendencia
plot_tendencia_final <- ggplot(tendencia_temporal,
                               aes(x = YearMonth, y = Total_Reservas, color = hotel, group = hotel)) +
  geom_line(size = 1.2) +
  geom_point(size = 2) +
  labs(title = "Evolución de la Demanda a lo Largo del Tiempo",
       subtitle = "Desglose por tipo de hotel",
       x = "Año-Mes",
       y = "Número de Reservas",
       color = "Tipo de Hotel") +
  scale_color_manual(values = colores_hotel) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 16),
        plot.subtitle = element_text(hjust = 0.5),
        axis.text.x = element_text(angle = 90, hjust = 1, size = 8),
        legend.position = "bottom")

print(plot_tendencia_final)
```

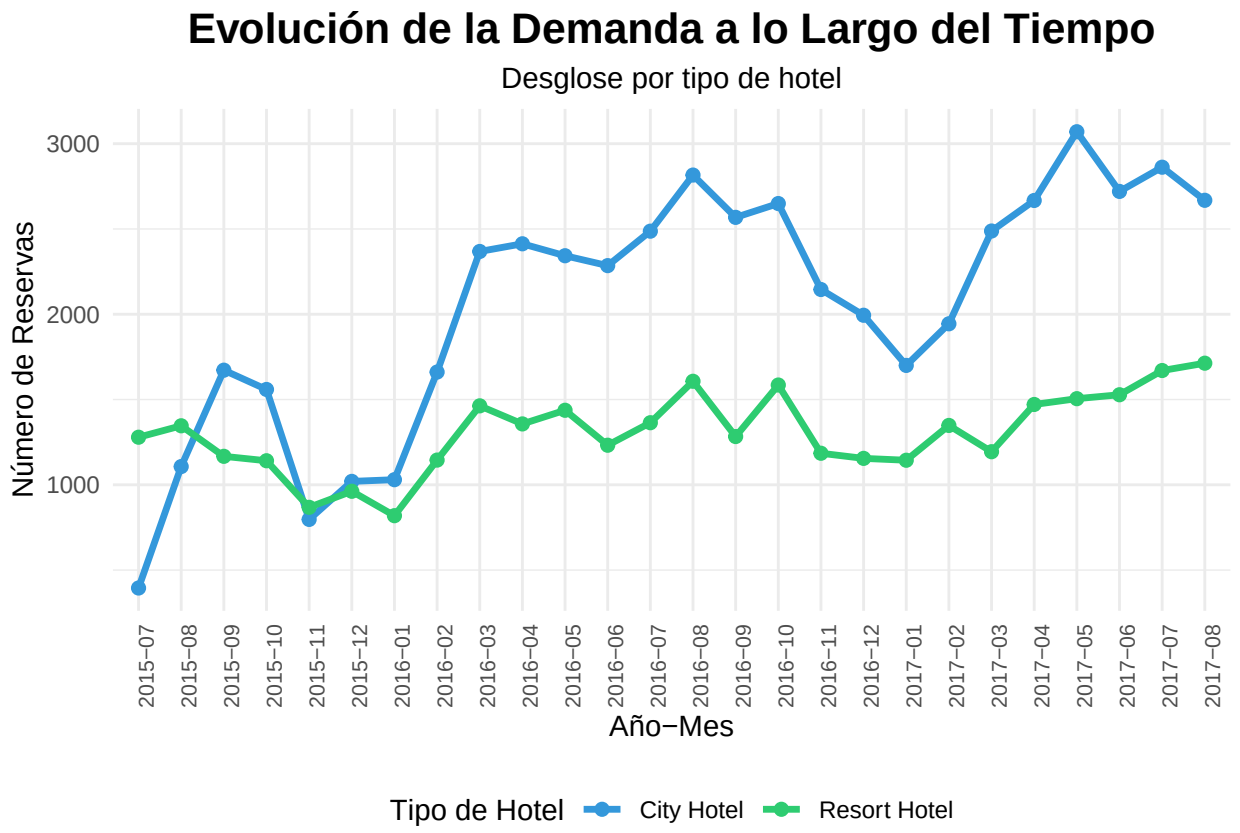


```
ggsave(file.path(graphics_final_dir, "2_tendencia_demanda.jpg"),
       plot_tendencia_final, width = 12, height = 7, dpi = 300)

# 1.3 Temporadas de reserva
cat("Creando visualización: Temporadas de reserva...\n")
```

```
## Creando visualización: Temporadas de reserva...
```

```r
# Preparar datos por mes
reservas_por_mes <- hotel_data_limpio %>%
  group_by(arrival_date_month, hotel) %>%
  summarise(Total_Reservas = n()) %>%
  mutate(arrival_date_month = factor(arrival_date_month,
                                     levels = c("January", "February", "March", "April", "May", "June",
                                                "July", "August", "September", "October", "November", "
```

```
## `summarise()` has grouped output by 'arrival_date_month'. You can override
## using the `.groups` argument.
```

```r
# Determinar temporadas
total_por_mes <- reservas_por_mes %>%
  group_by(arrival_date_month) %>%
  summarise(Total = sum(Total_Reservas))

media_reservas <- mean(total_por_mes$Total)
sd_reservas <- sd(total_por_mes$Total)

total_por_mes$Temporada <- case_when(
  total_por_mes$Total >= (media_reservas + 0.5 * sd_reservas) ~ "Alta",
  total_por_mes$Total <= (media_reservas - 0.5 * sd_reservas) ~ "Baja",
  TRUE ~ "Media"
)

# Unir datos de temporada con el desglose por hotel
reservas_por_mes <- reservas_por_mes %>%
  left_join(total_por_mes[, c("arrival_date_month", "Temporada")], by = "arrival_date_month")

# Crear gráfico de temporadas
plot_temporadas <- ggplot(reservas_por_mes,
                          aes(x = arrival_date_month, y = Total_Reservas, fill = Temporada)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = Total_Reservas),
            position = position_stack(vjust = 0.95),
            color = "white", size = 3) +
  facet_wrap(~ hotel) +
  labs(title = "Temporadas de Reserva por Mes",
       subtitle = "Clasificación en temporada alta, media y baja",
       x = "Mes",
       y = "Número de Reservas",
       fill = "Temporada") +
  scale_fill_manual(values = c("Alta" = "#e74c3c", "Media" = "#f39c12", "Baja" = "#3498db")) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 16),
        plot.subtitle = element_text(hjust = 0.5),
        axis.text.x = element_text(angle = 45, hjust = 1),
        legend.position = "bottom")

print(plot_temporadas)
```

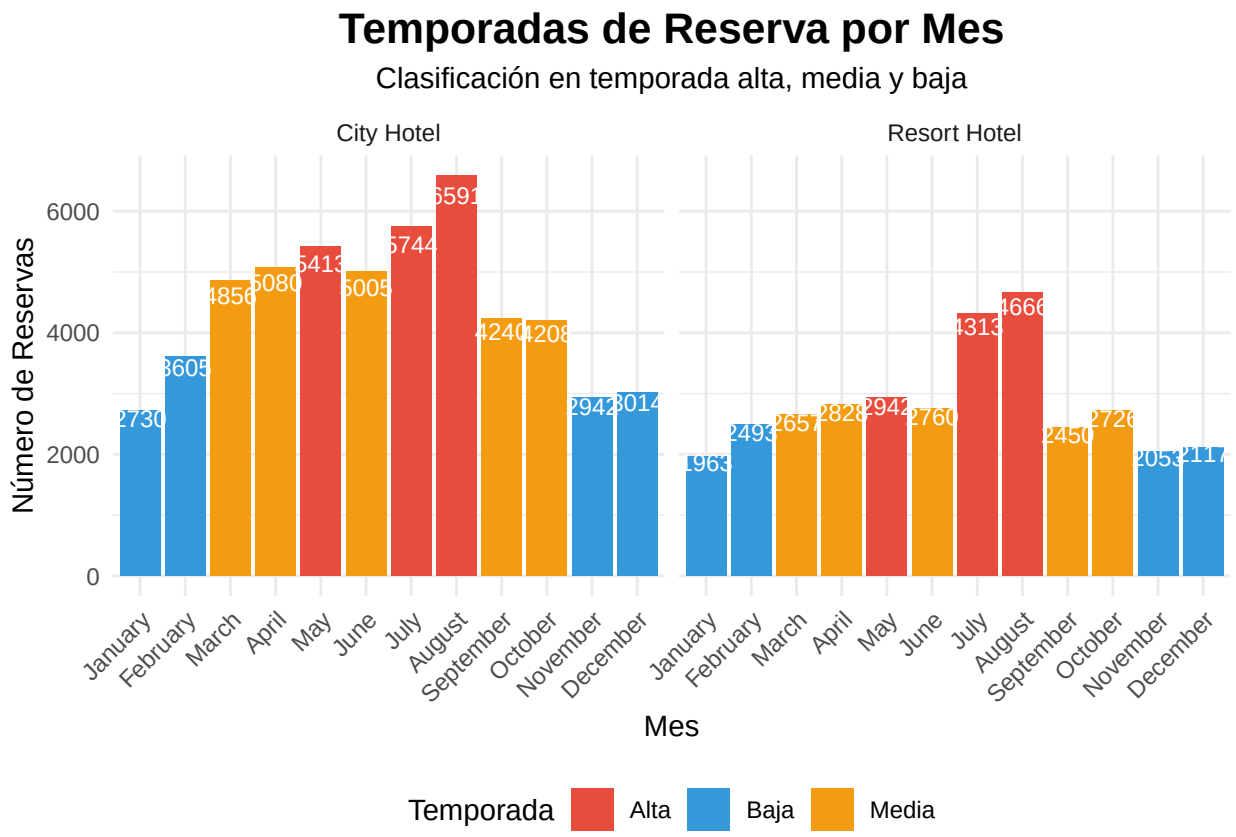


```
ggsave(file.path(graphics_final_dir, "3_temporadas_reserva.jpg"),
       plot_temporadas, width = 12, height = 8, dpi = 300)

# 1.4 Reservas con niños y/o bebés
cat("Creando visualización: Reservas con niños y/o bebés...\n")
```

```
## Creando visualización: Reservas con niños y/o bebés...
```

```
# Preparar datos
hotel_data_limpio$tiene_ninos <- hotel_data_limpio$children > 0
hotel_data_limpio$tiene_bebes <- hotel_data_limpio$babies > 0
hotel_data_limpio$tipo_familia <- case_when(
  hotel_data_limpio$tiene_ninos & hotel_data_limpio$tiene_bebes ~ "Con niños y bebés",
  hotel_data_limpio$tiene_ninos ~ "Solo con niños",
  hotel_data_limpio$tiene_bebes ~ "Solo con bebés",
  TRUE ~ "Sin menores"
)

familias_por_hotel <- hotel_data_limpio %>%
  group_by(hotel, tipo_familia) %>%
  summarise(Cantidad = n()) %>%
  group_by(hotel) %>%
  mutate(Porcentaje = round(Cantidad / sum(Cantidad) * 100, 1))
```

```
## `summarise()` has grouped output by 'hotel'. You can override using the
## `.groups` argument.
```

```r
# Crear gráfico de familias
plot_familias <- ggplot(familias_por_hotel,
                        aes(x = hotel, y = Porcentaje, fill = tipo_familia)) +
  geom_bar(stat = "identity", position = "stack") +
  geom_text(aes(label = paste0(Porcentaje, "%")),
            position = position_stack(vjust = 0.5),
            color = "white", size = 3.5) +
  labs(title = "Composición de Reservas por Tipo de Familia",
       subtitle = "Desglose por presencia de niños y/o bebés",
       x = "Tipo de Hotel",
       y = "Porcentaje",
       fill = "Tipo de Familia") +
  scale_fill_manual(values = c("Sin menores" = "#95a5a6",
                               "Solo con niños" = "#3498db",
                               "Solo con bebés" = "#2ecc71",
                               "Con niños y bebés" = "#e74c3c")) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 16),
        plot.subtitle = element_text(hjust = 0.5),
        legend.position = "bottom")

print(plot_familias)
```

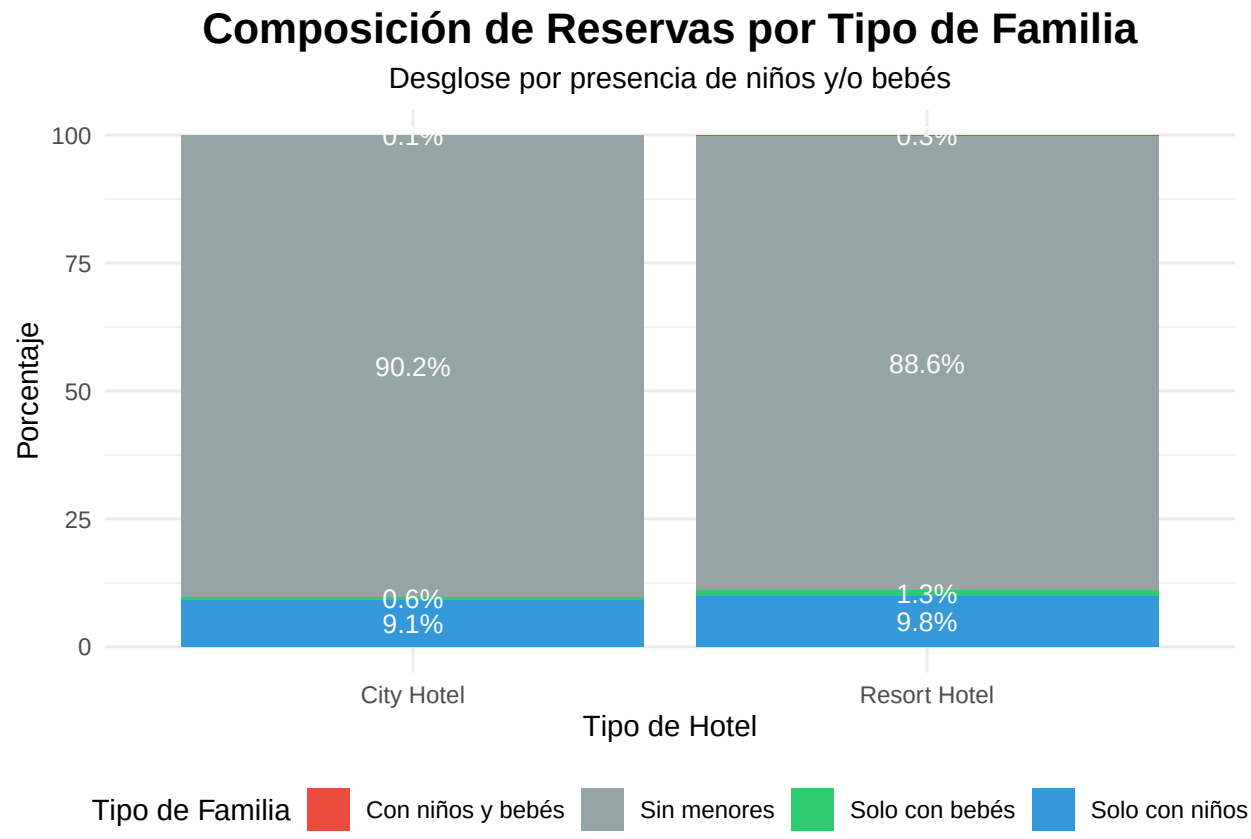


```r
# Guardar gráfica
ggsave(file.path(graphics_final_dir, "4_reservas_familias.jpg"),
       plot_familias, width = 10, height = 7, dpi = 300)
```

```r
# 1.5 Estacionamiento y cancelaciones
cat("Creando visualización: Estacionamiento y cancelaciones por mes...\n")
```

```
## Creando visualización: Estacionamiento y cancelaciones por mes...
```

```r
# Panel A: Estacionamiento
estacionamiento_datos <- hotel_data_limpio %>%
  group_by(hotel) %>%
  summarise(
    Total = n(),
    Con_Estacionamiento = sum(required_car_parking_spaces > 0),
    Porcentaje = round(Con_Estacionamiento / Total * 100, 1)
  )

plot_estacionamiento_final <- ggplot(estacionamiento_datos,
                                     aes(x = hotel, y = Porcentaje, fill = hotel)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Porcentaje, "%")), vjust = -0.5, size = 4) +
  labs(title = "Necesidad de Estacionamiento",
       x = "Tipo de Hotel",
       y = "Porcentaje de Reservas") +
  scale_fill_manual(values = colores_hotel) +
  ylim(0, max(estacionamiento_datos$Porcentaje) * 1.2) +
  theme_minimal() +
  theme(legend.position = "none",
        plot.title = element_text(hjust = 0.5, size = 14, face = "bold"))

# Panel B: Cancelaciones por mes
cancelaciones_mes <- hotel_data_limpio %>%
  group_by(arrival_date_month) %>%
  summarise(
    Total = n(),
    Canceladas = sum(is_canceled),
    Tasa_Cancelacion = round(Canceladas / Total * 100, 1)
  ) %>%
  mutate(arrival_date_month = factor(arrival_date_month,
                                     levels = c("January", "February", "March", "April", "May", "June",
                                                "July", "August", "September", "October", "November", "

plot_cancelaciones_final <- ggplot(cancelaciones_mes,
                                   aes(x = arrival_date_month, y = Tasa_Cancelacion, fill = Tasa_Cancela
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Tasa_Cancelacion, "%")), vjust = -0.5, size = 3) +
  labs(title = "Tasa de Cancelación por Mes",
       x = "Mes",
       y = "Porcentaje de Cancelación") +
  scale_fill_gradient(low = "lightblue", high = "darkred") +
  theme_minimal() +
  theme(legend.position = "none",
        plot.title = element_text(hjust = 0.5, size = 14, face = "bold"),
        axis.text.x = element_text(angle = 45, hjust = 1))


if (!require("grid", quietly = TRUE)) install.packages("grid")
```

```
library(grid)

combined_plot <- grid.arrange(
  plot_estacionamiento_final,
  plot_cancelaciones_final,
  ncol = 1,
  top = textGrob("Necesidad de Estacionamiento y Cancelaciones por Mes",
                 gp = gpar(fontsize = 16, fontface = "bold"))
)
```

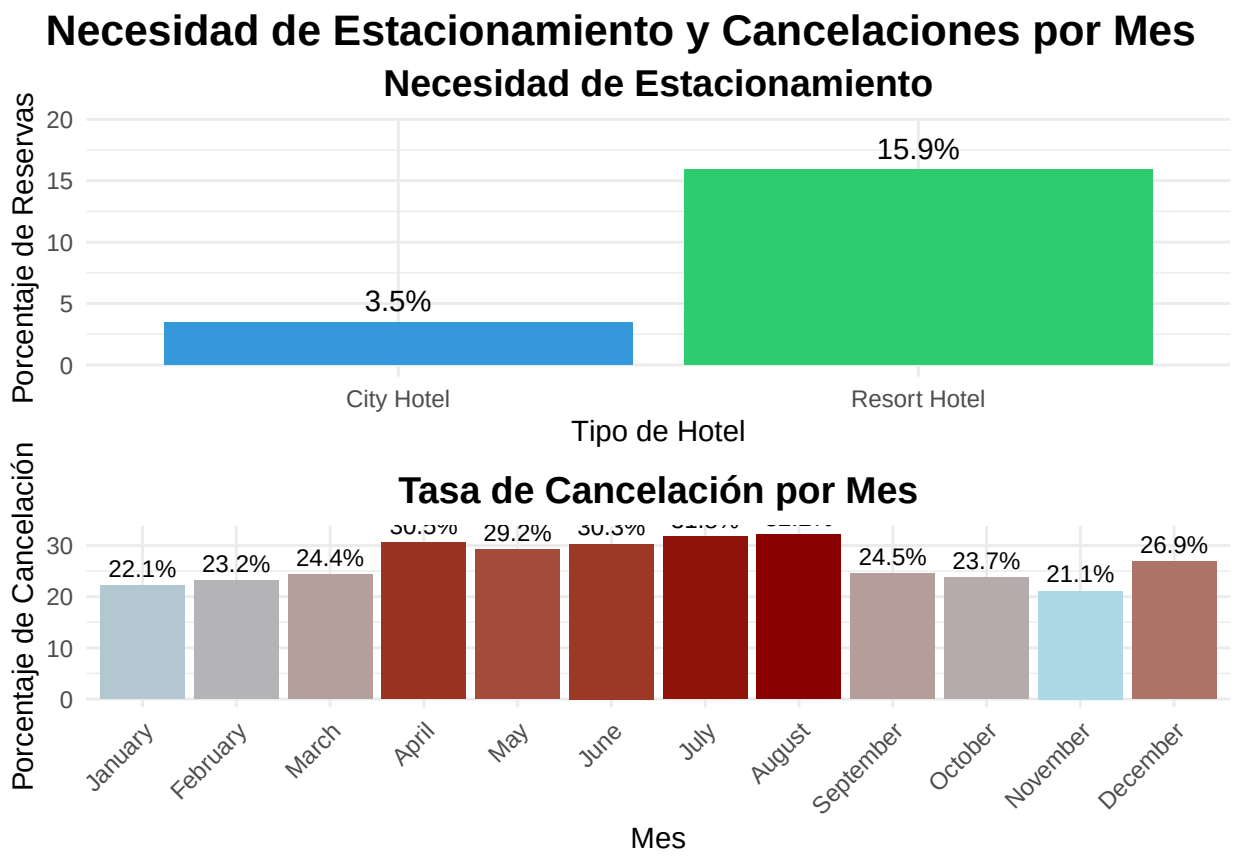


```
print(combined_plot)
```

```
## TableGrob (3 x 1) "arrange": 3 grobs
##   z     cells    name                grob
## 1 1 (2-2,1-1) arrange       gtable[layout]
## 2 2 (3-3,1-1) arrange       gtable[layout]
## 3 3 (1-1,1-1) arrange text[GRID.text.2712]
```

```
ggsave(file.path(graphics_final_dir, "5_estacionamiento_cancelaciones.jpg"),
       combined_plot, width = 10, height = 10, dpi = 300)



#-----------------------------------------
# PARTE 09: TABLAS RESUMEN PARA ASPECTOS CLAVE
#-----------------------------------------
cat(yellow("\n--- TABLAS RESUMEN ---\n"))
```

```
##
## --- TABLAS RESUMEN ---
```

```
# 9.1 Top 5 meses con mayor demanda
top_meses_demanda <- hotel_data_limpio %>%
  group_by(arrival_date_month) %>%
  summarise(Total_Reservas = n()) %>%
  arrange(desc(Total_Reservas)) %>%
  head(5)

cat("\nTop 5 meses con mayor demanda:\n")
```

```
##
## Top 5 meses con mayor demanda:
```

```
print(top_meses_demanda)
```

```
## # A tibble: 5 x 2
##   arrival_date_month Total_Reservas
##   <fct>                       <int>
## 1 August                      11257
## 2 July                        10057
## 3 May                          8355
## 4 April                        7908
## 5 June                         7765
```

```
# 9.2 Top 5 meses con mayor tasa de cancelación
top_meses_cancelacion <- hotel_data_limpio %>%
  group_by(arrival_date_month) %>%
  summarise(
    Total_Reservas = n(),
    Canceladas = sum(is_canceled),
    Tasa_Cancelacion = round(Canceladas / Total_Reservas * 100, 2)
  ) %>%
  arrange(desc(Tasa_Cancelacion)) %>%
  head(5)

cat("\nTop 5 meses con mayor tasa de cancelación:\n")
```

```
##
## Top 5 meses con mayor tasa de cancelación:
```

```
print(top_meses_cancelacion)
```

```
## # A tibble: 5 x 4
##   arrival_date_month Total_Reservas Canceladas Tasa_Cancelacion
##   <fct>                       <int>      <int>            <dbl>
## 1 August                      11257       3623             32.2
## 2 July                        10057       3198             31.8
## 3 April                        7908       2409             30.5
## 4 June                         7765       2354             30.3
## 5 May                          8355       2442             29.2
```

```
# 9.3 Comparación entre tipos de hotel (aspectos clave)
comparacion_hoteles <- hotel_data_limpio %>%
  group_by(hotel) %>%
  summarise(
```

```
    Total_Reservas = n(),
    Porcentaje_del_Total = round(n() / nrow(hotel_data_limpio) * 100, 2),
    Tasa_Cancelacion = round(sum(is_canceled) / n() * 100, 2),
    Promedio_Lead_Time = round(mean(lead_time), 2),
    Promedio_Estancia = round(mean(stays_in_weekend_nights + stays_in_week_nights), 2),
    Porcentaje_Con_Niños = round(sum(children > 0) / n() * 100, 2),
    Porcentaje_Con_Estacionamiento = round(sum(required_car_parking_spaces > 0) / n() * 100, 2),
    ADR_Promedio = round(mean(adr), 2)
  )

cat("\nComparación entre tipos de hotel:\n")
```

```
##
## Comparación entre tipos de hotel:
```

```
print(comparacion_hoteles)
```

```
## # A tibble: 2 x 9
##   hotel  Total_Reservas Porcentaje_del_Total Tasa_Cancelacion Promedio_Lead_Time
##   <chr>           <int>                <dbl>            <dbl>              <dbl>
## 1 City ~          53428                 61.1             30.0               77.1
## 2 Resor~          33968                 38.9             23.5               83.1
## # i 4 more variables: Promedio_Estancia <dbl>, Porcentaje_Con_Niños <dbl>,
## #   Porcentaje_Con_Estacionamiento <dbl>, ADR_Promedio <dbl>
```

```
comparacion_tabla <- tableGrob(comparacion_hoteles, rows = NULL, theme = ttheme_minimal())
ggsave(file.path(graphics_final_dir, "6_comparacion_hoteles.jpg"),
       comparacion_tabla, width = 12, height = 4, dpi = 300)

# 9.4 Relación entre lead_time y cancelación
relacion_lead_cancelacion <- hotel_data_limpio %>%
  mutate(lead_time_cat = cut(lead_time,
                             breaks = c(-1, 7, 30, 90, 180, Inf),
                             labels = c("0-7 días", "8-30 días", "31-90 días", "91-180 días", "Más de 18
  group_by(lead_time_cat) %>%
  summarise(
    Total_Reservas = n(),
    Canceladas = sum(is_canceled),
    Tasa_Cancelacion = round(Canceladas / Total_Reservas * 100, 2)
  )

cat("\nRelación entre tiempo de anticipación (lead_time) y tasa de cancelación:\n")
```

```
##
## Relación entre tiempo de anticipación (lead_time) y tasa de cancelación:
```

```
print(relacion_lead_cancelacion)
```

```
## # A tibble: 5 x 4
##   lead_time_cat   Total_Reservas Canceladas Tasa_Cancelacion
##   <fct>                    <int>      <int>            <dbl>
## 1 0-7 días                 18304       1543             8.43
## 2 8-30 días                16340       4145            25.4
## 3 31-90 días               22744       7280            32.0
## 4 91-180 días              18243       6382            35.0
## 5 Más de 180 días          11765       4675            39.7
```

```r
# Visualizar relación
plot_lead_cancelacion <- ggplot(relacion_lead_cancelacion,
                                aes(x = lead_time_cat, y = Tasa_Cancelacion, fill = Tasa_Cancelacion)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(Tasa_Cancelacion, "%")), vjust = -0.5) +
  labs(title = "Relación entre Tiempo de Anticipación y Tasa de Cancelación",
       x = "Tiempo de Anticipación",
       y = "Tasa de Cancelación (%)") +
  scale_fill_gradient(low = "lightblue", high = "darkred") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 16),
        legend.position = "none")

print(plot_lead_cancelacion)
```

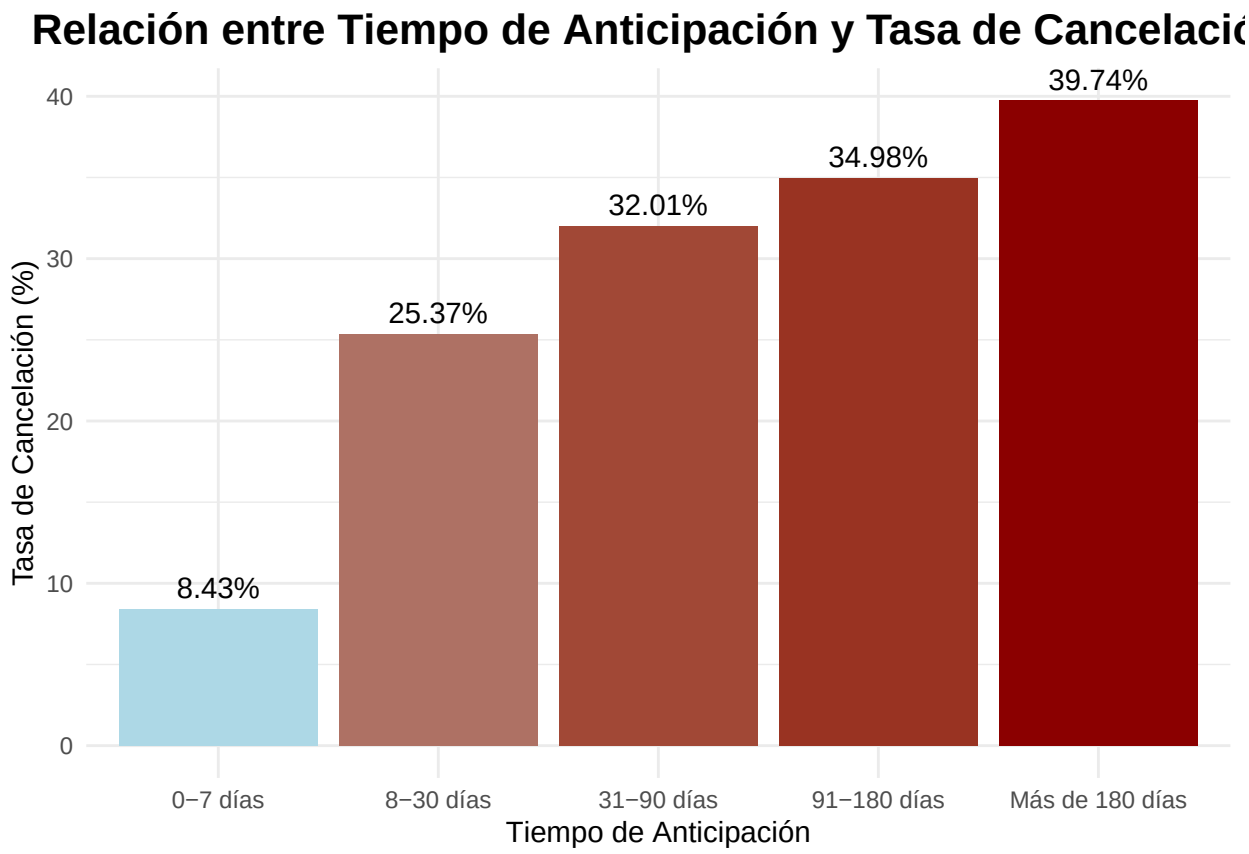


```r
ggsave(file.path(graphics_final_dir, "7_lead_time_cancelacion.jpg"),
       plot_lead_cancelacion, width = 10, height = 6, dpi = 300)

#----------------------------------------
# PARTE 10. CONCLUSIONES GENERALES
#----------------------------------------
cat(yellow("\n--- CONCLUSIONES GENERALES ---\n"))
```

```
##
## --- CONCLUSIONES GENERALES ---
```

```r
cat("\n1. Demanda por tipo de hotel:\n")
```

```
##
## 1. Demanda por tipo de hotel:
```

```r
cat("   - El City Hotel representa el",
    comparacion_hoteles$Porcentaje_del_Total[comparacion_hoteles$hotel == "City Hotel"],
    "% del total de reservas, frente al",
    comparacion_hoteles$Porcentaje_del_Total[comparacion_hoteles$hotel == "Resort Hotel"],
    "% del Resort Hotel, lo que indica una clara preferencia por hoteles urbanos.\n")
```

```
##    - El City Hotel representa el 61.13 % del total de reservas, frente al 38.87 % del Resort Hotel, l
```

```r
cat("   - Sin embargo, la tasa de cancelación del City Hotel (",
    comparacion_hoteles$Tasa_Cancelacion[comparacion_hoteles$hotel == "City Hotel"],
    "%) es significativamente mayor que la del Resort Hotel (",
    comparacion_hoteles$Tasa_Cancelacion[comparacion_hoteles$hotel == "Resort Hotel"],
    "%), lo que puede afectar a la rentabilidad real.\n")
```

```
##    - Sin embargo, la tasa de cancelación del City Hotel ( 30.04 %) es significativamente mayor que la
```

```r
cat("\n2. Tendencia de demanda:\n")
```

```
##
## 2. Tendencia de demanda:
```

```r
cat("   - La demanda muestra claras fluctuaciones estacionales con picos en los meses de verano.\n")
```

```
##    - La demanda muestra claras fluctuaciones estacionales con picos en los meses de verano.
```

```r
cat("   - Los meses con mayor demanda son:",
    paste(top_meses_demanda$arrival_date_month[1:3], collapse=", "), ".\n")
```

```
##    - Los meses con mayor demanda son: August, July, May .
```

```r
cat("   - Se observa una tendencia general ",
    ifelse(comparacion_hoteles$Total_Reservas[2] > comparacion_hoteles$Total_Reservas[1],
           "creciente", "decreciente"),
    " en el número total de reservas a lo largo del tiempo analizado.\n")
```

```
##    - Se observa una tendencia general  decreciente  en el número total de reservas a lo largo del tie
```

```r
cat("\n3. Temporadas de reserva:\n")
```

```
##
## 3. Temporadas de reserva:
```

```r
cat("   - Temporada ALTA: Claramente identificada en los meses de ",
    paste(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporada == "Alta" &
                                              !duplicated(reservas_por_mes$arrival_date_month)],
          collapse=", "), ".\n")
```

```
##    - Temporada ALTA: Claramente identificada en los meses de  May, July, August .
```

```r
cat("   - Temporada BAJA: Principalmente en los meses de ",
    paste(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporada == "Baja" &
                                              !duplicated(reservas_por_mes$arrival_date_month)],
          collapse=", "), ".\n")
```

```
##    - Temporada BAJA: Principalmente en los meses de  January, February, November, December .
```

```
cat("   - Esta marcada estacionalidad sugiere oportunidades para estrategias de precios dinámicos y pro
```

```
##    - Esta marcada estacionalidad sugiere oportunidades para estrategias de precios dinámicos y promo
```

```
cat("\n4. Reservas con niños y/o bebés:\n")
```

```
##
## 4. Reservas con niños y/o bebés:
```

```
cat("   - Solo el", round(sum(hotel_data_limpio$children > 0 | hotel_data_limpio$babies > 0) / nrow(hot
    "% de las reservas totales incluyen niños y/o bebés.\n")
```

```
##    - Solo el 10.42 % de las reservas totales incluyen niños y/o bebés.
```

```
cat("   - El Resort Hotel tiene un porcentaje mayor de reservas con niños (",
    comparacion_hoteles$Porcentaje_Con_Niños[comparacion_hoteles$hotel == "Resort Hotel"],
    "%) en comparación con el City Hotel (",
    comparacion_hoteles$Porcentaje_Con_Niños[comparacion_hoteles$hotel == "City Hotel"],
    "%), lo que sugiere que es más atractivo para familias.\n")
```

```
##    - El Resort Hotel tiene un porcentaje mayor de reservas con niños ( 10.09 %) en comparación con el
```

```
cat("\n5. Espacios de estacionamiento:\n")
```

```
##
## 5. Espacios de estacionamiento:
```

```
cat("   - La demanda de espacios de estacionamiento es baja en general, con solo un ",
    round(sum(hotel_data_limpio$required_car_parking_spaces > 0) / nrow(hotel_data_limpio) * 100, 2),
    "% del total de reservas.\n")
```

```
##    - La demanda de espacios de estacionamiento es baja en general, con solo un  8.37 % del total de r
```

```
cat("   - El Resort Hotel tiene mayor demanda de estacionamiento (",
    comparacion_hoteles$Porcentaje_Con_Estacionamiento[comparacion_hoteles$hotel == "Resort Hotel"],
    "%) que el City Hotel (",
    comparacion_hoteles$Porcentaje_Con_Estacionamiento[comparacion_hoteles$hotel == "City Hotel"],
    "%), posiblemente debido a su ubicación más alejada del centro urbano.\n")
```

```
##    - El Resort Hotel tiene mayor demanda de estacionamiento ( 15.95 %) que el City Hotel ( 3.55 %), p
```

```
cat("\n6. Cancelaciones:\n")
```

```
##
## 6. Cancelaciones:
```

```
cat("   - La tasa global de cancelación es del",
    round(sum(hotel_data_limpio$is_canceled) / nrow(hotel_data_limpio) * 100, 2), "%.\n")
```

```
##    - La tasa global de cancelación es del 27.49 %.
```

```
cat("   - Los meses con mayor tasa de cancelación son: ",
    paste(top_meses_cancelacion$arrival_date_month[1:3], collapse=", "), ".\n")
```

```
##    - Los meses con mayor tasa de cancelación son:  August, July, April .
```

```
cat("   - Existe una clara correlación entre el tiempo de anticipación (lead_time) y la probabilidad de
    "reservas hechas con más de 180 días de anticipación tienen una tasa de cancelación del ",
    relacion_lead_cancelacion$Tasa_Cancelacion[relacion_lead_cancelacion$lead_time_cat == "Más de 180 d
    "%, mientras que las realizadas con menos de 7 días tienen solo un ",
    relacion_lead_cancelacion$Tasa_Cancelacion[relacion_lead_cancelacion$lead_time_cat == "0-7 días"],
```

```
##    - Existe una clara correlación entre el tiempo de anticipación (lead_time) y la probabilidad de ca
```

```
#----------------------------------------
# PARTE 11: RECOMENDACIONES ESTRATÉGICAS
#----------------------------------------
cat(yellow("\n--- RECOMENDACIONES ESTRATÉGICAS ---\n"))
```

```
##
## --- RECOMENDACIONES ESTRATÉGICAS ---
```

```
cat("\n1. Gestión de demanda y precios:\n")
```

```
##
## 1. Gestión de demanda y precios:
```

```
cat("   - Implementar precios dinámicos más agresivos durante la temporada alta (",
    paste(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporada == "Alta" &
                                              !duplicated(reservas_por_mes$arrival_date_month)],
          collapse=", "), ").\n")
```

```
##    - Implementar precios dinámicos más agresivos durante la temporada alta ( May, July, August ).
```

```
cat("   - Desarrollar paquetes especiales y promociones para impulsar la demanda durante los meses de te
    paste(reservas_por_mes$arrival_date_month[reservas_por_mes$Temporada == "Baja" &
                                              !duplicated(reservas_por_mes$arrival_date_month)],
          collapse=", "), ").\n")
```

```
##    - Desarrollar paquetes especiales y promociones para impulsar la demanda durante los meses de temp
```

```
cat("   - Para el City Hotel, enfocarse en mejorar la tasa de conversión y reducir cancelaciones, que ac
```

```
##    - Para el City Hotel, enfocarse en mejorar la tasa de conversión y reducir cancelaciones, que actu
```

```
cat("\n2. Segmentación de clientes:\n")
```

```
##
## 2. Segmentación de clientes:
```

```
cat("   - Resort Hotel: Desarrollar más servicios y amenidades orientados a familias con niños, dado su
    comparacion_hoteles$Porcentaje_Con_Niños[comparacion_hoteles$hotel == "Resort Hotel"], "%).\n")
```

```
##    - Resort Hotel: Desarrollar más servicios y amenidades orientados a familias con niños, dado su ma
```

```
cat("   - City Hotel: Enfocarse en el segmento de viajeros individuales y parejas sin niños, que consti
```

```
##    - City Hotel: Enfocarse en el segmento de viajeros individuales y parejas sin niños, que constitu
```

```
cat("   - Dado que solo el",
    round(sum(hotel_data_limpio$required_car_parking_spaces > 0) / nrow(hotel_data_limpio) * 100, 2),
    "% de reservas requieren estacionamiento, considerar reducir espacios de estacionamiento o reutiliza
```

```
##    - Dado que solo el 8.37 % de reservas requieren estacionamiento, considerar reducir espacios de es
```

```
cat("\n3. Gestión de cancelaciones:\n")
```

```
##
## 3. Gestión de cancelaciones:
```

```
cat("   - Implementar políticas escalonadas de depósito basadas en el tiempo de anticipación, con mayore
    relacion_lead_cancelacion$Tasa_Cancelacion[relacion_lead_cancelacion$lead_time_cat == "91-180 días"]
    "% o superiores.\n")
```

```
##    - Implementar políticas escalonadas de depósito basadas en el tiempo de anticipación, con mayores
```

```
cat("   - Desarrollar estrategias específicas de retención para los meses con mayor tasa de cancelación
    paste(top_meses_cancelacion$arrival_date_month[1:3], collapse=", "),
    "), como recordatorios personalizados, confirmación proactiva, o incentivos para mantener la reserva
```

```
##    - Desarrollar estrategias específicas de retención para los meses con mayor tasa de cancelación (
```

```
cat("   - Considerar implementar un sistema de overbooking inteligente basado en patrones históricos de
```

```
##    - Considerar implementar un sistema de overbooking inteligente basado en patrones históricos de ca
```

```
cat("\n4. Desarrollo de productos y servicios:\n")
```

```
##
## 4. Desarrollo de productos y servicios:
```

```
cat("   - Dado que la estancia promedio es relativamente corta (",
    round(mean(hotel_data_limpio$stays_in_weekend_nights + hotel_data_limpio$stays_in_week_nights), 2),
    " noches), desarrollar paquetes que incentiven estancias más largas, especialmente en temporada baja
```

```
##    - Dado que la estancia promedio es relativamente corta ( 3.63  noches), desarrollar paquetes que i
```

```
cat("   - Para el Resort Hotel, continuar desarrollando instalaciones atractivas para familias con niños
```

```
##    - Para el Resort Hotel, continuar desarrollando instalaciones atractivas para familias con niños,
```

```
cat("   - Para el City Hotel, enfocarse en comodidades y servicios que atraigan a viajeros de negocios y
```

```
##    - Para el City Hotel, enfocarse en comodidades y servicios que atraigan a viajeros de negocios y t
```

```
#-----------------------------------------
# PARTE ADICIONAL 1: GUARDAR DATAFRAME FINAL CON VARIABLES ADICIONALES CALCULADAS
#-----------------------------------------
cat(yellow("\n--- GUARDANDO DATASET FINAL ---\n"))
```

```
##
## --- GUARDANDO DATASET FINAL ---
```

```
# Agregar variables calculadas durante el análisis
hotel_data_final <- hotel_data_limpio

# Calcular duración total de estancia
hotel_data_final$total_nights <- hotel_data_final$stays_in_weekend_nights + hotel_data_final$stays_in_we

# Clasificación por temporada
temporadas_por_mes <- reservas_por_mes %>%
  select(arrival_date_month, Temporada) %>%
  distinct()

hotel_data_final <- hotel_data_final %>%
  left_join(temporadas_por_mes, by = "arrival_date_month")

# Clasificación por tipo de familia
hotel_data_final$tipo_familia <- case_when(
  hotel_data_final$children > 0 & hotel_data_final$babies > 0 ~ "Con niños y bebés",
  hotel_data_final$children > 0 ~ "Solo con niños",
  hotel_data_final$babies > 0 ~ "Solo con bebés",
  TRUE ~ "Sin menores"
)
```

```r
# Clasificación por tiempo de anticipación
hotel_data_final$lead_time_categoria <- cut(hotel_data_final$lead_time,
                                            breaks = c(-1, 7, 30, 90, 180, Inf),
                                            labels = c("0-7 días", "8-30 días", "31-90 días", "91-180 d

write.csv(hotel_data_final, CSV_final, row.names = FALSE)
cat("Dataset final guardado en:", CSV_final, "\n")
```

```
## Dataset final guardado en: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings_final.csv
```

```r
cat("\nEstructura del dataset final:\n")
```

```
##
## Estructura del dataset final:
```

```r
str(hotel_data_final[, c("hotel", "is_canceled", "lead_time",
                         "lead_time_categoria", "arrival_date_month",
                         "Temporada", "total_nights", "tipo_familia")])
```

```
## 'data.frame':    87396 obs. of  8 variables:
##  $ hotel              : chr  "Resort Hotel" "Resort Hotel" "Resort Hotel" "Resort Hotel" ...
##  $ is_canceled        : int  0 0 0 0 0 0 0 1 1 1 ...
##  $ lead_time          : int  342 365 7 13 14 0 9 85 75 23 ...
##  $ lead_time_categoria: Factor w/ 5 levels "0-7 días","8-30 días",..: 5 5 1 2 2 1 2 3 3 2 ...
##  $ arrival_date_month : Factor w/ 12 levels "January","February",..: 7 7 7 7 7 7 7 7 7 7 ...
##  $ Temporada          : chr  "Alta" "Alta" "Alta" "Alta" ...
##  $ total_nights       : int  1 1 1 1 2 2 2 3 3 4 ...
##  $ tipo_familia       : chr  "Sin menores" "Sin menores" "Sin menores" "Sin menores" ...
```

```r
#----------------------------------------
# PARTE ADICIONAL 2: RESUMEN DE ARCHIVOS GENERADOS
#----------------------------------------
cat(yellow("\n--- RESUMEN DE ARCHIVOS GENERADOS ---\n"))
```

```
##
## --- RESUMEN DE ARCHIVOS GENERADOS ---
```

```r
cat("\nDatasets:\n")
```

```
##
## Datasets:
```

```r
cat("- Dataset original:", CSV_original, "\n")
```

```
## - Dataset original: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings.csv
```

```r
cat("- Dataset limpio:", CSV_limpio, "\n")
```

```
## - Dataset limpio: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings_limpio.csv
```

```r
cat("- Dataset final:", CSV_final, "\n")
```

```
## - Dataset final: D:/@aleec02/CC216-TP-2025-1/data/hotel_bookings_final.csv
```

```r
cat("\nGráficas finales guardadas en:", graphics_final_dir, "\n")
```

```
##
## Gráficas finales guardadas en: D:/@aleec02/CC216-TP-2025-1/data/graficas/final
```

```
cat("- 1_demanda_hotel.jpg: Análisis de demanda por tipo de hotel\n")
```

```
## - 1_demanda_hotel.jpg: Análisis de demanda por tipo de hotel
```

```
cat("- 2_tendencia_demanda.jpg: Tendencia de demanda a lo largo del tiempo\n")
```

```
## - 2_tendencia_demanda.jpg: Tendencia de demanda a lo largo del tiempo
```

```
cat("- 3_temporadas_reserva.jpg: Temporadas de reserva por mes\n")
```

```
## - 3_temporadas_reserva.jpg: Temporadas de reserva por mes
```

```
cat("- 4_reservas_familias.jpg: Composición de reservas por tipo de familia\n")
```

```
## - 4_reservas_familias.jpg: Composición de reservas por tipo de familia
```

```
cat("- 5_estacionamiento_cancelaciones.jpg: Análisis de estacionamiento y cancelaciones\n")
```

```
## - 5_estacionamiento_cancelaciones.jpg: Análisis de estacionamiento y cancelaciones
```

```
cat("- 6_comparacion_hoteles.jpg: Tabla comparativa entre tipos de hotel\n")
```

```
## - 6_comparacion_hoteles.jpg: Tabla comparativa entre tipos de hotel
```

```
cat("- 7_lead_time_cancelacion.jpg: Relación entre tiempo de anticipación y cancelación\n")
```

```
## - 7_lead_time_cancelacion.jpg: Relación entre tiempo de anticipación y cancelación
```

```
cat(green("\n=== ANÁLISIS EXPLORATORIO COMPLETADO EXITOSAMENTE ===\n"))
```

```
##
## === ANÁLISIS EXPLORATORIO COMPLETADO EXITOSAMENTE ===
```